



UNIVERSIDADE FEDERAL DO CEARÁ
CENTRO DE CIÊNCIAS
DEPARTAMENTO DE COMPUTAÇÃO
PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO
MESTRADO ACADÊMICO EM CIÊNCIA DA COMPUTAÇÃO

PAULO ROBERTO PINTO COSTA

MORTE ARTIFICIAL: PRECARIEDADE É TUDO QUE VOCÊ PRECISA

FORTALEZA

2026

PAULO ROBERTO PINTO COSTA

MORTE ARTIFICIAL: PRECARIEDADE É TUDO QUE VOCÊ PRECISA

Dissertação apresentada ao Curso de Mestrado Acadêmico em Ciência Da Computação do Programa de Pós-Graduação em Ciência Da Computação do Centro de Ciências da Universidade Federal do Ceará, como requisito parcial à obtenção do título de mestre em Computação Gráfica. Área de Concentração: Aprendizado por Reforço

Orientador: Prof. Dr. Yuri Lenon Barbosa Nogueira

Coorientador: Prof. Dr. Joaquim Bento Cavalcante Neto

FORTALEZA

2026

PAULO ROBERTO PINTO COSTA

MORTE ARTIFICIAL: PRECARIEDADE É TUDO QUE VOCÊ PRECISA

Dissertação apresentada ao Curso de Mestrado Acadêmico em Ciência Da Computação do Programa de Pós-Graduação em Ciência Da Computação do Centro de Ciências da Universidade Federal do Ceará, como requisito parcial à obtenção do título de mestre em Computação Gráfica. Área de Concentração: Aprendizado por Reforço

Aprovada em: xx/xx/xxxx

BANCA EXAMINADORA

Prof. Dr. Yuri Lenon Barbosa Nogueira (Orientador)
Universidade Federal do Ceará (UFC)

Prof. Dr. Joaquim Bento Cavalcante
Neto (Coorientador)
Universidade Federal do Ceará (UFC)

Prof. Dr. Creto Augusto Vidal
Universidade Federal do Ceará (UFC)

Prof. Dr. José Gilvan Rodrigues Maia
Universidade Federal do Ceará (UFC)

À minha família, pelos esforços dedicados à minha formação como pessoa. À minha mãe, por sua imensa ajuda e por seu apoio em todas as fases da minha vida. Seu cuidado tornou tudo isso possível. Ao meu pai, muito obrigado por, mesmo de longe, oferecer todo o apoio quando necessário. À Marília, pelo amor, pelo carinho e, principalmente, pelos puxões de orelha durante este capítulo da minha vida.

AGRADECIMENTOS

Agradeço, primeiramente, aos meus pais, Roberto e Neila. Afinal, eles foram os responsáveis por toda a minha formação. Cada pedra em que pisei e que me trouxe até este momento teve uma mãozinha deles. Obrigado por nunca deixarem faltar nada à nossa família e por sempre me permitirem escolher o meu próprio caminho. Literalmente, sem vocês, eu não estaria aqui. Agradeço também à minha irmã, Camila, por ter sido a pioneira da família a estudar computação. Você certamente me influenciou na escolha dessa área, mesmo que talvez nem saiba disso. Também não poderia deixar de agradecer a todos os meus familiares que apoiaram os meus estudos e se preocuparam com o meu futuro. Eles ficaram tão felizes quanto eu quando ingressei na UFC e tenho certeza de que também celebram esta conquista. Muito obrigado a todos os meus familiares.

Agradeço à minha namorada e futura esposa, Marília, pelo apoio durante todo este processo, por demonstrar interesse pelo meu trabalho, por me escutar falar sobre ele em tantos momentos e por fazer perguntas que certamente contribuíram para fortalecê-lo. Seu apoio foi uma das grandes forças que me tiraram da inércia e me ajudaram a concluir este trabalho. Agradeço também à minha sogra, Cilene, companheira de pós-graduação. Foi muito divertido compartilhar esse momento com você. Juntos, vivenciamos dores e alegrias semelhantes durante este processo.

Agradeço ao meu orientador, Yuri, por aceitar me orientar mesmo quando eu ainda não possuía experiência prévia em pesquisa e por me conduzir a uma área de investigação tão interessante. Se não fosse por você, eu não estaria aqui para contar esta história. Agradeço ao meu grupo de pesquisa, CRAb, por disponibilizar as máquinas utilizadas na realização dos experimentos. Agradeço ao meu coorientador, Bento, e ao professor Creto por contribuírem continuamente para o aprimoramento da pesquisa. Agradeço ao Rodrigo, companheiro de pesquisa, por todas as nossas discussões nas quartas-feiras, por meio das quais conseguimos refinar cada vez mais o nosso trabalho. Agradeço ao Anderson por ter tido, no passado, a brilhante ideia do glaucoma. Agradeço também ao professor Gilvan por aceitar participar da banca examinadora deste trabalho. Suas contribuições foram muito importantes.

Agradeço aos servidores da UFC, especialmente a Vlademiro e Eldo, pela ajuda no laboratório, tanto com os equipamentos quanto com o acesso aos espaços. Agradeço também à equipe de limpeza, que sempre manteve não apenas o laboratório, mas todo o bloco limpo. Em especial, agradeço a Lourdes, por abrir a porta do LIA quando eu chegava cedo demais.

Agradeço às instituições de fomento à pesquisa pelo apoio durante o período do mestrado. O presente trabalho foi realizado com apoio da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior – Brasil (CAPES) – Código de Financiamento 001. Por fim, agradeço ao LSBd pelo apoio no último semestre do mestrado, por meio da concessão de uma bolsa.

“Nós só podemos ver um pouco do futuro, mas o
suficiente para perceber que há muito a fazer.”

(Alan Turing)

RESUMO

A autonomia artificial exige repensar o papel da recompensa no Aprendizado por Reforço. Em abordagens tradicionais, o agente aprende a partir de recompensas externas definidas pelo projetista, o que pode produzir comportamentos eficientes, mas limita a emergência de formas mais autônomas de ação. Inspirado pela Inteligência Artificial Enativa, este trabalho investiga agentes cuja ação é orientada por condições internas de viabilidade. Para isso, utiliza-se a tarefa experimental *Health-Gathering*, da plataforma VizDoom, na qual um agente perde vida continuamente em uma sala com chão ácido e percebe o ambiente por meio da visão. Em vez de recompensar explicitamente a coleta de *medikits*, itens que restauram a vida do agente, introduz-se uma forma artificial de precariedade corporal. À medida que o agente permanece sem coletar *medikits*, sua visão é degradada, sendo restaurada quando ele os coleta. A motivação do agente é produzida por uma recompensa intrínseca baseada em curiosidade, calculada por meio do método *Random Network Distillation* (RND). Como a curiosidade depende das observações visuais, a degradação perceptiva reduz a capacidade do agente de obter recompensa intrínseca. Assim, manter-se viável torna-se condição para continuar percebendo, explorando e agindo. A política aprendida será analisada com técnicas de interpretabilidade visual, buscando compreender como precariedade, percepção e curiosidade podem favorecer comportamentos adaptativos sem impor diretamente uma solução por recompensas extrínsecas. Sendo assim, se a autonomia nasce da precariedade, então ser inteligente é, fundamentalmente, estar engajado em um processo contínuo de negociação com a possibilidade de deixar de existir.

Palavras-chave: Agentes autônomos. Inteligência Artificial Enativa. Curiosidade. Aprendizado por Reforço Profundo. Precariedade. Motivação intrínseca

ABSTRACT

Artificial autonomy requires rethinking the role of reward in Reinforcement Learning. In traditional approaches, the agent learns from external rewards defined by the designer, which may produce efficient behaviors but limits the emergence of more autonomous forms of action. Inspired by Enactive Artificial Intelligence, this work investigates agents whose actions are guided by internal viability conditions. To this end, the *Health-Gathering* experimental task from the VizDoom platform is used, in which an agent continuously loses health in a room with an acidic floor and perceives the environment through vision. Instead of explicitly rewarding the collection of *medikits*, items that restore the agent’s health, an artificial form of bodily precariousness is introduced. As the agent remains without collecting *medikits*, its vision progressively deteriorates and is restored when it collects them. The agent’s motivation is produced by an intrinsic curiosity-based reward calculated using the *Random Network Distillation* (RND) method. Since curiosity depends on visual observations, perceptual degradation reduces the agent’s ability to obtain intrinsic reward. Thus, remaining viable becomes a condition for continuing to perceive, explore, and act. The learned policy will be analyzed using visual interpretability techniques to understand how precariousness, perception, and curiosity may promote adaptive behaviors without directly imposing a solution through extrinsic rewards. Therefore, if autonomy arises from precariousness, then being intelligent fundamentally means being engaged in a continuous process of negotiating with the possibility of ceasing to exist.

Keywords: Autonomous agents. Enactive Artificial Intelligence. Curiosity. Deep Reinforcement Learning. Precariousness. Intrinsic motivation.

LISTA DE ILUSTRAÇÕES

- Figura 1 – Ilustração esquemática da agência: o sistema é formado por uma rede de processos autossustentados (círculo à esquerda) em interação com o ambiente, na qual mecanismos internos de regulação modulam esse acoplamento, configurando o comportamento do agente para manter a sua identidade. **Fonte:** Adaptado de Barandiaran *et al.* (2009). 32
- Figura 2 – Diagrama do ciclo de interação no aprendizado por reforço. O agente observa o estado do ambiente, seleciona uma ação com base em sua política e a executa no ambiente. Como consequência, o ambiente transita para um novo estado e fornece ao agente um sinal numérico de recompensa. Esse ciclo de percepção–ação–*feedback* se repete continuamente, permitindo que o agente ajuste seu comportamento ao longo do tempo de forma a maximizar a recompensa acumulada. **Fonte:** Adaptado de Sutton e Barto (2018). . . . 33
- Figura 3 – Esquema de Aprendizado por Reforço Profundo. Uma Rede Neural Profunda aprende a política π que o agente utiliza para executar uma ação no ambiente. Uma recompensa e a informação sobre o novo estado do sistema são devolvidas ao agente, que aprimora e aprende sua política de acordo. **Fonte:** Adaptado de Pozza *et al.* (2022). 36
- Figura 4 – Representação esquemática de uma arquitetura CNN, destacando os blocos de extração de características (convolução e pooling) e os blocos de classificação final (camadas densas e softmax). **Fonte:** Adaptado de MathWorks (2026). . 38
- Figura 5 – Arquitetura do método *Random Network Distillation* (RND). O erro quadrático médio (MSE) entre a saída da Rede Alvo fixa ($f(s_t)$) e a Rede Preditora treinável ($\hat{f}(s_t)$) é utilizado como sinal de curiosidade ou recompensa intrínseca. 47
- Figura 6 – Visão panorâmica do método Grad-CAM. A ilustração detalha o fluxo de processamento onde informações de gradiente são utilizadas para ponderar os mapas de características das camadas convolucionais, resultando na geração de um mapa de calor que destaca as regiões relevantes da imagem de entrada para a classificação final. **Fonte:** Adaptado de Theocharis (2024). 48

Figura 7 – Exemplo esquemático de <i>specification gaming</i> em uma tarefa de empilhamento de Lego. O agente satisfaz a métrica especificada, elevar a face inferior do bloco vermelho, sem realizar o objetivo pretendido de empilhar o bloco vermelho sobre o azul. Fonte: Adaptado de Popov <i>et al.</i> (2017).	55
Figura 8 – Visão superior do ambiente da tarefa <i>Health-Gathering</i> . Os itens em formato de “+” representam os <i>medikits</i> distribuídos no ambiente, que podem ser coletados pelo agente para restaurar sua vida. Fonte: Elaborada pelo autor .	63
Figura 9 – Etapas de pré-processamento da observação visual do agente: imagem RGB original com resolução de 320×240 pixels, conversão para escala de cinza, redimensionamento para 84×84 pixels e normalização dos valores para o intervalo $[0, 1]$. Fonte: Elaborada pelo autor	66
Figura 10 – Arquitetura da rede neural utilizada pela política do agente, composta por três camadas convolucionais, uma etapa de vetorização, uma camada totalmente conectada com 512 unidades e a camada de saída. Fonte: Elaborada pelo autor.	68
Figura 11 – Comparação ilustrativa entre uma visão sem comprometimento, à esquerda, e a perda de visão periférica associada ao glaucoma, à direita. Fonte: American Optometric Association (American Optometric Association, s.d.).	73
Figura 12 – Evolução da percepção visual do agente com glaucoma artificial de força 100. Da esquerda para a direita, a figura mostra a visão limpa após 0 <i>frames</i> sem comer, glaucoma inicial após 1 <i>frame</i> , degradação intermediária após 20 <i>frames</i> e degradação severa após 50 <i>frames</i> . Fonte: Elaborada pelo autor . .	75
Figura 13 – Arquitetura compartilhada pelas redes alvo e preditora do RND, composta por três camadas convolucionais, uma etapa de vetorização e duas camadas totalmente conectadas. Fonte: Elaborada pelo autor.	78
Figura 14 – Distribuições espaciais dos <i>medikits</i> utilizadas nas análises comportamentais. Da esquerda para a direita, são apresentadas as distribuições em quadrado, círculo, <i>grid</i> e seno. Os sinais de “+” indicam os <i>medikits</i> , enquanto o ponto vermelho indica a posição inicial do agente no episódio. Fonte: Elaborada pelo autor.	84

Figura 15 – Exemplo ilustrativo de mapa de calor inspirado em Grad-CAM aplicado à tarefa <i>Health-Gathering</i> . As regiões mais quentes indicam as áreas da observação com maior relevância para a decisão do agente, isto é, aquelas que mais importam na análise visual da política aprendida. Fonte: Elaborada pelo autor.	86
Figura 16 – Duração média dos episódios ao longo do treinamento nas condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca baseada em RND, sob glaucoma de força 50. As regiões sombreadas representam a variabilidade entre as sementes experimentais. Fonte: Elaborada pelo autor.	88
Figura 17 – Trajetórias produzidas pelas políticas salvas após 9 633 792 passos de treinamento nas distribuições em quadrado, círculo, seno e <i>grid</i> , sob as condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca baseada em RND, para glaucoma de força 50. Fonte: Elaborada pelo autor.	90
Figura 18 – Evolução da recompensa intrínseca calculada pelo módulo RND após 200 704 passos de treinamento e da precariedade perceptiva ao longo de um episódio com glaucoma de força 50. A estrela indica a coleta de um <i>medikit</i> e a consequente restauração da visão. Fonte: Elaborada pelo autor.	92
Figura 19 – Mapas de Grad-CAM para as condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca calculada pelo RND, sob glaucoma de força 50. A linha superior apresenta as políticas após 100 352 passos de treinamento, e a linha inferior apresenta as políticas após 9 633 792 passos. As regiões mais quentes possuem maior relevância para a saída analisada da política segundo o Grad-CAM. Fonte: Elaborada pelo autor.	93
Figura 20 – Duração média dos episódios ao longo do treinamento nas condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca calculada pelo RND, sob glaucoma de força 100. As regiões sombreadas representam a variabilidade entre as sementes experimentais. Fonte: Elaborada pelo autor.	95
Figura 21 – Trajetórias produzidas pelas políticas salvas após 9 533 440 passos de treinamento nas distribuições em quadrado, círculo, seno e <i>grid</i> , sob as condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca calculada pelo RND, para glaucoma de força 100. Fonte: Elaborada pelo autor.	96

Figura 22 – Evolução da recompensa intrínseca calculada pelo módulo RND após 200 704 passos de treinamento e da precariedade perceptiva ao longo de um episódio com glaucoma de força 100. A estrela indica a coleta de um <i>medikit</i> e a consequente restauração da visão. Fonte: Elaborada pelo autor.	98
Figura 23 – Mapas de Grad-CAM para as condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca calculada pelo RND, sob glaucoma de força 100. A linha superior apresenta as políticas após 100 352 passos de treinamento, e a linha inferior apresenta as políticas após 9 533 440 passos. As regiões mais quentes possuem maior relevância para a saída analisada da política segundo o Grad-CAM. Fonte: Elaborada pelo autor.	99
Figura 24 – Duração média dos episódios ao longo do treinamento nas condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca calculada pelo RND, sob glaucoma de força 200. As regiões sombreadas representam a variabilidade entre as sementes experimentais. Fonte: Elaborada pelo autor.	101
Figura 25 – Trajetórias produzidas pelas políticas salvas após 9 533 440 passos de treinamento nas distribuições em quadrado, círculo, seno e <i>grid</i> , sob as condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca calculada pelo RND, para glaucoma de força 200. Fonte: Elaborada pelo autor.	103
Figura 26 – Evolução da recompensa intrínseca calculada pelo módulo RND após 200 704 passos de treinamento e da precariedade perceptiva ao longo de um episódio com glaucoma de força 200. A estrela indica a coleta de um <i>medikit</i> e a consequente restauração da visão. Fonte: Elaborada pelo autor.	104
Figura 27 – Mapas de Grad-CAM para as condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca calculada pelo RND, sob glaucoma de força 200. A linha superior apresenta as políticas após 100 352 passos de treinamento, e a linha inferior apresenta as políticas após 9 533 440 passos. As regiões mais quentes possuem maior relevância para a saída analisada da política segundo o Grad-CAM. Fonte: Elaborada pelo autor.	105

- Figura 28 – Duração média dos episódios ao longo do treinamento nas condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca calculada pelo RND, sob glaucoma de força 0. As regiões sombreadas representam a variabilidade entre as sementes experimentais. **Fonte:** Elaborada pelo autor. 107
- Figura 29 – Trajetórias produzidas pelas políticas salvas após 9 132 032 passos de treinamento nas distribuições em quadrado, círculo, seno e *grid*, sob as condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca calculada pelo RND, para glaucoma de força 0. **Fonte:** Elaborada pelo autor. 110
- Figura 30 – Evolução da recompensa intrínseca calculada pelo módulo RND após 301 056 passos de treinamento e da precariedade perceptiva ao longo de um episódio com glaucoma de força 0. A estrela indica a coleta de um *medikit*. **Fonte:** Elaborada pelo autor. 111
- Figura 31 – Mapas de Grad-CAM para as condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca calculada pelo RND, sob glaucoma de força 0. A linha superior apresenta as políticas após 100 352 passos de treinamento, e a linha inferior apresenta as políticas após 9 132 032 passos. As regiões mais quentes possuem maior relevância para a saída analisada da política segundo o Grad-CAM. **Fonte:** Elaborada pelo autor. 113

LISTA DE TABELAS

Tabela 1 – Hiperparâmetros de aprendizado utilizados no PPO.	67
Tabela 2 – Arquitetura da rede neural utilizada pelo agente.	68
Tabela 3 – Configurações de execução do treinamento.	70
Tabela 4 – Arquitetura das redes alvo e preditora utilizadas no RND.	77

SUMÁRIO

1	INTRODUÇÃO	19
1.1	Motivação	19
1.2	Contextualização	21
1.3	Objetivos	23
1.4	Proposta	24
1.5	Organização	25
2	FUNDAMENTAÇÃO TEÓRICA	26
2.1	Fundamentação Filosófica	26
2.1.1	<i>Inteligência Como Resolução de Problemas</i>	<i>26</i>
2.1.2	<i>Inteligência: Um Fenômeno Emergente da Vida</i>	<i>27</i>
2.1.3	<i>Inteligência e a Dinâmica da Sobrevivência</i>	<i>29</i>
2.2	Fundamentação Computacional	32
2.2.1	<i>Aprendizado por Reforço</i>	<i>32</i>
2.2.1.1	<i>Definição Matemática</i>	<i>33</i>
2.2.1.2	<i>Função Valor de Estado</i>	<i>34</i>
2.2.2	<i>Aprendizado por Reforço Profundo</i>	<i>35</i>
2.2.2.1	<i>Redes Neurais Convolucionais</i>	<i>37</i>
2.2.3	<i>Aprendizado Contínuo</i>	<i>39</i>
2.2.3.1	<i>Métodos de Gradiente de Política</i>	<i>40</i>
2.2.3.2	<i>Trust Region Policy Optimization</i>	<i>41</i>
2.2.3.3	<i>Proximal Policy Optimization</i>	<i>43</i>
2.2.4	<i>Exploração, Motivação Intrínseca e Curiosidade</i>	<i>44</i>
2.2.4.1	<i>Recompensa Intrínseca</i>	<i>44</i>
2.2.4.2	<i>Random Network Distillation</i>	<i>46</i>
2.2.5	<i>Análise Visual da Política Aprendida</i>	<i>47</i>
2.2.5.1	<i>Gradient-weighted Class Activation Mapping</i>	<i>48</i>
3	TRABALHOS RELACIONADOS	50
3.1	Aprendizado por Reforço Profundo	50
3.2	Função de Recompensa e Suas Implicações	54
3.3	Aprendizado Enativo	57

3.4	Aprendizado por Curiosidade	59
4	METODOLOGIA	62
4.1	Ambiente Experimental	62
4.2	Formulação em Aprendizado por Reforço	64
4.2.1	<i>Observação</i>	65
4.2.2	<i>Ação</i>	65
4.2.3	<i>Recompensa</i>	66
4.3	Algoritmo de Aprendizado	66
4.3.1	<i>Hiperparâmetros</i>	67
4.3.2	<i>Arquitetura da Rede Neural</i>	68
4.4	Configuração Experimental do Treinamento	69
4.5	Estratégia de Recompensa	70
4.5.1	<i>O Problema da Recompensa</i>	70
4.5.2	<i>Autopoiese, IA Enativa e Perspectiva de Solução</i>	71
4.6	Glaucoma como Precariedade	73
4.6.1	<i>Glaucoma Artificial</i>	74
4.7	Recompensa Intrínseca por Curiosidade	76
4.7.1	<i>Calculando a Recompensa Intrínseca</i>	77
4.7.2	<i>Recompensa Intrínseca e sua Relação com o Glaucoma</i>	78
4.7.3	<i>Limites da Recompensa Intrínseca</i>	79
4.8	Configurações Experimentais	80
4.9	Métricas de Avaliação	81
4.9.1	<i>Duração Média dos Episódios</i>	82
4.9.2	<i>Análise Comportamental das Trajetórias</i>	83
4.9.3	<i>Relação entre Recompensa Intrínseca e Precariedade</i>	84
4.10	Análise Visual da Política Apreendida	85
5	RESULTADOS	87
5.1	Resultados por Força de Glaucoma	87
5.1.1	<i>Glaucoma de Força 50</i>	88
5.1.1.1	<i>Duração Média dos Episódios</i>	88
5.1.1.2	<i>Análise das Trajetórias</i>	89
5.1.1.3	<i>Relação entre Recompensa Intrínseca e Precariedade</i>	91

5.1.1.4	<i>Análise Visual com Grad-CAM</i>	92
5.1.2	<i>Glaucoma de Força 100</i>	94
5.1.2.1	<i>Duração Média dos Episódios</i>	94
5.1.2.2	<i>Análise das Trajetórias</i>	95
5.1.2.3	<i>Relação entre Recompensa Intrínseca e Precariedade</i>	97
5.1.2.4	<i>Análise Visual com Grad-CAM</i>	99
5.1.3	<i>Glaucoma de Força 200</i>	100
5.1.3.1	<i>Duração Média dos Episódios</i>	100
5.1.3.2	<i>Análise das Trajetórias</i>	102
5.1.3.3	<i>Relação entre Recompensa Intrínseca e Precariedade</i>	104
5.1.3.4	<i>Análise Visual com Grad-CAM</i>	105
5.1.4	<i>Glaucoma de Força 0</i>	107
5.1.4.1	<i>Duração Média dos Episódios</i>	107
5.1.4.2	<i>Análise das Trajetórias</i>	108
5.1.4.3	<i>Relação entre Recompensa Intrínseca e Precariedade</i>	111
5.1.4.4	<i>Análise Visual com Grad-CAM</i>	112
5.2	<i>Síntese Comparativa dos Resultados</i>	114
6	CONCLUSÃO	116
6.1	Contribuições do Trabalho	118
6.2	Limitações	119
6.3	Trabalhos Futuros	120
	REFERÊNCIAS	122

1 INTRODUÇÃO

Este capítulo apresenta o problema investigado e a proposta adotada para aproximar a ideia de autoconstrução dos sistemas vivos ao Aprendizado por Reforço Profundo. O ponto de partida é que um organismo não age apenas para maximizar um número externo. Sua atividade está ligada à manutenção de um corpo cuja continuidade não está garantida. A partir dessa inspiração, o trabalho investiga se um agente artificial pode aprender comportamentos de sobrevivência quando sua percepção e suas possibilidades de interação dependem de uma condição corporal precária.

Inicialmente, são discutidas a motivação e a contextualização da pesquisa. Em seguida, são apresentados os objetivos, a proposta experimental e a organização dos demais capítulos da dissertação.

1.1 Motivação

A Inteligência Artificial contemporânea tem alcançado resultados expressivos em tarefas de percepção, planejamento e tomada de decisão, incluindo jogos complexos, alinhamento de modelos de linguagem e manipulação robótica (BERNER *et al.*, 2019; OUYANG *et al.*, 2022; YANG *et al.*, 2024). Parte importante desses avanços decorre do Aprendizado por Reforço, paradigma no qual um agente ajusta seu comportamento por meio da interação com um ambiente e das consequências expressas por sinais de recompensa (SUTTON; BARTO, 2018). Quando esse paradigma é combinado com redes neurais profundas, torna-se possível aprender políticas a partir de observações de alta dimensionalidade, como imagens (MNIH *et al.*, 2013; Mnih *et al.*, 2015).

A recompensa oferece uma forma eficiente de especificar tarefas. Se o objetivo é fazer um agente coletar um item, uma solução direta consiste em atribuir um valor positivo à coleta. Entretanto, essa escolha não apenas orienta o aprendizado. Ela também informa previamente ao agente qual elemento do ambiente deve ser importante e qual comportamento deve ser repetido. O significado do item e a solução esperada são introduzidos pelo projetista por meio de um número.

Essa abordagem é adequada quando o interesse principal está em resolver uma tarefa bem definida. Contudo, ela se torna limitada quando o objetivo é investigar formas mais autônomas de inteligência. Um sistema vivo não recebe de um observador externo uma

recompensa numérica por manter seu corpo. Ele precisa agir porque sua própria organização é precária e pode deixar de existir. A possibilidade de morte e a necessidade contínua de manutenção fazem com que determinadas interações adquiram relevância para o organismo.

Este trabalho parte dessa diferença. Em vez de recompensar diretamente a coleta de um recurso, busca-se fazer com que o agente trabalhe para manter uma condição corporal artificial. Sua continuidade no ambiente depende de sua vida, que diminui ao longo do episódio e pode resultar em sua morte. Além disso, sua capacidade de perceber o mundo se degrada quando permanece muito tempo sem coletar recursos. O agente não deve buscar o *medikit* apenas porque um número foi associado ao item. O recurso deve adquirir relevância porque altera sua condição e preserva suas possibilidades futuras de percepção, exploração e sobrevivência.

Pode-se questionar por que adotar esse caminho quando seria mais simples fornecer diretamente a recompensa desejada. A resposta está no tipo de problema investigado. A engenharia de recompensas procura descrever o comportamento que o agente deve aprender. A proposta deste trabalho procura controlar as condições a partir das quais um comportamento pode tornar-se relevante. Em vez de modificar o algoritmo para cada solução ou criar uma recompensa específica para cada ação desejada, modifica-se o corpo artificial e sua relação com o ambiente. A curiosidade permanece como um mecanismo geral de exploração, mas passa a ser modulada pelas consequências que a precariedade produz sobre a experiência do agente.

Essa mudança permite investigar se um mesmo mecanismo de aprendizado pode produzir comportamentos diferentes quando o corpo ou o ambiente são alterados. Organismos com constituições distintas não encontram exatamente o mesmo mundo de significados, mesmo quando ocupam um ambiente semelhante. Da mesma forma, alterações no ambiente modificam as possibilidades de ação disponíveis a um mesmo organismo. Trabalhos de Nogueira *et al.* (2020) e Nogueira *et al.* (2016) mostram que comportamentos de navegação e forrageamento podem emergir de relações entre energia, percepção, corpo e ambiente sem a descrição direta de um objetivo comportamental. Esses estudos reforçam que a organização do agente e a riqueza de seu acoplamento com o ambiente influenciam os comportamentos que podem emergir.

A questão central desta dissertação é, portanto, se a curiosidade artificial pode ser orientada por meio do corpo do agente. Mais especificamente, investiga-se se uma condição corporal precária pode modificar a percepção e fazer com que a coleta de recursos se torne relevante sem receber uma recompensa extrínseca específica. A proposta não abandona o Aprendizado por Reforço nem elimina o uso de sinais numéricos. Ela utiliza uma recompensa

intrínseca baseada em curiosidade, mas desloca a definição da solução da função de recompensa para a relação entre corpo, percepção e ambiente.

1.2 Contextualização

O Aprendizado por Reforço Profundo tem sido aplicado a diferentes classes de ambientes, desde jogos Atari baseados em imagens até tarefas de controle contínuo e simulação robótica (MNIH *et al.*, 2013; Mnih *et al.*, 2015; SCHULMAN *et al.*, 2017; YANG *et al.*, 2024). Neste trabalho, utiliza-se a plataforma VizDoom, que oferece ambientes tridimensionais em primeira pessoa e permite que o agente aprenda a partir de observações visuais (WYDMUCH *et al.*, 2018). Essa perspectiva é importante porque o agente não recebe uma descrição global do espaço. Ele precisa agir a partir da experiência visual produzida por sua posição e por sua orientação no ambiente.

A tarefa selecionada é a *Health-Gathering*. Nela, o agente permanece em uma sala cujo chão reduz continuamente sua vida. Os *medikits* distribuídos pelo ambiente restauram essa condição, e o episódio termina quando a vida se esgota. A morte do agente depende, portanto, do estado de seu corpo artificial e não de uma simples redução da recompensa acumulada. Essa dinâmica fornece uma base adequada para investigar comportamento de manutenção, pois o agente precisa encontrar recursos para continuar existindo no ambiente.

A interpretação dessa tarefa é inspirada pela Inteligência Artificial Enativa, que procura compreender a cognição a partir da organização autônoma do agente e de seu acoplamento contínuo com o ambiente (FROESE; ZIEMKE, 2009). Nessa perspectiva, a inteligência não consiste apenas na resolução de problemas definidos externamente. Ela emerge da atividade de um sistema corporificado que precisa manter sua própria continuidade e que produz um domínio de interações significativas a partir dessa necessidade.

O conceito de autopoiese descreve os sistemas vivos como redes de processos que produzem e mantêm continuamente os próprios componentes (MATURANA; VARELA, 1980; VARELA, 1991). A organização autopoietica não está garantida de antemão. Ela permanece exposta à possibilidade de desintegração e precisa ser reconstruída por meio da própria atividade do organismo. Essa condição é denominada precariedade. Um sistema precário depende de processos que precisam continuar ocorrendo para que sua identidade seja preservada.

O agente desenvolvido nesta dissertação não realiza autopoiese em sentido próprio. Ele não produz seus componentes, não define sua identidade e não estabelece autonomamente

seus limites de viabilidade. O glaucoma artificial oferece apenas uma aproximação operacional à ideia de um corpo que precisa ser mantido. Quando o agente permanece sem coletar *medikits*, sua percepção se degrada progressivamente. Quando coleta um recurso, recupera a condição perceptiva. Assim, agir sobre o ambiente produz uma forma limitada de reconstrução de sua capacidade de continuar percebendo e explorando.

Essa relação transforma o *medikit*. Do ponto de vista de um observador externo, ele continua sendo um objeto presente no cenário. Para o agente, entretanto, o item pode adquirir significado funcional porque interfere em sua condição corporal e em suas experiências futuras. A precariedade faz com que o ambiente deixe de ser apenas um conjunto de elementos visuais e passe a constituir um mundo de interações com consequências diferentes para a continuidade do agente.

O mecanismo utilizado para explorar essa relação é o glaucoma artificial. Uma região escurecida cresce progressivamente sobre a observação enquanto o agente permanece sem coletar recursos. A velocidade desse crescimento é controlada pela força do glaucoma. Quando um *medikit* é coletado, a observação é restaurada. O glaucoma não busca reproduzir clinicamente a doença humana. Ele funciona como uma forma computacional de precariedade perceptiva que conecta o estado do corpo artificial à capacidade de acessar o ambiente.

A política é treinada com o algoritmo *Proximal Policy Optimization* (PPO) (SCHULMAN *et al.*, 2017). A curiosidade é implementada por meio do *Random Network Distillation* (RND), que utiliza o erro de uma rede preditora como medida de novidade das observações (BURDA *et al.*, 2018b). Observações frequentes e degradadas tendem a tornar-se previsíveis e produzir recompensas menores. Quando a visão é restaurada, a imagem volta a apresentar maior quantidade de informação visual e pode produzir maior erro de predição. Dessa maneira, o corpo artificial modula a curiosidade sem que seja necessário atribuir uma recompensa específica ao *medikit*, à restauração da visão ou à sobrevivência.

O deslocamento proposto ocorre da engenharia da solução por recompensa para a engenharia das condições corporais e ambientais. O PPO e o RND permanecem os mesmos nas diferentes forças positivas de glaucoma. O que muda é a velocidade com que a condição perceptiva se deteriora. Se as políticas aprendidas também mudarem, essa diferença não decorrerá de uma nova regra de aprendizado ou de uma nova recompensa associada à coleta. Ela decorrerá da alteração do corpo e de seu acoplamento com o ambiente.

Essa proposta constitui uma contribuição na direção da autonomia e da inteligência

artificial, mas não pretende resolver o problema da autonomia. O trabalho não avalia autonomia constitutiva nem adaptatividade em seu sentido forte. Seu objetivo é mais restrito. Busca-se investigar uma forma de trazer para o Aprendizado por Reforço a ideia de que a atividade de um agente pode estar relacionada à manutenção de sua própria condição. Trata-se de um pequeno passo inspirado pela autoconstrução da vida, realizado dentro de uma arquitetura que permanece projetada externamente.

1.3 Objetivos

O objetivo geral deste trabalho é investigar experimentalmente se uma forma artificial de precariedade corporal pode orientar a curiosidade e favorecer comportamentos de manutenção em agentes de Aprendizado por Reforço Profundo sem recompensar diretamente a coleta de recursos. Nesse contexto, comportamento de manutenção designa uma resposta operacional às alterações de percepção e viabilidade da tarefa. O termo não indica a implementação de autopoiese, autonomia constitutiva ou adaptatividade em sentido forte.

De forma específica, este trabalho tem como objetivos

- Estruturar uma tarefa experimental na qual a continuidade do episódio dependa do estado corporal do agente e da coleta de recursos
- Implementar um mecanismo de glaucoma artificial capaz de degradar e restaurar gradualmente a percepção conforme a interação com os *medikits*
- Relacionar a condição corporal artificial à recompensa por curiosidade sem atribuir uma recompensa específica à coleta, à sobrevivência ou à restauração da visão
- Treinar agentes sob ausência de recompensa, recompensa extrínseca e recompensa intrínseca baseada em RND
- Avaliar como diferentes forças de glaucoma modificam o aprendizado, a estabilidade e a capacidade de sobrevivência
- Analisar se alterações no corpo artificial produzem mudanças no comportamento sem exigir modificações no PPO ou no mecanismo de curiosidade
- Comparar as trajetórias diante de diferentes distribuições espaciais de *medikits*
- Investigar a relação temporal entre precariedade perceptiva e recompensa intrínseca
- Examinar quais regiões das observações influenciam as decisões das políticas aprendidas

1.4 Proposta

A proposta experimental combina três condições de recompensa e quatro configurações corporais. A primeira condição não utiliza recompensa e funciona como controle negativo. A segunda utiliza a recompensa extrínseca da tarefa e funciona como controle positivo, pois informa diretamente ao agente quais consequências devem ser valorizadas. A terceira utiliza apenas a recompensa intrínseca calculada pelo RND e corresponde à proposta central do trabalho.

As forças de glaucoma avaliadas são 0, 50, 100 e 200. A força 0 preserva a visão durante todo o episódio e funciona como uma ablação da precariedade perceptiva. As demais forças produzem degradação em velocidades crescentes. Essa comparação permite observar se o comportamento muda quando o mesmo agente, treinado com o mesmo algoritmo e com o mesmo mecanismo de curiosidade, passa a possuir condições corporais diferentes.

A hipótese investigada é que a curiosidade isolada não estabelece uma relação confiável entre os *medikits* e a continuidade do agente. Quando a percepção se degrada, entretanto, a ausência de coleta torna as observações progressivamente mais pobres e previsíveis. A restauração da visão produzida pelo recurso volta a disponibilizar um ambiente visualmente rico. O RND pode então fornecer recompensas maiores em estados menos precários, favorecendo indiretamente ações que mantêm a capacidade perceptiva.

Espera-se, assim, que o *medikit* adquira relevância não porque a recompensa descreve sua importância, mas porque o item transforma a relação entre o agente e o ambiente. A política continua sendo atualizada por um sinal numérico, como exige o Aprendizado por Reforço utilizado nesta pesquisa. Contudo, o vínculo entre esse sinal e a sobrevivência não é programado como uma recompensa direta pela coleta. Ele depende da interação entre corpo artificial, degradação perceptiva, novidade das observações e história de aprendizado.

Os resultados são avaliados por meio da duração média dos episódios, da variabilidade entre sementes, das trajetórias em diferentes distribuições de recursos e da relação entre recompensa intrínseca e precariedade. A análise é complementada pelo *Gradient-weighted Class Activation Mapping* (Grad-CAM), que permite identificar regiões das observações relevantes para as decisões das políticas (SELVARAJU *et al.*, 2016). A combinação dessas dimensões busca verificar não apenas se os agentes sobrevivem, mas também como navegam, como a condição corporal modifica a curiosidade e quais elementos visuais participam das decisões.

1.5 Organização

Além desta introdução, o trabalho está organizado em cinco capítulos. O Capítulo 2 apresenta a fundamentação filosófica e computacional da pesquisa, abrangendo inteligência, autonomia, autopoiese, precariedade, Aprendizado por Reforço Profundo, motivação intrínseca, curiosidade artificial e interpretabilidade visual. O Capítulo 3 discute estudos sobre Aprendizado por Reforço Profundo, engenharia de recompensas, aprendizado enativo e aprendizado orientado por curiosidade.

O Capítulo 4 descreve a tarefa experimental, o corpo artificial do agente, o mecanismo de glaucoma, os algoritmos de aprendizado, as condições experimentais e as métricas de avaliação. O Capítulo 5 apresenta e discute os resultados quantitativos e qualitativos. Por fim, o Capítulo 6 reúne as conclusões da pesquisa, suas contribuições, suas limitações e as possibilidades de continuidade.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo reúne os conceitos filosóficos e computacionais que sustentam a pesquisa. A primeira parte discute diferentes concepções de inteligência e apresenta noções relacionadas à vida, à autonomia, à autopoiese e à perspectiva enativa. A segunda parte aborda os fundamentos do Aprendizado por Reforço e do Aprendizado por Reforço Profundo, incluindo métodos de otimização de políticas, motivação intrínseca, curiosidade artificial e técnicas de análise visual das políticas aprendidas.

2.1 Fundamentação Filosófica

2.1.1 *Inteligência Como Resolução de Problemas*

A palavra inteligência vem do latim *intelligentia*, derivada do verbo *intelligere* (*inter*, “entre” e *legere*, “escolher”, “colher”, “separar”, “ler”). Portanto, em sua origem, inteligência significa a capacidade de escolher entre várias opções ou, mais profundamente, “ler entre” (as linhas, os fatos, as aparências). Não é apenas processar o que está lá, mas discernir o que é relevante e o que não é.

Entretanto, na Inteligência Artificial (IA) atual, a concepção de “inteligência” é frequentemente reduzida a resolução de problemas, tarefas específicas, otimização ou desempenho em benchmarks, em detrimento de aspectos mais amplos da inteligência humana, como compreensão profunda, criatividade ou raciocínio contextual. A IA atual demonstra mais “conquista artificial” (conquistas em tarefas específicas) do que inteligência genuína, pois é limitada a problemas treinados, sem capacidade de resolver problemas novos como humanos. (GIGNAC; SZODORAI, 2024).

Um dos maiores e mais famosos exemplos desta concepção de inteligência pode ser vista em Turing (1950). Nesse texto, Alan Turing propõe uma reformulação da pergunta clássica “As máquinas podem pensar?” para evitar debates semânticos sobre os termos “máquina” e “pensar”. Em vez de definir diretamente o que é inteligência, ele introduz o jogo da imitação, hoje conhecido como Teste de Turing. No teste, um interrogador humano conversa por texto, sem ver ou ouvir os interlocutores, com dois participantes: um humano e uma máquina. O objetivo é determinar se a máquina consegue imitar respostas humanas de forma tão convincente que o interrogador não consiga distinguir qual é a máquina. Se a máquina passar no teste, Turing

sugere que seria razoável dizer que ela “pensa” ou exibe inteligência. Todavia, o Teste de Turing representa o início da visão contemporânea de inteligência, baseada em resolução de problemas específicos previamente definidos, como responder perguntas de forma indistinguível de um humano, sem exigir “leitura entre as linhas” (*intelligere*) ou consciência, sendo o “Argumento do Quarto Chinês” (SEARLE, 1980) o principal argumento a favor disto.

O “Argumento do Quarto Chinês” propõe um cenário hipotético destinado a ilustrar que a manipulação sintática (símbolos), por si só, não produz compreensão semântica (significado). Imagine uma pessoa que não fala chinês (como um falante nativo de português) trancada em uma sala. Essa pessoa recebe perguntas em chinês por uma fresta. Ela tem um manual em português com regras puramente sintáticas para manipular símbolos chineses (sem entender seu significado) e produzir respostas corretas em chinês. Seguindo rigorosamente as regras, as respostas saem indistinguíveis das de um falante nativo de chinês, ou seja, o sistema passa no Teste de Turing na imitação de uma pessoa falante de chinês. No entanto, a pessoa na sala não entende uma palavra de chinês, ela apenas manipula símbolos formais (sintaxe) sem qualquer semântica, incapaz de explicar o que lhe foi perguntado.

Searle (1980) distingue entre IA fraca (máquinas que simulam aspectos da cognição humana, como ferramentas úteis) e IA forte (a ideia de que um computador programado adequadamente literalmente entende, tem mente e consciência, como um humano). Mesmo com excelência em simulação de resolução de problemas (passar no teste), a IA atual permanece no nível sintático, processa símbolos sem discernir relevância profunda, sem criatividade ou raciocínio genuíno. Ela otimiza resultados, mas não “lê entre” os fatos com compreensão semântica, como sugere a raiz etimológica da inteligência.

Essas dificuldades sugerem que o desafio talvez não resida apenas em desenvolver algoritmos mais sofisticados ou métodos mais eficientes de aprendizado, mas em reconsiderar a própria natureza da inteligência. Em vez de concebê-la apenas como resolução de problemas ou manipulação de símbolos, a inteligência pode ser entendida como um fenômeno que emerge da dinâmica organizacional da vida.

2.1.2 *Inteligência: Um Fenômeno Emergente da Vida*

Uma abordagem alternativa para compreender a natureza da inteligência consiste em abordá-la a partir da biologia, ampliando o escopo das interpretações tradicionalmente associadas à computação. Nessa linha, a inteligência não é tratada apenas como a capacidade de

resolver problemas previamente definidos, mas como um fenômeno emergente das propriedades fundamentais dos sistemas vivos. Essa perspectiva tem origem no conceito de *autopoiese*, introduzido por Maturana e Varela (1980).

Autopoiese (do grego *auto*, “si mesmo”, e *poiesis*, “produção” ou “criação”) descreve a organização característica dos sistemas vivos. Um sistema autopoietico é uma rede de processos que produz continuamente os próprios componentes que, por sua vez, mantêm essa mesma rede de produção. Em outras palavras, um organismo vivo não é simplesmente uma coleção de partes organizadas externamente, mas uma rede dinâmica que produz e mantém a si mesma. Essa auto-produção contínua estabelece uma identidade operacional que distingue o sistema de seu ambiente.

Entretanto, essa identidade não implica isolamento. Pelo contrário, sistemas vivos dependem de interações constantes com o meio para manter sua organização. Essa relação é descrita por Maturana e Varela como *acoplamento estrutural*. O acoplamento estrutural refere-se à história recorrente de interações entre um organismo e seu ambiente, na qual perturbações externas desencadeiam mudanças estruturais no sistema, enquanto o próprio sistema responde a essas perturbações de acordo com sua organização interna. O ambiente não determina diretamente o comportamento do organismo, ele apenas desencadeia mudanças possíveis dentro das limitações estruturais do sistema (VARELA, 1991).

Ao longo do tempo, essas interações recorrentes levam a uma congruência estrutural entre o organismo e o ambiente no qual ele vive. O organismo torna-se adaptado ao domínio de interações que encontra regularmente, e sua própria estrutura reflete essa história de acoplamento. Dessa forma, a relação entre organismo e ambiente não é simplesmente de estímulo e resposta, mas de influência mútua.

Essa perspectiva tem implicações profundas para a compreensão da cognição. Segundo essa abordagem, cognição não deve ser entendida primariamente como manipulação de representações internas ou processamento de informações simbólicas. Em vez disso, cognição pode ser vista como um aspecto inerente da própria vida. Um sistema vivo, ao manter sua identidade autopoietica em interação contínua com o ambiente, deve constantemente distinguir entre interações que contribuem para sua continuidade e aquelas que ameaçam sua organização.

Esse processo de distinção é frequentemente descrito como “produção de sentido”. Um organismo não encontra no ambiente significados prontos ou informações previamente estruturadas. Em termos puramente físicos, o ambiente consiste apenas em fluxos de matéria

e energia. Entretanto, para o organismo, certas interações tornam-se relevantes ou irrelevantes dependendo de sua relação com a manutenção da própria identidade. Uma molécula de açúcar, por exemplo, possui apenas propriedades físico-químicas no ambiente, contudo, para uma bactéria capaz de metabolizá-la, essa mesma molécula adquire significado como fonte de energia (VARELA, 1991).

Assim, o significado não está no ambiente em si, nem é simplesmente projetado pelo organismo de forma arbitrária. Ele emerge da relação dinâmica entre o sistema autopoietico e seu meio. Essa relação dá origem ao que alguns autores distinguem como o *ambiente* observado externamente e o *mundo* vivido pelo organismo. O ambiente refere-se ao domínio físico descrito por um observador externo, enquanto o mundo corresponde ao domínio de interações significativas que surgem da perspectiva do próprio sistema vivo.

A partir dessa perspectiva, a cognição pode ser entendida como a atividade contínua pela qual um sistema vivo produz e mantém um mundo significativo enquanto preserva sua própria identidade. Essa atividade envolve uma tensão fundamental: por um lado, o organismo depende de seu ambiente e deve manter acoplamento com ele, por outro, é justamente essa atividade que estabelece a distinção entre o sistema e o ambiente, dando origem a um domínio próprio de significações.

Consequentemente, a inteligência pode ser vista como um fenômeno emergente da vida. Em vez de ser apenas a capacidade de resolver problemas formais ou executar tarefas específicas, inteligência estaria enraizada na dinâmica fundamental pela qual sistemas vivos mantêm sua autonomia, adaptam-se ao ambiente e produzem sentido em suas interações. Sob essa perspectiva, processos cognitivos complexos, como percepção, aprendizado e raciocínio, podem ser compreendidos como extensões de mecanismos mais básicos presentes na própria organização da vida.

2.1.3 Inteligência e a Dinâmica da Sobrevivência

A abordagem autopoietica apresentada anteriormente fornece uma base poderosa para repensar a natureza da cognição. Ao identificar a vida como um processo de auto-produção e manutenção de identidade, ela permite compreender o surgimento do significado como inerente à própria organização dos sistemas vivos. Entretanto, como discutido, essa perspectiva, por si só, permanece limitada ao estabelecer apenas uma normatividade binária: algo é bom apenas na medida em que contribui para a continuidade da identidade do sistema e ruim caso contrário.

Essa limitação torna-se evidente quando consideramos que organismos vivos não apenas sobrevivem ou deixam de sobreviver, mas operam continuamente em um espectro de diferentes graus de viabilidade, respondendo a perturbações, antecipando riscos e, em muitos casos, melhorando suas próprias condições de existência. Em outras palavras, a vida não é apenas manutenção, mas também regulação e adaptação.

É nesse contexto que emerge a abordagem da Inteligência Artificial Enativa, que busca estender os princípios da autopoiese em direção a uma teoria mais robusta da cognição natural e artificial (FROESE; ZIEMKE, 2009). Enação refere-se à ideia de que a cognição não consiste na representação de um mundo pré-dado, mas emerge da interação dinâmica entre um sistema autônomo e seu ambiente, por meio de suas ações corporificadas, nas quais o organismo “traz à tona” (enata) um domínio de significados relevante para sua própria viabilidade. Em vez de abandonar a noção de autonomia introduzida por Maturana e Varela, a IA Enativa a toma como ponto de partida, propondo dois princípios de design que visam orientar a construção de sistemas artificiais capazes de exibir formas mais genuínas de cognição:

1. **Autonomia Constitutiva:** O primeiro desses princípios, estabelece que um agente artificial deve ser constitutivamente autônomo, isto é, deve possuir uma organização interna capaz de produzir e manter sua própria identidade. Esse princípio é diretamente enraizado na noção de autopoiese discutida anteriormente. Assim como nos sistemas vivos, a identidade do agente não deve ser imposta externamente, mas emergir de uma rede de processos internos que se sustentam mutuamente. Nesse sentido, o agente não é apenas um sistema que executa funções pré-definidas, mas um sistema cuja própria existência depende da continuidade de sua organização.
2. **Adaptatividade:** Segundo Di Paolo (2005), um sistema adaptativo é aquele capaz de regular sua própria dinâmica em resposta a perturbações internas e externas, mantendo-se dentro de limites de viabilidade. Essa noção introduz o conceito de “restrição de viabilidade”, que se refere ao conjunto de condições que devem ser satisfeitas para que o sistema continue existindo, permitindo que ele identifique tendências (positivas ou negativas) e aja para se afastar de estados fatais.

Embora esses princípios orientem a discussão conceitual desta pesquisa, eles não são assumidos como requisitos implementados ou avaliados pelo experimento. O agente desenvolvido não é constitutivamente autônomo, pois sua arquitetura, sua condição de viabilidade e os mecanismos que regulam sua percepção são definidos externamente. Da mesma forma, o

trabalho não pretende demonstrar adaptatividade no sentido forte da IA Enativa. Autonomia constitutiva e adaptatividade funcionam como referências para indicar uma direção de pesquisa, enquanto o experimento se limita a investigar se uma condição interna artificialmente projetada pode adquirir consequências sobre percepção, exploração e comportamento.

De acordo com Froese e Ziemke (2009), essa noção de restrição de viabilidade mantida em aberto, permite duas interpretações distintas. Por um lado, a restrição de viabilidade pode ser imposta externamente, como em sistemas projetados ou algoritmos evolutivos. Por outro lado, e mais profundamente, essa restrição pode ser entendida como intrínseca à própria identidade do sistema, o que implica que o agente não apenas segue regras de sobrevivência, mas constitui essas regras a partir de sua própria organização.

Essa segunda interpretação radicaliza a proposta autopoietica e torna o problema da cognição artificial significativamente mais desafiador. Como afirmam os autores, a combinação entre autonomia constitutiva e adaptatividade é condição necessária para o surgimento da produção de sentido. Nessa perspectiva, o significado não emerge apenas da distinção entre o que preserva ou destrói o sistema, mas da forma como diferentes perturbações adquirem valores distintos em relação à sua viabilidade.

Essa ideia revela um aspecto fundamental frequentemente negligenciado nas abordagens tradicionais da inteligência: o papel constitutivo da precariedade. Sistemas vivos não são entidades estáveis em equilíbrio permanente, mas processos dinâmicos continuamente expostos ao risco de desintegração. A possibilidade de falha, em última instância, a possibilidade de morte, não é um acidente, mas uma condição essencial para o surgimento da cognição.

Sob essa ótica, a inteligência pode ser reinterpretada como a capacidade de um sistema de lidar com sua própria precariedade. Um organismo inteligente não é aquele que resolve problemas previamente definidos, mas aquele que consegue manter-se viável em um mundo incerto, atribuindo relevância às interações que afetam sua continuidade. Assim, a cognição emerge como uma atividade normativa, orientada pela necessidade constante de evitar a perda da própria identidade.

Essa concepção é aprofundada por autores como Barandiaran *et al.* (2009), que enfatizam que a agência requer não apenas autonomia, mas também a capacidade de modular ativamente a relação com o ambiente em função de condições internas. Como mostrado na Figura 1, essa modulação não é externa ao sistema, mas emerge de sua própria dinâmica interna, orientando suas interações de acordo com sua viabilidade. Nesse sentido, a inteligência não está

localizada em um mecanismo específico, mas na dinâmica global do sistema enquanto ele regula sua existência.



Figura 1 – Ilustração esquemática da agência: o sistema é formado por uma rede de processos autossustentados (círculo à esquerda) em interação com o ambiente, na qual mecanismos internos de regulação modulam esse acoplamento, configurando o comportamento do agente para manter a sua identidade.

Fonte: Adaptado de Barandiaran *et al.* (2009).

A IA Enativa, portanto, propõe uma mudança paradigmática na forma de conceber sistemas inteligentes. Em vez de projetar máquinas capazes de resolver problemas em domínios previamente especificados, o objetivo passa a ser a construção de sistemas capazes de constituir seus próprios domínios de relevância a partir de sua interação com o ambiente.

Dessa forma, um sistema artificial que incorpore simultaneamente autonomia constitutiva e adaptatividade representaria um avanço significativo em direção a modelos mais fiéis da cognição natural. Tal sistema não apenas processaria informações, mas produziria sentido, não apenas executaria tarefas, mas sustentaria sua própria existência diante das constantes ameaças impostas pelo mundo.

Em última instância, a IA Enativa sugere que a inteligência não pode ser dissociada da vida. Ser inteligente é, fundamentalmente, estar engajado em um processo contínuo de negociação com a possibilidade de deixar de existir.

2.2 Fundamentação Computacional

2.2.1 Aprendizado por Reforço

O Aprendizado por Reforço (AR) é um paradigma de aprendizado de máquina no qual um agente interage continuamente com um ambiente, tomando ações e recebendo, como consequência, sinais de feedback na forma de recompensas e novos estados. Essa interação ocorre de maneira sequencial: a cada instante, o agente observa o estado atual do ambiente,

escolhe uma ação e, como resultado, o ambiente evolui para um novo estado e fornece uma recompensa associada à ação executada, conforme ilustrado na Figura 2.




Figura 2 – Diagrama do ciclo de interação no aprendizado por reforço. O agente observa o estado do ambiente, seleciona uma ação com base em sua política e a executa no ambiente. Como consequência, o ambiente transita para um novo estado e fornece ao agente um sinal numérico de recompensa. Esse ciclo de percepção–ação–*feedback* se repete continuamente, permitindo que o agente ajuste seu comportamento ao longo do tempo de forma a maximizar a recompensa acumulada.

Fonte: Adaptado de Sutton e Barto (2018).

O objetivo central dos algoritmos de aprendizado por reforço é aprender uma estratégia de decisão que maximize uma medida acumulada de recompensa ao longo do tempo. Diferentemente do aprendizado supervisionado, no qual pares entrada-saída são explicitamente fornecidos, no AR o agente não recebe instruções diretas sobre qual ação tomar. Em vez disso, ele deve inferir, a partir do sinal de recompensa, tentativa e erro, quais comportamentos são mais adequados, explorando o ambiente e ajustando suas decisões com base nas consequências observadas. Nos casos mais interessantes e desafiadores, as ações podem afetar não apenas a recompensa imediata, mas também a próxima situação e, por consequência, todas as recompensas subsequentes. Essas duas características, busca por tentativa e erro e recompensa atrasada, são os dois aspectos mais importantes que distinguem o aprendizado por reforço (SUTTON; BARTO, 2018).

2.2.1.1 Definição Matemática

Formalmente, o problema de aprendizado por reforço é frequentemente modelado como um *Processo de Decisão de Markov* (PDM), definido pela tupla:

$$\mathcal{M} = (S, A, P, R, \gamma)$$

em que:

- S é o conjunto de estados possíveis do ambiente.

- A é o conjunto de ações disponíveis ao agente.
- $P(s' | s, a)$ é a função de transição de estados, que define a probabilidade de transitar para o estado s' ao executar a ação a no estado s . Esta função satisfaz a *Propriedade de Markov*, onde a probabilidade de ir para o próximo estado depende apenas do estado atual, sendo independente da trajetória passada. Matematicamente, isso significa que:

$$P(s_{t+1} | s_t, a_t, s_{t-1}, \dots, s_0) = P(s_{t+1} | s_t, a_t);$$

- $R(s, a)$ é a função de recompensa, que associa um valor escalar ao par estado-ação;
- $\gamma \in [0, 1)$ é o fator de desconto, responsável por controlar a importância relativa das recompensas futuras no cálculo do retorno acumulado. Na equação do retorno, o termo γ^k decai exponencialmente à medida que k aumenta, fazendo com que recompensas mais distantes no tempo contribuam menos para o valor total. Dessa forma, o fator de desconto estabelece um equilíbrio entre recompensas imediatas e ganhos de longo prazo.

A dinâmica do AR ocorre em etapas discretas de tempo. Em cada instante t , o agente observa um estado $s_t \in S$, seleciona uma ação $a_t \in A$ de acordo com uma política π , recebe uma recompensa r_t e transita para um novo estado s_{t+1} , como ilustrado na Figura 2.

A política $\pi(a | s)$ define o comportamento do agente, isto é, a probabilidade de escolher a ação a no estado s . O objetivo do agente é encontrar uma política ótima π^* que maximize o retorno esperado, sendo este, o grande desafio dos algoritmos de aprendizagem por reforço. O retorno, por sua vez, pode ser definido em função da recompensa e do fator de desconto de recompensas futuras. Assim, o retorno a partir do tempo t é definido como:

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$$

2.2.1.2 Função Valor de Estado

Embora o objetivo do agente seja maximizar o retorno acumulado ao longo do tempo, essa quantidade, por si só, não é diretamente utilizável para a tomada de decisão em cada instante, uma vez que depende de recompensas futuras ainda desconhecidas. Dessa forma, torna-se necessário introduzir mecanismos que permitam avaliar, de maneira antecipada, a qualidade das situações nas quais o agente pode se encontrar. Nesse contexto, define-se a função valor de estado, que fornece uma medida da qualidade de um estado ao quantificar o retorno esperado a partir dele, assumindo que o agente seguirá uma determinada política π . Intuitivamente, o valor

de um estado reflete o quão promissor ele é em termos de recompensas futuras, ou seja, estados com valores mais elevados indicam maior potencial de retorno, enquanto estados com valores mais baixos sugerem situações menos favoráveis. Permitindo, assim, comparar estados e orientar o agente na escolha de ações que o conduzam, de forma consistente, a regiões mais vantajosas do espaço de estados. Formalmente, a função valor de estado é definida como:

$$V_{\pi}(s) = \mathbb{E}_{\pi}[G_t \mid s_t = s]$$

2.2.2 *Aprendizado por Reforço Profundo*

Embora a fundamentação matemática do Aprendizado por Reforço forneça a base para a tomada de decisão sequencial, a aplicação desses conceitos em ambientes complexos e de alta dimensionalidade enfrenta o desafio da chamada *maldição da dimensionalidade*. Esse termo refere-se ao crescimento exponencial da quantidade de estados possíveis à medida que aumenta a dimensionalidade do espaço de estados. Em problemas reais, pequenas variações contínuas nas observações do ambiente podem gerar um número extremamente elevado de configurações distintas, tornando inviável armazenar explicitamente informações para cada estado possível.

Essa limitação torna-se particularmente evidente em métodos tabulares, nos quais funções de políticas são representadas por tabelas contendo estimativas associadas a cada estado. Em problemas nos quais o espaço de estados S é contínuo ou composto por entradas sensoriais brutas, como pixels de imagens, o número de combinações possíveis cresce rapidamente, tornando impraticável tanto o armazenamento quanto o aprendizado eficiente dessas representações.

O Aprendizado por Reforço Profundo (ARP) (Mnih *et al.*, 2013) resolve essa limitação ao integrar os princípios do AR com o poder de representação das Redes Neurais Profundas. Nesse paradigma, as redes neurais atuam como aproximadores de funções universais, sendo capazes de aprender representações compactas e generalizáveis a partir de dados complexos.

A principal mudança introduzida pelo ARP é a parametrização dos componentes do agente. A política π , que antes era uma distribuição de probabilidade definida em uma tabela, passa a ser representada por uma rede neural com um conjunto de parâmetros θ , denotada como $\pi_{\theta}(a \mid s)$. O objetivo do aprendizado, portanto, desloca-se para a busca dos parâmetros θ que maximizam o retorno esperado. A figura 3 mostra o desenho esquemático de um algoritmo de ARP.

Entretanto, para que a rede neural consiga representar adequadamente a política do




Figura 3 – Esquema de Aprendizado por Reforço Profundo. Uma Rede Neural Profunda aprende a política π que o agente utiliza para executar uma ação no ambiente. Uma recompensa e a informação sobre o novo estado do sistema são devolvidas ao agente, que aprimora e aprende sua política de acordo.

Fonte: Adaptado de Pozza *et al.* (2022).

agente, é necessário um mecanismo capaz de ajustar seus parâmetros internos com base nas experiências adquiridas durante a interação com o ambiente. Em redes neurais profundas, esse aprendizado ocorre por meio de um processo de otimização iterativa, no qual os parâmetros θ são atualizados de forma a minimizar uma função de perda que mede o erro entre as previsões da rede e os valores desejados.

De maneira geral, uma rede neural pode ser entendida como uma função parametrizada $f_{\theta}(x)$, na qual x representa a entrada da rede e θ o conjunto de pesos e vieses que determinam seu comportamento. Durante o treinamento, o objetivo consiste em encontrar os valores de θ que minimizam uma função objetivo $\mathcal{L}(\theta)$, frequentemente definida em termos do erro de predição da rede.

A atualização dos parâmetros é realizada por métodos de otimização baseados em gradiente, sendo o Gradiente Descendente uma das abordagens mais utilizadas. Nesse método, calcula-se o gradiente da função de perda em relação aos parâmetros da rede,

$$\nabla_{\theta} \mathcal{L}(\theta),$$

o qual indica a direção de maior crescimento da função objetivo. Assim, para minimizar a perda, os parâmetros são atualizados iterativamente na direção oposta ao gradiente:

$$\theta \leftarrow \theta - \alpha \nabla_{\theta} \mathcal{L}(\theta),$$

em que α representa a taxa de aprendizado, responsável por controlar o tamanho das atualizações realizadas a cada etapa de treinamento.

O cálculo eficiente desses gradientes é realizado por meio do algoritmo de retro-propagação do erro, que aplica a regra da cadeia para propagar o erro da saída da rede em direção às camadas internas, permitindo determinar a contribuição de cada parâmetro para o erro total. Dessa forma, a rede neural ajusta progressivamente suas representações internas, tornando-se capaz de aproximar funções altamente não lineares e extrair padrões relevantes dos dados observados.

No contexto do Aprendizado por Reforço Profundo, esse mecanismo de otimização é utilizado para ajustar os parâmetros da política $\pi_\theta(a | s)$ ou das funções de valor aproximadas pela rede neural. Assim, a experiência adquirida pelo agente durante sua interação com o ambiente é convertida em sinais de treinamento que orientam a atualização dos parâmetros θ , permitindo que o comportamento do agente evolua progressivamente em direção a políticas mais eficientes.

2.2.2.1 Redes Neurais Convolucionais

Em muitos problemas de Aprendizado por Reforço Profundo, o agente não recebe como entrada estados simbólicos ou vetores de baixa dimensionalidade, mas sim dados perceptuais complexos, como imagens provenientes de câmeras ou quadros de jogos digitais. Nesses casos, torna-se necessário um mecanismo capaz de extrair automaticamente representações relevantes a partir dos dados brutos de entrada. As Redes Neurais Convolucionais (LECUN *et al.*, 1989), do inglês, CNNs, desempenham papel fundamental nesse contexto, sendo amplamente utilizadas em tarefas de visão computacional devido à sua capacidade de aprender características espaciais diretamente de imagens.

Diferentemente de redes totalmente conectadas, nas quais cada neurônio está ligado a todos os elementos da entrada, as CNNs exploram a estrutura espacial dos dados por meio da operação de convolução. Nessa operação, pequenos filtros percorrem a imagem realizando produtos internos locais, produzindo mapas de ativação que destacam padrões específicos presentes na entrada. Formalmente, a convolução discreta bidimensional entre uma entrada I e um filtro K pode ser expressa como:

$$S(i, j) = (I \otimes K)(i, j) = \sum_m \sum_n I(i - m, j - n) K(m, n),$$




Figura 4 – Representação esquemática de uma arquitetura CNN, destacando os blocos de extração de características (convolução e pooling) e os blocos de classificação final (camadas densas e softmax).

Fonte: Adaptado de MathWorks (2026).

em que $S(i, j)$ representa o valor produzido na posição (i, j) do mapa de características resultante.

Durante o treinamento, os valores dos filtros convolucionais são aprendidos automaticamente pela rede neural por meio da retropropagação do erro. Dessa forma, diferentes filtros passam a responder a diferentes padrões visuais presentes na imagem. Nas primeiras camadas da rede, os filtros tendem a detectar características simples, como bordas, texturas e contrastes. À medida que a informação se propaga para camadas mais profundas, a rede combina essas características elementares para representar estruturas progressivamente mais complexas, como formas, objetos ou regiões semanticamente relevantes.

Outra propriedade importante das CNNs é o compartilhamento de parâmetros. Como o mesmo filtro é aplicado em diferentes regiões da imagem, o número de parâmetros necessários torna-se significativamente menor em comparação com redes totalmente conectadas. Além de reduzir o custo computacional, essa característica permite que a rede desenvolva invariância translacional parcial, isto é, a capacidade de reconhecer padrões independentemente de sua posição exata na imagem.

Frequentemente, as camadas convolucionais são combinadas com operações de subamostragem (*pooling*), responsáveis por reduzir a dimensionalidade espacial dos mapas de ativação e aumentar a robustez das representações aprendidas. Em particular, operações como *max-pooling* preservam apenas as ativações mais relevantes de uma região local, contribuindo para a redução de ruído e para a generalização do modelo. A arquitetura geral de uma CNN pode ser visto na figura 4.

No caso do ARP, a CNN atua como um mecanismo de percepção capaz de transformar imagens de alta dimensionalidade em representações compactas e semanticamente relevantes, que posteriormente são utilizadas pela política do agente para a tomada de decisão.

2.2.3 *Aprendizado Contínuo*

Dentro dos algoritmos de Aprendizado por Reforço, é possível distinguir dois tipos principais: métodos *on-policy* e *off-policy*. Segundo Sutton e Barto (2018), a principal diferença entre essas abordagens está na relação entre a política utilizada para gerar experiências no ambiente e a política efetivamente atualizada durante o aprendizado. Métodos *on-policy* avaliam ou aprimoram a mesma política responsável pela interação atual do agente com o ambiente. Já métodos *off-policy* permitem aprender uma política-alvo distinta daquela utilizada para coletar experiências, desacoplando a política de comportamento da política que está sendo otimizada.

Em algoritmos *on-policy*, a política utilizada para agir no ambiente é exatamente a mesma política que está sendo aprendida. Isso significa que o agente adapta seu comportamento diretamente a partir das experiências produzidas por sua política atual. O processo de aprendizado permanece continuamente alinhado ao modo como o agente percebe, age e interage no ambiente naquele momento específico.

Por outro lado, métodos *off-policy* permitem que o aprendizado utilize experiências geradas por políticas diferentes da política atual do agente. Assim, a política-alvo pode continuar sendo otimizada utilizando dados coletados anteriormente, experiências produzidas sob estratégias mais exploratórias ou até trajetórias geradas por outros agentes. Dessa forma, o aprendizado deixa de depender exclusivamente da política atualmente em execução.

Essa distinção possui implicações importantes quando analisada sob a perspectiva da IA Enativa. Em abordagens *on-policy*, o aprendizado ocorre de forma fortemente acoplada à política atualmente incorporada pelo agente durante sua interação com o ambiente. A política utilizada para perceber, agir e explorar o mundo é a mesma política continuamente transformada pela experiência vivida. Assim, cognição e adaptação emergem conjuntamente da dinâmica de interação situada entre agente e ambiente.

Sob a ótica da IA Enativa, esse acoplamento reforça a ideia de que o conhecimento não é simplesmente armazenado ou processado de maneira abstrata, mas construído continuamente a partir da própria atividade do agente no mundo. O agente age sobre o ambiente, sofre diretamente as consequências de suas ações e modifica seu comportamento com base nos efeitos produzidos por essa interação contínua. Dessa forma, o aprendizado não aparece como um processo separado da ação, mas como parte integrante do ciclo contínuo de percepção, ação e adaptação, no qual a própria experiência vivida transforma continuamente a política utilizada pelo agente.

Em contraste, métodos *off-policy* introduzem uma separação parcial entre a política responsável pela experiência atual e a política efetivamente aprendida. Embora isso aumente significativamente a eficiência amostral e permita maior reutilização de experiências, o processo de adaptação torna-se menos diretamente dependente da interação presente do agente com o ambiente. Sob a perspectiva enativa, isso reduz parcialmente o vínculo imediato entre cognição e ação situada, aproximando o aprendizado de um processo mais mediado pela reutilização e processamento de experiências previamente coletadas.

2.2.3.1 Métodos de Gradiente de Política

No âmbito dos métodos *on-policy*, uma das primeiras abordagens consolidadas são os métodos de gradiente de política (*Policy Gradient Methods*) (SUTTON *et al.*, 1999). Diferentemente de métodos baseados em função valor, nos quais o agente aprende indiretamente uma política a partir da estimativa de valores de estados ou ações, os métodos de gradiente de política buscam otimizar diretamente a própria política do agente.

Nessa abordagem, a política é parametrizada por um conjunto de parâmetros θ , geralmente representados pelos pesos de uma rede neural, sendo denotada por $\pi_\theta(a|s)$. Essa política define uma distribuição de probabilidade sobre as ações possíveis em cada estado do ambiente. O objetivo do aprendizado consiste em encontrar os parâmetros θ que maximizem o retorno esperado obtido pelo agente ao interagir com o ambiente. Formalmente, deseja-se maximizar:

$$J(\pi_\theta) = \mathbb{E}_{\tau \sim \pi_\theta} [R(\tau)],$$

em que τ representa uma trajetória gerada pela interação entre agente e ambiente. Uma trajetória corresponde à sequência de estados, ações e recompensas observadas durante um episódio de interação, podendo ser representada por:

$$\tau = (s_0, a_0, r_1, s_1, a_1, r_2, \dots, s_T).$$

O termo $R(\tau)$ representa o retorno acumulado ao longo dessa trajetória. Assim, o objetivo do agente é ajustar sua política de modo que trajetórias com maiores retornos tornem-se mais prováveis.

Para isso, os métodos de gradiente de política utilizam o gradiente da função objetivo em relação aos parâmetros da política:

$$\nabla_{\theta} J(\pi_{\theta}).$$

A ideia central consiste em aumentar a probabilidade de ações que levaram a retornos elevados e reduzir a probabilidade de ações associadas a retornos menores. Intuitivamente, se determinadas escolhas resultaram em consequências favoráveis ao agente, a política deve ser atualizada para tornar tais ações mais prováveis em situações semelhantes futuras.

A partir do chamado Teorema do Gradiente da Política, é possível escrever o gradiente da política na forma:

$$\nabla_{\theta} J(\pi_{\theta}) = \mathbb{E}_{\tau \sim \pi_{\theta}} \left[\sum_{t=0}^T \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) R(\tau) \right].$$

Apesar de estabelecerem uma formulação teórica geral para otimização direta de políticas parametrizadas, métodos de gradiente de política apresentam limitações importantes na prática. Pequenas alterações nos parâmetros podem gerar mudanças significativas no comportamento da política, tornando o treinamento instável. De forma análoga, um pequeno ajuste na direção de um veículo em alta velocidade pode alterar drasticamente sua trajetória. Em políticas parametrizadas por redes neurais, pequenas atualizações nos parâmetros podem modificar significativamente as probabilidades das ações executadas, fazendo com que o comportamento do agente varie abruptamente entre diferentes etapas do treinamento. Além disso, as estimativas do gradiente frequentemente apresentam alta variância, exigindo grande quantidade de interações com o ambiente para obtenção de aprendizado estável e eficiente.

2.2.3.2 *Trust Region Policy Optimization*

As limitações observadas nos métodos clássicos de gradiente de política motivaram o desenvolvimento de abordagens mais estáveis para atualização da política. Embora esses métodos permitam otimizar diretamente o comportamento do agente, pequenas atualizações nos parâmetros podem provocar mudanças abruptas na distribuição de ações da política, comprometendo o desempenho aprendido anteriormente. Em muitos casos, uma única atualização inadequada é suficiente para fazer o agente perder comportamentos que já haviam sido aprendidos.

Diante desse problema, o *Trust Region Policy Optimization* (TRPO) (SCHULMAN *et al.*, 2015) introduz a ideia de limitar explicitamente o quanto a política pode mudar a cada

etapa de treinamento. Em vez de apenas seguir a direção do gradiente de maior recompensa esperada, o TRPO busca garantir que a nova política permaneça suficientemente próxima da política anterior. Assim, o agente continua aprendendo, mas de maneira mais controlada e estável.

Formalmente, o TRPO procura maximizar uma função objetivo associada à vantagem esperada da nova política em relação à política antiga, ao mesmo tempo em que impõe uma restrição sobre a divergência entre ambas:

$$\theta_{k+1} = \arg \max_{\theta} \mathcal{L}(\theta_k, \theta) \quad \text{sujeito a} \quad \bar{D}_{KL}(\theta \parallel \theta_k) \leq \delta.$$

Nesse contexto, $\mathcal{L}(\theta_k, \theta)$ representa uma aproximação do ganho esperado ao atualizar a política, enquanto $\bar{D}_{KL}$ corresponde à divergência de Kullback-Leibler média entre a política antiga e a nova política. Essa divergência atua como uma medida de diferença entre distribuições de probabilidade, permitindo controlar o quanto o comportamento do agente pode variar entre duas atualizações consecutivas.

Intuitivamente, o TRPO impede que o agente “mude de ideia” de maneira excessivamente brusca. Mesmo que o gradiente indique uma direção potencialmente vantajosa, o algoritmo restringe o tamanho do passo de atualização, garantindo que a política evolua gradualmente. Isso reduz colapsos repentinos de desempenho e produz um processo de aprendizado mais estável.

Apesar de suas vantagens, o TRPO apresenta elevada complexidade computacional. O método exige resolver um problema de otimização restrita relativamente sofisticado, envolvendo aproximações de segunda ordem e cálculos relacionados à matriz Hessiana da divergência KL. Na prática, isso torna sua implementação mais difícil e computacionalmente mais custosa quando comparada a métodos mais simples de gradiente de política.

Ainda assim, o TRPO representou um avanço importante na evolução dos métodos *on-policy*, ao introduzir mecanismos explícitos de estabilidade no processo de atualização da política. Suas ideias serviram posteriormente de base para algoritmos mais simples e eficientes, como o *Proximal Policy Optimization* (PPO), que preserva a intuição central do TRPO, mas reduz significativamente sua complexidade computacional.

2.2.3.3 Proximal Policy Optimization

O *Proximal Policy Optimization* (PPO) (SCHULMAN *et al.*, 2017) surge como uma evolução natural das ideias introduzidas pelo TRPO. Assim como seu predecessor, o PPO busca evitar que atualizações excessivamente grandes da política provoquem degradações abruptas de desempenho. Entretanto, em vez de resolver um problema de otimização restrita complexo, o PPO adota uma estratégia significativamente mais simples e eficiente, baseada em um mecanismo denominado *clipping*.

A motivação central permanece a mesma: permitir que o agente aprenda continuamente sem alterar drasticamente seu comportamento entre duas atualizações consecutivas. Em métodos clássicos de gradiente de política, uma atualização muito intensa pode fazer com que a política passe a escolher ações completamente diferentes das anteriores, destruindo comportamentos úteis já aprendidos. O PPO procura limitar esse problema de forma prática e computacionalmente eficiente.

Formalmente, o algoritmo compara a nova política π_θ com a política anterior $\pi_{\theta_{\text{old}}}$ por meio da razão:

$$r_t(\theta) = \frac{\pi_\theta(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)}.$$

Essa razão mede o quanto a nova política aumentou ou reduziu a probabilidade de executar a ação a_t no estado s_t . Valores próximos de 1 indicam poucas mudanças entre as políticas, enquanto valores muito maiores ou menores indicam alterações mais agressivas no comportamento do agente.

A função objetivo do PPO incorpora então um mecanismo de *clipping*, definido por:

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t [\min(r_t(\theta)\hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon)\hat{A}_t)],$$

em que $\hat{A}_t$ representa a vantagem estimada da ação executada. Intuitivamente, essa vantagem mede o quanto uma ação produziu resultados melhores ou piores do que o esperado pela política atual. Em geral, a vantagem é estimada pela diferença entre o retorno efetivamente obtido após executar a ação e o valor esperado para o estado correspondente, podendo ser expressa por:

$$\hat{A}_t \approx \hat{R}_t - V(s_t),$$

onde $\hat{R}_t$ representa o retorno acumulado observado a partir do instante t , enquanto $V(s_t)$ corresponde à estimativa de valor do estado s_t , isto é, a recompensa esperada ao seguir a política atual a partir desse estado. Dessa forma, vantagens positivas indicam ações que produziram resultados melhores do que o esperado, enquanto vantagens negativas indicam ações menos vantajosas. Já o parâmetro ϵ define o limite permitido para a variação da política entre atualizações consecutivas.

Embora essa expressão matemática pareça complexa, sua ideia intuitiva é relativamente simples. O PPO recompensa mudanças que melhoram o desempenho da política, mas impede que essas mudanças se tornem excessivamente grandes. O mecanismo de *clipping* funciona como um limitador de segurança: quando a nova política tenta alterar demais a probabilidade de determinadas ações, o algoritmo interrompe o benefício adicional dessa mudança.

Por combinar simplicidade computacional, estabilidade de treinamento e boa eficiência empírica, o PPO tornou-se um dos algoritmos *on-policy* mais utilizados em Aprendizado por Reforço Profundo. Sua capacidade de manter um equilíbrio entre exploração, aprendizado contínuo e estabilidade fez com que ele fosse amplamente adotado em aplicações envolvendo ambientes complexos e de alta dimensionalidade.

2.2.4 Exploração, Motivação Intrínseca e Curiosidade

Um dos principais desafios no Aprendizado por Reforço é o chamado dilema de exploração versus exploração. Esse dilema consiste em decidir entre duas estratégias conflitantes: *explorar*, isto é, aproveitar o conhecimento atual para maximizar recompensas imediatas ou *explorar* o ambiente em busca de novas informações que possam levar a recompensas maiores no futuro. Enquanto a exploração tende a ser segura e eficiente no curto prazo, a exploração é essencial para evitar soluções sub-ótimas e descobrir estados potencialmente mais vantajosos.

Esse problema se torna particularmente crítico em ambientes com recompensas esparsas, onde sinais de recompensa são raros e difíceis de encontrar. Nessas condições, agentes puramente orientados à exploração frequentemente falham, pois não conseguem coletar informação suficiente para aprender políticas eficazes. Assim, mecanismos que incentivem a exploração tornam-se fundamentais.

2.2.4.1 Recompensa Intrínseca

Uma forma de compreender esse desafio é por meio da distinção entre *motivação intrínseca* e *motivação extrínseca*, amplamente estudada na literatura psicológica (RYAN; DECI,

2000). Motivação intrínseca refere-se à realização de uma atividade por seu valor inerente, isto é, pelo interesse, curiosidade ou satisfação associada à própria execução da tarefa. Em contraste, a motivação extrínseca está associada à realização de uma atividade como meio para atingir um objetivo externo, como recompensas, reconhecimento ou evitar punições.

Essa distinção é particularmente relevante porque, embora ambas as formas de motivação possam levar à execução de uma mesma ação, elas diferem fundamentalmente em sua origem e nos comportamentos que incentivam. Enquanto a motivação extrínseca é guiada por consequências externas ao agente, a motivação intrínseca está relacionada a uma propensão natural à exploração, aprendizado e assimilação de novas informações. Em humanos, por exemplo, comportamentos exploratórios frequentemente emergem mesmo na ausência de recompensas explícitas, sendo impulsionados por curiosidade e interesse.

No contexto do Aprendizado por Reforço, essa distinção pode ser reinterpretada de forma análoga: recompensas extrínsecas correspondem aos sinais fornecidos diretamente pelo ambiente, enquanto recompensas intrínsecas são introduzidas artificialmente no agente como forma de incentivar comportamentos desejáveis, como a exploração de estados desconhecidos. Essa perspectiva tem motivado o desenvolvimento de diversas técnicas que aumentam a função de recompensa com sinais internos ao agente, visando superar limitações impostas por recompensas esparsas ou pouco informativas. Com isso, a recompensa total pode ser definida como:

$$r_t = r_t^{\text{ext}} + r_t^{\text{int}},$$

onde r_t^{ext} é a recompensa extrínseca e r_t^{int} representa a recompensa intrínseca.

Na prática, a recompensa intrínseca pode ser implementada de diferentes maneiras, a depender de quais aspectos do processo de aprendizado se deseja enfatizar. Uma forma de implementar esse tipo de sinal é por meio da noção de *curiosidade* (PATHAK *et al.*, 2017). Nesse contexto, a curiosidade pode ser entendida como a tendência do agente em buscar experiências que revelem limitações em seu conhecimento atual, isto é, situações nas quais sua capacidade de previsão ou compreensão ainda é insuficiente. Dessa forma, estados que são difíceis de prever ou que diferem significativamente da experiência prévia do agente tornam-se mais atrativos.

A partir dessa perspectiva, a curiosidade pode ser formalizada como um tipo de recompensa intrínseca, na qual o agente recebe um bônus adicional ao interagir com estados considerados novos ou informativos. Esse tipo de formulação permite traduzir o comportamento exploratório em um sinal quantitativo, que pode ser incorporado diretamente à função de recompensa.

2.2.4.2 *Random Network Distillation*

Dentro desse contexto, destaca-se o método de *Random Network Distillation* (RND) (BURDA *et al.*, 2018b), proposto como uma forma simples e eficiente de incentivar a exploração em ambientes de alta dimensionalidade. A ideia central do RND é utilizar o erro de predição como medida de novidade.

O método consiste em duas redes neurais: uma rede alvo fixa, inicializada aleatoriamente, e uma rede preditora treinável. Em geral, ambas possuem a mesma arquitetura, normalmente implementada por redes neurais convolucionais quando as observações do ambiente são imagens. Nesse caso, as camadas convolucionais são responsáveis por extrair características espaciais relevantes da entrada, enquanto camadas totalmente conectadas projetam essas características em um espaço latente de menor dimensionalidade.

A rede alvo possui parâmetros fixos, inicializados aleatoriamente no início do treinamento e mantidos inalterados ao longo de toda a execução do algoritmo. Dessa forma, ela define uma função determinística que mapeia observações do ambiente para representações vetoriais em um espaço de características. Já a rede preditora possui parâmetros treináveis e tem como objetivo aproximar a saída produzida pela rede alvo para uma determinada observação.

O treinamento da rede preditora é realizado por aprendizado supervisionado, utilizando como alvo a saída da rede fixa. Assim, a cada nova observação s_t , a rede preditora ajusta seus parâmetros por meio de descida do gradiente, minimizando o erro quadrático médio (*Mean Squared Error* – MSE) entre sua saída e a saída produzida pela rede alvo. Esse processo é ilustrado na Figura 5.

A intuição por trás dessa abordagem é que estados frequentemente visitados terão seus padrões bem aprendidos pela rede preditora, resultando em baixo erro de predição. Por outro lado, estados novos ou raros produzirão erros elevados, gerando um forte sinal de recompensa intrínseca que incentiva o agente a explorá-los.

Em síntese, a introdução de mecanismos de curiosidade e motivação intrínseca, como o RND, representa um avanço significativo na resolução do dilema exploração-exploração, permitindo que agentes aprendam de forma mais eficiente em ambientes desafiadores e pouco informativos.




Figura 5 – Arquitetura do método *Random Network Distillation* (RND). O erro quadrático médio (MSE) entre a saída da Rede Alvo fixa ($f(s_t)$) e a Rede Preditora treinável ($\hat{f}(s_t)$) é utilizado como sinal de curiosidade ou recompensa intrínseca.

2.2.5 Análise Visual da Política Aprendida

Embora mecanismos de motivação intrínseca, como o RND, promovam uma exploração mais eficiente do ambiente, eles também tornam o comportamento do agente mais difícil de interpretar. Isso ocorre porque a política aprendida passa a ser influenciada não apenas por recompensas extrínsecas explícitas, mas também por sinais internos de curiosidade, cuja dinâmica pode não ser imediatamente evidente. Nesse contexto, compreender por que o agente toma determinadas decisões torna-se um desafio fundamental.

Modelos baseados em redes neurais profundas, frequentemente utilizados para representar políticas em Aprendizado por Reforço, são conhecidos por seu alto poder de representação, mas também por sua baixa interpretabilidade. Esses modelos operam como verdadeiras “caixas pretas”, nas quais a relação entre entrada (estado) e saída (ação) não é facilmente compreendida. Assim, mesmo quando o agente apresenta um bom desempenho, torna-se difícil identificar quais aspectos do ambiente estão sendo considerados relevantes para a tomada de decisão.

Uma abordagem promissora para lidar com esse problema é o uso de técnicas de Inteligência Artificial Explicável (XAI), em particular métodos de visualização que permitem identificar regiões da entrada responsáveis por uma determinada decisão.

2.2.5.1 Gradient-weighted Class Activation Mapping

Uma das abordagens iniciais para promover interpretabilidade em redes convolucionais é o *Class Activation Mapping* (CAM) (ZHOU *et al.*, 2015), que permite identificar regiões da imagem relevantes para a predição de uma determinada classe. O CAM baseia-se na combinação linear dos mapas de ativação da última camada convolucional, ponderados pelos pesos associados à camada de classificação. Apesar de sua simplicidade e interpretabilidade direta, esse método apresenta limitações importantes, uma vez que requer modificações específicas na arquitetura da rede, como a substituição de camadas totalmente conectadas por operações de *global average pooling*. Essa restrição dificulta sua aplicação em modelos já treinados ou em arquiteturas mais complexas.

Com o objetivo de superar essas limitações, foi proposto o método *Gradient-weighted Class Activation Mapping* (Grad-CAM) (SELVARAJU *et al.*, 2016), que generaliza a ideia do CAM ao utilizar informações de gradiente para estimar a importância dos mapas de ativação, tornando possível sua aplicação em uma ampla variedade de arquiteturas sem a necessidade de alterações estruturais ou re-treinamento do modelo, a visão panorâmica do método pode ser vista na figura 6.




Figura 6 – Visão panorâmica do método Grad-CAM. A ilustração detalha o fluxo de processamento onde informações de gradiente são utilizadas para ponderar os mapas de características das camadas convolucionais, resultando na geração de um mapa de calor que destaca as regiões relevantes da imagem de entrada para a classificação final.

Fonte: Adaptado de Theocharis (2024).

O Grad-CAM baseia-se na análise dos gradientes do escore de saída de uma classe (ou, no contexto de Aprendizado por Reforço, de uma ação ou valor associado) em relação aos

mapas de ativação de uma camada convolucional. Especificamente, os gradientes são utilizados para estimar a importância de cada mapa de ativação na decisão final do modelo. Esses valores de importância são então utilizados para ponderar linearmente os mapas de ativação, gerando um mapa de calor que indica as regiões da entrada mais relevantes para a decisão considerada.

Formalmente, seja y^c o escore associado a uma saída de interesse c , e A^k o k -ésimo mapa de ativação de uma camada convolucional. A importância de cada mapa é dada por:

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k},$$

onde Z representa o número total de elementos no mapa. Em outras palavras, investiga-se como pequenas variações nessas representações internas impactam o valor associado à classe considerada. Regiões cuja variação provoca maior alteração no escore são interpretadas como mais relevantes para a decisão do modelo e são destacadas com maior intensidade, enquanto regiões com pouca ou nenhuma influência apresentam menor intensidade. O mapa de ativação final é então obtido pela combinação linear dos scores com os mapas de ativação:

$$L_{\text{Grad-CAM}}^c = \text{ReLU} \left(\sum_k \alpha_k^c A^k \right).$$

A aplicação da função ReLU garante que apenas as contribuições positivas, isto é, aquelas que aumentam o escore da saída de interesse, sejam consideradas, resultando em um mapa de calor que destaca evidências favoráveis à decisão do modelo.

No contexto de aprendizagem por reforço, o Grad-CAM pode ser utilizado para analisar visualmente a política aprendida pelo agente. Ao destacar quais regiões do estado observado influenciam determinadas ações, torna-se possível investigar como o agente está utilizando as informações do ambiente, bem como avaliar o impacto de mecanismos de exploração, como o RND, no processo de tomada de decisão. Dessa forma, a combinação entre motivação intrínseca e interpretabilidade contribui não apenas para o desempenho do agente, mas também para uma compreensão mais profunda de seu comportamento.

3 TRABALHOS RELACIONADOS

Este capítulo apresenta os trabalhos que fundamentam e delimitam a contribuição desta pesquisa. A discussão está organizada em quatro eixos: os avanços do Aprendizado por Reforço Profundo, as implicações da definição de funções de recompensa, as abordagens de aprendizado inspiradas pela perspectiva enativa e os métodos de exploração orientados por curiosidade. Essa organização permite identificar aproximações e lacunas em relação à articulação entre percepção, precariedade, motivação intrínseca e autonomia artificial.

3.1 Aprendizado por Reforço Profundo

Mnih *et al.* (2013) apresentam um dos primeiros marcos do Aprendizado por Reforço Profundo ao demonstrar que uma rede neural convolucional poderia aprender políticas de controle diretamente a partir de entradas visuais de alta dimensionalidade. Os autores propõem uma arquitetura baseada em *Deep Q-Network* (DQN), na qual quadros brutos de jogos Atari 2600 são utilizados como entrada e a rede estima valores de ação esperados. A abordagem representou uma ruptura em relação a métodos anteriores de Aprendizado por Reforço, pois reduziu a dependência de atributos definidos manualmente e mostrou que uma única arquitetura poderia aprender diferentes tarefas a partir de pixels.

Apesar de sua relevância, o trabalho de Mnih *et al.* (2013) ainda apresenta algumas limitações. A avaliação foi realizada em um conjunto reduzido de jogos, o que limita a generalização dos resultados. Além disso, a aprendizagem do agente permanece fortemente dependente de recompensas extrínsecas definidas pelo ambiente, sem mecanismos internos mais elaborados de exploração ou curiosidade. Assim, o artigo estabelece a base técnica do Aprendizado por Reforço Profundo, mas ainda deixa em aberto questões relacionadas à autonomia e à adaptatividade do agente.

Mnih *et al.* (2015) expandem e consolidam os resultados iniciais do DQN ao avaliar o método em 49 jogos Atari 2600. Nesse trabalho, um único agente, recebendo apenas os pixels da tela e a pontuação do jogo, aprende políticas competitivas utilizando a mesma arquitetura, o mesmo algoritmo e os mesmos hiperparâmetros. O estudo reforça a importância da combinação entre redes neurais convolucionais, *experience replay* e uma rede alvo separada, tornando-se um marco por demonstrar desempenho comparável ao humano em um conjunto amplo de tarefas visuais e sequenciais.

Entretanto, embora Mnih *et al.* (2015) represente um avanço expressivo em desempenho e escala experimental, o método ainda depende de grandes quantidades de interação com o ambiente e apresenta dificuldades em jogos que exigem exploração de longo prazo ou estratégias mais abstratas. Além disso, a recompensa externa permanece como principal guia de aprendizagem. Assim, o trabalho consolida o Aprendizado por Reforço Profundo como uma abordagem poderosa para controle baseado em percepção, mas também evidencia limitações relacionadas à eficiência exploratória.

Como fechamento dessa linha histórica, Hessel *et al.* (2018) mostram como a revolução iniciada pelo DQN motivou uma série de aprimoramentos posteriores. O trabalho combina diferentes extensões do DQN, incluindo Double DQN, *Prioritized Experience Replay*, arquitetura *dueling*, aprendizado multi-etapas, aprendizado distribucional e camadas ruidosas para exploração. Essa combinação alcançou desempenho de estado da arte no benchmark Atari 2600, tanto em eficiência de dados quanto em desempenho final. Ainda assim, para os objetivos desta pesquisa, o Rainbow é tratado principalmente como evidência da relevância histórica do DQN: ele mostra a força dessa família de métodos, mas permanece dentro de uma abordagem centrada na maximização de recompensas externas e em melhorias algorítmicas do aprendizado por valor.

A evolução do Aprendizado por Reforço Profundo, entretanto, não ocorreu apenas pela melhoria de métodos baseados em valor, como o DQN e suas extensões. Paralelamente, outra linha de pesquisa passou a explorar métodos baseados diretamente na otimização da política do agente. Enquanto abordagens como DQN e Rainbow estimam valores de ação para selecionar comportamentos, métodos de gradiente de política buscam ajustar diretamente os parâmetros da política responsável pela escolha das ações. Essa diferença é importante porque permite lidar de forma mais natural com políticas estocásticas, espaços de ação contínuos e problemas nos quais a forma da política aprendida é central para o desempenho do agente.

Um passo intermediário importante nessa direção foi o desenvolvimento de métodos ator-crítico, que combinam a estimação de valor com a otimização direta da política. Em vez de depender apenas de uma função de valor para escolher a ação, esses métodos utilizam um componente ator, responsável pela política, e um componente crítico, responsável por avaliar as ações ou estados. Trabalhos como o A3C, proposto por Mnih *et al.* (2016), mostraram que essa combinação poderia ser escalada de forma eficiente por meio de agentes assíncronos interagindo em paralelo com diferentes cópias do ambiente.

Essa linha de pesquisa abriu espaço para métodos voltados à otimização estável de políticas. O TRPO, proposto por Schulman *et al.* (2015), buscou limitar grandes alterações na política entre atualizações sucessivas, reduzindo o risco de degradações abruptas de desempenho. Embora eficaz, o método possui maior complexidade de implementação. Nesse contexto, o PPO, proposto por Schulman *et al.* (2017), surge como uma alternativa mais simples e prática, preservando a ideia de atualizações controladas da política por meio de uma função objetivo com *clipping*. Assim, o PPO pode ser entendido como uma continuação da transição do Aprendizado por Reforço Profundo: dos métodos baseados em valor, historicamente importantes no Atari, para métodos on-policy baseados em política, mais flexíveis e amplamente utilizados em problemas modernos de controle.

Essa versatilidade pode ser observada em aplicações de grande escala posteriores ao artigo original. Em Berner *et al.* (2019), o PPO foi utilizado no treinamento do OpenAI Five, um sistema multiagente para o jogo Dota 2. Dota 2¹ é um jogo eletrônico competitivo do gênero *multiplayer online battle arena* (MOBA), no qual duas equipes controlam personagens com habilidades distintas e disputam objetivos estratégicos em um mapa compartilhado. Esse ambiente apresenta desafios como horizonte temporal longo, informação imperfeita, alta dimensionalidade e coordenação entre agentes. Por meio de treinamento distribuído em larga escala e autojogo, o sistema foi capaz de derrotar a equipe campeã mundial, evidenciando que métodos baseados em política podem ser escalados para tarefas complexas, dinâmicas e parcialmente observáveis.

Mais recentemente, o PPO também passou a ter papel importante fora do domínio clássico de jogos e controle. Em Ouyang *et al.* (2022), os autores utilizam Aprendizado por Reforço com Feedback Humano para ajustar modelos de linguagem a preferências humanas. Nesse processo, após uma etapa de ajuste supervisionado e treinamento de um modelo de recompensa, o PPO é empregado para otimizar a política do modelo de linguagem. Os resultados mostram que modelos menores ajustados com feedback humano podem ser preferidos a modelos maiores treinados apenas por predição de texto, indicando a relevância do PPO em problemas modernos de alinhamento e interação humano-máquina.

No campo da robótica, Yang *et al.* (2024) demonstram que o PPO continua sendo explorado em aplicações recentes e desafiadoras. O trabalho propõe o ClothPPO, uma estrutura para manipulação robótica de roupas em espaços de ação muito grandes e alinhados à observação visual. A abordagem combina pré-treinamento supervisionado com uma etapa posterior de

¹ Página oficial do jogo: <<https://www.dota2.com>>.

refinamento por PPO, permitindo melhorar a política em uma tarefa de manipulação de objetos deformáveis. Esse resultado reforça a atualidade do PPO como método flexível para otimizar políticas em domínios que envolvem percepção visual, ação contínua ou de alta dimensionalidade e adaptação a dinâmicas complexas.

Um trabalho relevante sobre agentes em tarefas de forrageamento é apresentado por Mesquita *et al.* (2020), no qual os autores propõem um agente autônomo em um ambiente com alimentos e venenos distribuídos. A tarefa é modelada como um problema de Aprendizado por Reforço Profundo, no qual imagens coloridas simulam a visão do agente e são processadas por uma rede neural convolucional. A partir dessas entradas visuais, um algoritmo baseado em SARSA aprende a selecionar ações que permitem ao agente buscar alimento e evitar venenos, demonstrando a viabilidade de combinar percepção visual e aprendizado por reforço em uma tarefa de forrageamento.

Embora o trabalho demonstre resultados importantes, algumas limitações podem ser observadas. A principal delas é o uso de uma recompensa extrínseca definida previamente, que já especifica quais interações devem ser valorizadas pelo agente, como buscar alimento e evitar veneno. Com isso, parte do comportamento desejado é introduzida diretamente pela função de recompensa, reduzindo a possibilidade de avaliar se o agente desenvolveria critérios próprios de relevância a partir da interação com o ambiente. Além disso, a avaliação concentra-se principalmente na curva de recompensa acumulada, o que dificulta uma análise mais detalhada dos comportamentos efetivamente aprendidos ao longo do treinamento. A interpretação da política aprendida também é limitada, pois não há uma investigação visual mais aprofundada sobre quais regiões ou elementos da observação influenciam as decisões do agente.

Também no contexto de forrageamento em ambientes virtuais, Filho *et al.* (2024) investigam agentes multissensoriais na tarefa *Health-Gathering* da plataforma VizDoom (WYD-MUCH *et al.*, 2018). O trabalho parte da observação de que grande parte dos agentes de Aprendizado por Reforço Profundo depende predominantemente de informação visual, embora organismos naturais utilizem múltiplas modalidades sensoriais para navegar e localizar recursos. Para isso, os autores propõem uma estratégia de treinamento baseada em currículo, na qual o agente é gradualmente levado a utilizar tanto visão quanto áudio como fontes de informação. Os resultados indicam que, sem esse currículo, agentes com visão e audição tendem a ignorar o áudio quando a informação visual é suficiente. Entretanto, quando treinados de forma gradual, tornam-se mais robustos em condições nas quais a visão é limitada ou indisponível.

Apesar desses resultados, algumas limitações podem ser observadas. A dependência de uma estratégia de currículo indica que a integração entre modalidades sensoriais não emerge de forma direta apenas pela disponibilidade dos canais de visão e áudio, exigindo uma organização cuidadosa do processo de treinamento. Além disso, a avaliação se concentra principalmente no desempenho final e na robustez diante da ausência de visão, deixando menos claro como o agente combina efetivamente as informações visuais e sonoras ao longo da tomada de decisão.

3.2 Função de Recompensa e Suas Implicações

A dependência de recompensas externas também levanta um problema central para o Aprendizado por Reforço Profundo: a engenharia de recompensa. Em princípio, a função de recompensa deveria expressar o comportamento desejado pelo projetista, na prática, porém, especificar essa função de forma completa é difícil, pois pequenas escolhas de modelagem podem levar o agente a otimizar atalhos indesejados. Esse problema é discutido por Amodei *et al.* (2016) como uma questão de especificação de objetivos: quando a recompensa observável não captura adequadamente a intenção humana, o agente pode maximizar o sinal recebido sem realizar o comportamento realmente esperado. A dificuldade, portanto, não está apenas em ajustar pesos ou penalidades, mas em transformar uma expectativa externa sobre o comportamento do agente em um critério fixo de valor.

Esse tipo de falha é frequentemente descrito como *reward hacking* ou *specification gaming*. Krakovna *et al.* (2020) definem esse fenômeno como um comportamento que satisfaz literalmente a especificação formal de um objetivo, mas sem alcançar o resultado realmente pretendido pelo projetista. O problema ocorre quando há uma diferença entre aquilo que se queria produzir no mundo e aquilo que foi efetivamente codificado como métrica, recompensa ou critério de avaliação. Nesses casos, o agente não precisa compreender a intenção humana por trás da tarefa, sendo assim, basta encontrar uma estratégia que maximize o sinal disponível.

Um exemplo apresentado por Krakovna *et al.* (2020) é a tarefa de empilhamento de blocos de Lego. O objetivo pretendido era fazer com que um bloco vermelho terminasse sobre um bloco azul. Entretanto, a recompensa foi definida com base na altura da face inferior do bloco vermelho quando ele não estivesse tocando o bloco azul. Em vez de realizar a manobra mais difícil de levantar o bloco vermelho e empilhá-lo corretamente, o agente simplesmente virou o bloco vermelho, elevando sua face inferior e obtendo recompensa sem cumprir o objetivo pretendido. A Figura 7 ilustra esse tipo de falha de especificação.




Figura 7 – Exemplo esquemático de *specification gaming* em uma tarefa de empilhamento de Lego. O agente satisfaz a métrica especificada, elevar a face inferior do bloco vermelho, sem realizar o objetivo pretendido de empilhar o bloco vermelho sobre o azul.

Fonte: Adaptado de Popov *et al.* (2017).

A importância desse exemplo está em mostrar que o comportamento do agente pode ser considerado bem-sucedido do ponto de vista do algoritmo, pois ele encontrou uma maneira eficiente de maximizar a recompensa especificada. No entanto, do ponto de vista do objetivo pretendido, o comportamento revela uma falha na formulação da tarefa. Assim, o problema não decorre necessariamente de uma deficiência do algoritmo de Aprendizado por Reforço, mas da distância entre a intenção do projetista e sua tradução em uma função objetivo. Como discutem Krakovna *et al.* (2020), a mesma capacidade de encontrar soluções inesperadas pode ser vista como sinal de criatividade algorítmica em benchmarks, mas torna-se problemática quando se espera que o agente realize uma intenção específica no mundo.

De modo semelhante, Lehman *et al.* (2020) mostram, a partir de relatos da computação evolucionária e vida artificial, que processos de otimização podem produzir soluções criativas, mas também surpreendentes e indesejadas, quando a medida de desempenho não corresponde ao objetivo pretendido. Esses resultados indicam que o problema não está apenas no algoritmo de aprendizagem, mas na própria tentativa de reduzir comportamentos complexos a

uma função objetivo externa e fixa. Quando a recompensa é usada para reforçar diretamente um comportamento específico, o agente tende a repetir a estratégia que satisfaz esse critério, mesmo que o contexto mude ou que existam alternativas mais adequadas. Nesse caso, a recompensa deixa de promover inteligência adaptativa e passa a cristalizar um padrão de ação previamente imaginado pelo projetista.

Para esta pesquisa, essa discussão é importante porque reforça a limitação de tratar a recompensa apenas como uma especificação explícita do projetista. Em tarefas de forrageamento, por exemplo, recompensas manuais podem induzir comportamentos úteis, como coletar alimento e evitar dano, mas ainda dependem de uma interpretação externa sobre o que deve ser relevante para o agente. Essa dependência é especialmente problemática quando o objetivo é produzir personagens autônomos e inteligentes, pois um agente desse tipo não deveria apenas executar uma rotina recompensada independentemente do que ocorre ao seu redor. Espera-se que ele reconheça mudanças na dinâmica do ambiente, reorganize sua ação e descubra modos de comportamento que talvez não tenham sido antecipados pela engenharia de recompensas. Assim, a recompensa não deveria funcionar como um mecanismo para forçar uma solução definida de antemão, possivelmente limitada ou subótima, mas como parte de uma estrutura que favoreça a busca por soluções.

A implicação mais profunda dessa crítica diz respeito à produção de sentido. Ao definir uma recompensa explícita, o projetista não apenas orienta o aprendizado do agente, mas também atribui previamente um significado às interações: sobreviver, alcançar um estado desejado, passar uma fase, coletar um recurso ou evitar uma ameaça. O problema é que essa atribuição parte da perspectiva de um observador externo, e não da perspectiva do próprio agente. Em termos próximos aos de Varela (1991), há uma diferença entre o ambiente observado e o mundo vivido pelo organismo: o ambiente corresponde ao domínio físico descrito externamente, enquanto o mundo corresponde ao domínio de interações significativas que emerge para o próprio sistema em sua atividade. Portanto, quando o significado da tarefa é totalmente dado pela recompensa, corre-se o risco de substituir o domínio de significância do agente por uma leitura externa do que deveria importar. A perspectiva enativa sugere justamente esse deslocamento: em vez de apenas projetar recompensas para impor um comportamento desejado, torna-se relevante investigar como sinais de valor podem emergir da relação entre o agente, suas estruturas internas, suas condições de viabilidade e seu acoplamento estrutural com o ambiente. Nesse sentido, apenas o próprio agente, por meio de sua dinâmica interna e de sua história de interação, poderia

constituir um domínio próprio de relevâncias, em vez de apenas receber de fora o significado de seus objetivos.

3.3 Aprendizado Enativo

Esta seção aproxima a discussão anterior sobre recompensas externas de uma perspectiva enativa para o aprendizado de agentes. Nos trabalhos revisados até aqui, o comportamento do agente é geralmente orientado por objetivos definidos previamente, principalmente por uma função de recompensa explícita. A abordagem enativa desloca esse foco: em vez de tratar percepção, ação e valor como componentes separados, ela enfatiza o acoplamento contínuo entre agente e ambiente, no qual o significado das interações emerge da própria história de atividade do agente. Assim, o interesse principal passa a ser compreender como um sistema pode construir regularidades sensório-motoras, reconhecer possibilidades de ação e organizar seu comportamento a partir de sua experiência.

Um trabalho diretamente relacionado a essa perspectiva é apresentado por Georgeon *et al.* (2013), que propõem o modelo *Enactive Markov Decision Process* (EMDP). Sua principal contribuição é reformular o problema clássico de Aprendizado por Reforço ao tratar percepção e ação como uma única unidade de interação sensório-motora. Assim, em vez de selecionar uma ação isolada para depois receber uma observação e uma recompensa, o agente aprende a realizar interações com o ambiente, avaliando seu sucesso ou fracasso a partir da própria experiência. Essa mudança desloca o foco da maximização de recompensas externas para a aprendizagem de regularidades no acoplamento entre agente e mundo.

No EMDP, a motivação do agente está ligada à construção e ao domínio de sequências de interação. O agente passa a preferir interações que consegue realizar com sucesso e a organizar comportamentos mais complexos a partir dessas regularidades aprendidas. Esse ponto é importante porque aproxima o aprendizado artificial da perspectiva enativa, segundo a qual conhecer não é apenas representar o ambiente, mas agir nele de modo recorrente e significativo. Ainda assim, permanece em aberto como conectar essa automotivação a condições internas de viabilidade, adaptação e precariedade do próprio agente. Em outras palavras, falta explicar como o valor das interações pode depender também do estado interno do sistema que age.

Uma contribuição posterior nessa direção é apresentada por Nogueira *et al.* (2020), que investigam a autonomia intrínseca por meio de computação evolucionária em um ambiente aberto. O trabalho parte da crítica de que algoritmos evolucionários tradicionais, quando

guiados por uma função de aptidão previamente definida, ainda descrevem externamente o comportamento esperado do agente. Em resposta a essa limitação, os autores propõem o EMOTIONAL, um algoritmo no qual a dinâmica de seleção é internalizada no próprio agente e vinculada à sua atividade contínua no ambiente, sem descrição explícita de objetivos, métricas de avaliação ou dinâmicas cooperativas. Nesse modelo, um robô virtual possui uma variável interna de energia, que diminui com sua atividade, pode ser reduzida por interações prejudiciais e pode ser recuperada por interações favoráveis. Assim, a precariedade do agente funciona como pressão adaptativa: o comportamento não emerge porque o projetista definiu diretamente tarefas como “coletar frutas” ou “evitar venenos”, mas porque certas interações afetam a continuidade do próprio sistema.

Os resultados mostram a emergência de comportamentos de navegação e forrageamento em um ambiente com frutas, venenos e obstáculos, mesmo sem uma função objetivo que especifique diretamente essas ações. Os sinais sensoriais precisam ser incorporados à dinâmica do agente ao longo de sua história de interação, de modo que uma fruta não é tratada desde o início como recompensa no sentido clássico do Aprendizado por Reforço, mas adquire relevância porque modifica o estado corporal do agente e interfere em sua permanência em atividade. Para esta pesquisa, esse trabalho é relevante porque explora uma noção mais forte de autonomia comportamental, na qual o valor da experiência passa a depender da relação entre ação, percepção, energia interna e acoplamento com o ambiente. Ao mesmo tempo, o estudo evidencia desafios, pois a ausência de uma função de aptidão explícita torna a avaliação dos comportamentos menos direta e os caminhos evolutivos continuam influenciados pelos parâmetros internos do algoritmo e pelas regras do ambiente.

Outro ponto importante é desenvolvido por Nogueira *et al.* (2016), que enfatizam a riqueza sensorial e ambiental como condição para a emergência de comportamentos mais complexos em personagens virtuais autônomos. O trabalho compara formas de acoplamento sensorio-motor e mostra que sistemas perceptivos mais expressivos, como visão baseada em câmera virtual, permitem comportamentos mais sensíveis ao ambiente do que sensores de proximidade mais simples, reduzindo limitações como pontos cegos e movimentos repetitivos. Ao relacionar visão, energia, ação e sobrevivência, o estudo reforça que a complexidade do ambiente e dos canais perceptivos influencia diretamente os tipos de regularidades que o agente pode construir. Assim, essa contribuição é importante porque mostra que a autonomia enativa não depende apenas de retirar uma função objetivo externa, mas também de oferecer um acoplamento

suficientemente rico para que o agente possa constituir formas próprias de relevância e adaptação.

Ao final, esse panorama é reforçado por Filho e Nogueira (2022), que analisam implementações práticas de IA Enativa a partir dos critérios teóricos propostos para agência e para sistemas enativos. Os autores observam que a área ainda possui forte desenvolvimento conceitual e relativamente poucos experimentos práticos. A análise indica que muitos trabalhos conseguem satisfazer condições gerais de agência, mas encontram maior dificuldade em implementar princípios mais exigentes da IA Enativa, especialmente aqueles ligados à autonomia constitutiva e à adaptatividade. Esse diagnóstico é importante porque mostra que o desafio não está apenas em produzir agentes capazes de agir no ambiente, mas em construir sistemas cujo comportamento esteja ligado à própria organização interna e à manutenção de suas condições de existência.

3.4 Aprendizado por Curiosidade

O aprendizado por curiosidade aparece no Aprendizado por Reforço Profundo como uma forma de fazer o agente explorar melhor o ambiente sem depender apenas de recompensas externas. Em vez de receber valor somente quando cumpre um objetivo definido pelo ambiente, o agente também pode receber sinais internos ligados à novidade, à incerteza ou à dificuldade de prever o que acontece depois de suas ações. Essa ideia é importante porque muda parcialmente a origem da recompensa. A interação passa a ter valor não apenas porque o projetista disse que ela é importante, mas também porque ela revela algo novo para o próprio agente.

Um exemplo importante dessa linha é o trabalho de Bellemare *et al.* (2016). Os autores retomam a ideia de exploração por contagem, comum em métodos mais clássicos, e a adaptam para ambientes com observações complexas, como imagens de jogos Atari. Como nesses ambientes não é simples contar estados de forma direta, o trabalho usa modelos de densidade para estimar pseudocontagens. Assim, estados menos conhecidos recebem um bônus de exploração. A solução é interessante porque leva uma ideia simples, visitar mais o que ainda é pouco conhecido, para problemas visuais de alta dimensionalidade. Ainda assim, esse tipo de recompensa continua muito ligado à novidade estatística da observação. Ele ajuda o agente a explorar regiões pouco visitadas, mas não garante que essa exploração tenha relação com necessidades internas ou com a manutenção do próprio agente.

Outra contribuição central é o módulo de curiosidade intrínseca proposto por Pathak *et al.* (2017). Nesse método, a curiosidade é calculada a partir do erro de predição das consequências das ações do agente em um espaço de características aprendido de forma autossupervisionada.

Um ponto forte dessa abordagem é o uso de um modelo inverso, que ajuda a dar mais peso aos aspectos do ambiente que dependem das ações do agente. Com isso, o método tenta evitar que o agente seja recompensado por mudanças que ele não controla.

Os experimentos foram realizados principalmente nos ambientes VizDoom (WYD-MUCH *et al.*, 2018) e Super Mario Bros.². No VizDoom, os autores avaliaram condições com recompensa extrínseca esparsa e também situações sem recompensa externa, investigando se o sinal de curiosidade seria suficiente para levar o agente a explorar o ambiente de forma eficiente. Em Super Mario Bros., além da exploração sem recompensa, o trabalho analisou a generalização para fases não vistas, mostrando que a experiência adquirida em uma fase podia acelerar a exploração em outra. Esses resultados indicam que a curiosidade pode auxiliar tanto quando a recompensa externa é rara quanto quando ela está ausente, funcionando como um sinal interno capaz de orientar a exploração sem depender diretamente de uma recompensa manual associada ao objetivo final da tarefa.

O estudo de Burda *et al.* (2018a) leva essa discussão adiante ao investigar agentes treinados apenas por curiosidade, ou seja, os agentes não recebem recompensas externas durante o treinamento. Os experimentos foram conduzidos em larga escala, envolvendo 54 ambientes de benchmark, incluindo jogos Atari, Super Mario Bros. e ambientes de navegação 3D em Unity³. Os autores também investigaram diferentes espaços de características para calcular o erro de predição, comparando representações aleatórias e representações aprendidas. Em jogos Atari, características aleatórias foram suficientes para produzir comportamentos competitivos em vários casos, enquanto em Super Mario Bros. as características aprendidas apresentaram melhor generalização para fases novas.

Como descrito na Seção 2.2.4.2, o *Random Network Distillation* (RND) utiliza erro de predição como medida de novidade. No artigo original, Burda *et al.* (2018b) avaliam esse mecanismo principalmente em jogos Atari de exploração difícil, nos quais recompensas extrínsecas são raras e agentes treinados apenas com PPO tendem a explorar pouco. Os experimentos comparam políticas treinadas com recompensa extrínseca, métodos de curiosidade baseados em dinâmica e políticas treinadas com RND, analisando especialmente jogos como Montezuma's Revenge⁴.

² Wikipédia do Super Mario Bros: <https://pt.wikipedia.org/wiki/Super_Mario_Bros>.

³ Unity é uma plataforma e motor de desenvolvimento de jogos e simulações interativas. Página oficial: <<https://unity.com>>.

⁴ Wikipédia do jogo Montezuma's Revenge: <[https://en.wikipedia.org/wiki/Montezuma%27s_Revenge_\(video_game\)](https://en.wikipedia.org/wiki/Montezuma%27s_Revenge_(video_game))>.

Os resultados mostram que o RND melhora a exploração nesses ambientes e permite ao agente alcançar regiões do jogo que dificilmente seriam descobertas apenas por recompensas externas esparsas. Em alguns casos, como no do Montezuma's Revenge, o método apresenta desempenho substancialmente superior ao PPO sem recompensa intrínseca. Ainda assim, os experimentos permanecem centrados na capacidade de visitar estados novos e melhorar pontuações em benchmarks. O valor do estado continua associado à novidade estatística da observação, sem considerar diretamente condições internas de viabilidade ou precariedade do agente.

Esses trabalhos mostram que a curiosidade pode ser usada de várias formas dentro do Aprendizado por Reforço Profundo. Ela pode aparecer como erro de predição, único sinal de aprendizagem ou destilação de redes aleatórias. Para os objetivos desta pesquisa, porém, a principal limitação dessa literatura é que a curiosidade costuma estar ligada à novidade da informação em si. Ela ajuda o agente a explorar, mas nem sempre explica por que certas experiências deveriam importar para ele. Por isso, esses trabalhos são uma ponte importante entre recompensas externas e sinais internos de aprendizagem, mas ainda deixam espaço para investigar formas de recompensa intrínseca mais próximas de processos enativos, nas quais o valor da interação depende da relação entre percepção, ação, estado interno e adaptação.

4 METODOLOGIA

Este capítulo apresenta a proposta metodológica deste trabalho, cujo objetivo é conectar o arcabouço teórico discutido nos capítulos anteriores com uma investigação prática em Aprendizado por Reforço Profundo. A pesquisa parte da hipótese de que a autonomia artificial pode ser investigada de modo mais adequado quando o comportamento do agente não é orientado apenas por recompensas externas, mas também por condições internas de viabilidade. Nesse sentido, a metodologia proposta busca construir uma configuração experimental na qual percepção, curiosidade e precariedade estejam diretamente relacionadas.

Ao longo do capítulo, serão comentados os principais elementos necessários para a construção desse experimento, incluindo a tarefa *Health-Gathering*, a formulação em Aprendizado por Reforço, o algoritmo PPO, a estratégia de recompensa, o glaucoma artificial, a recompensa intrínseca por curiosidade, as configurações experimentais, as métricas de avaliação e as análises comportamentais e visuais. A descrição detalhada de cada um desses pontos será desenvolvida nas seções correspondentes.

4.1 Ambiente Experimental

O ambiente escolhido para os experimentos corresponde à tarefa *Health-Gathering*, da plataforma VizDoom (WYDMUCH *et al.*, 2018). A escolha do VizDoom decorre do equilíbrio oferecido entre complexidade perceptiva e eficiência computacional. A plataforma fornece ambientes tridimensionais em primeira pessoa, nos quais o agente precisa interpretar imagens, estimar relações espaciais e selecionar ações sem acesso direto a uma representação global do ambiente. Essas características tornam a interação suficientemente rica para investigar percepção visual, navegação, exploração e adaptação, evitando que o problema seja reduzido a estados simbólicos ou a uma representação bidimensional simplificada.

Ao mesmo tempo, o VizDoom mantém um custo computacional relativamente baixo quando comparado a simuladores tridimensionais mais detalhados ou baseados em física complexa. Sua execução rápida permite gerar grandes quantidades de interações necessárias ao treinamento por Aprendizado por Reforço Profundo sem exigir, obrigatoriamente, máquinas de alto desempenho. Esse aspecto é especialmente importante neste trabalho, pois a comparação entre condições de recompensa e diferentes forças de glaucoma demanda múltiplos treinamentos e milhões de passos de interação. Dessa forma, a plataforma possibilita conduzir experimentos

visualmente complexos em equipamentos menos robustos e repetir as execuções com maior viabilidade computacional.

Entre as tarefas disponíveis na plataforma, *Health-Gathering* foi selecionada por apresentar uma dinâmica simples de controlar, mas adequada ao problema investigado. O agente está situado em uma sala cujo chão causa perda contínua de vida e pode coletar *medikits*, itens distribuídos no ambiente que restauram sua condição. Essa estrutura combina percepção tridimensional, navegação, busca por recursos, deterioração contínua e possibilidade de morte. Assim, a tarefa oferece complexidade suficiente para observar comportamentos adaptativos, preservando o controle necessário para relacionar as ações do agente às condições de viabilidade e à degradação perceptiva introduzida pelo glaucoma artificial. A Figura 8 apresenta uma visão superior desse ambiente, destacando a distribuição dos *medikits*.




Figura 8 – Visão superior do ambiente da tarefa *Health-Gathering*. Os itens em formato de “+” representam os *medikits* distribuídos no ambiente, que podem ser coletados pelo agente para restaurar sua vida.

Fonte: Elaborada pelo autor

Além disso, o *Health-Gathering* permite formular uma tarefa visual de navegação e forrageamento. O agente percebe o ambiente por meio de imagens da tela e deve selecionar ações que o mantenham em interação com o mundo. Essa característica aproxima o problema de tarefas de Aprendizado por Reforço Profundo baseadas em percepção visual, ao mesmo tempo em que fornece uma estrutura simples para investigar sobrevivência, busca por recursos e adaptação.

No contexto do VizDoom, um *tick* corresponde a uma unidade discreta de atualização

do jogo. A cada *tick*, o ambiente atualiza seus elementos internos, como posição do agente, estado dos objetos, valor de vida e observação visual disponível. Assim, o episódio pode ser entendido como uma sequência finita de *ticks*, durante os quais o agente observa o ambiente, escolhe ações e sofre as consequências dessas ações. Na configuração experimental adotada, cada episódio terá duração máxima de 2100 *ticks*.

A vida do agente funciona apenas como uma variável de controle do ambiente. Seu valor não compõe a observação fornecida à política, não é utilizado no cálculo da recompensa e não participa diretamente da atualização do aprendizado. Quando a vida chega a zero, o ambiente encerra o episódio, simulando a morte do agente após permanecer tempo suficiente sem se alimentar. Dessa forma, a vida determina por quanto tempo a interação pode continuar, mas não informa ao agente qual comportamento deve ser aprendido.

A perda de vida ocorre continuamente porque o chão do ambiente é ácido. O agente inicia cada episódio com 100 pontos de vida, que também correspondem à sua vida máxima, e perde 8 pontos de vida a cada 36 *ticks*, independentemente da ação escolhida. Os *medikits* funcionam como recursos de recuperação: ao serem coletados, restauram 25 pontos de vida do agente. O ambiente conterá 16 *medikits* disponíveis simultaneamente, posicionados aleatoriamente no início do episódio. Novos *medikits* surgirão a cada 30 *ticks* do jogo, mantendo a dinâmica de busca por recursos ao longo do episódio.

Os principais elementos do ambiente padrão, portanto, incluem a vida inicial e máxima do agente, a duração máxima dos episódios, a taxa de perda de vida no chão ácido, a quantidade de *medikits* disponíveis, a quantidade de vida restaurada por cada item e a regra de surgimento dos novos *medikits*. Esses elementos definem a dinâmica básica de sobrevivência e coleta de recursos da tarefa *Health-Gathering*.

4.2 Formulação em Aprendizado por Reforço

Como discutido na Seção 2.2.1, o Aprendizado por Reforço modela a interação entre agente e ambiente como um processo sequencial de observação, ação, transição de estado e recompensa. Nesta pesquisa, a tarefa *Health-Gathering* será formulada a partir dessa estrutura: a cada instante de tempo, o agente recebe uma observação visual do ambiente, escolhe uma ação e recebe um sinal de recompensa. Em seguida, o ambiente é atualizado e uma nova observação é produzida. Esse ciclo se repete até o fim do episódio, que pode ocorrer quando a vida do agente chega a zero ou quando o limite máximo de *ticks* é atingido.

4.2.1 Observação

As observações serão compostas por imagens do ponto de vista do agente. Assim, o agente não receberá uma representação simbólica do ambiente, como coordenadas absolutas dos *medikits* ou mapas completos da sala, mas sim informações visuais para um personagem situado no ambiente.

As imagens passarão por uma sequência fixa de pré-processamento, ilustrada na Figura 9. A observação original fornecida pelo ambiente possui resolução de 320×240 pixels em RGB. Em seguida, a imagem será convertida para escala de cinza, reduzindo os três canais de cor a um único canal de intensidade. Depois, será redimensionada para 84×84 pixels. Por fim, os valores dos pixels serão divididos por 255, passando inicialmente para o intervalo $[0, 1]$. Durante o treinamento, o Sample Factory também aplica uma normalização estatística baseada na média e no desvio padrão acumulados das observações.

O treinamento diretamente com as imagens originais exigiria processar uma quantidade muito maior de valores a cada interação, aumentando o consumo de memória, o tempo de inferência e o custo das atualizações da rede. Além disso, as informações de cor e a alta resolução não são indispensáveis para distinguir os principais elementos desta tarefa, como paredes, regiões navegáveis e *medikits*. O pré-processamento reduz detalhes visuais que não são centrais para o experimento, padroniza a escala da entrada e permite coletar e processar mais experiências com os recursos computacionais disponíveis. A resolução de 84×84 preserva a estrutura espacial necessária à navegação e à identificação dos recursos, sem impor o custo de treinar com a imagem original. Essa escolha, portanto, busca eficiência e estabilidade no treinamento, e não a obtenção da representação visual mais detalhada possível.

4.2.2 Ação

O conjunto de ações será composto por três comandos discretos de navegação: ir em frente, virar à esquerda e virar à direita. Essas ações permitem que o agente explore a sala e se desloque em direção aos recursos disponíveis, mantendo a formulação do problema simples e adequada aos objetivos da pesquisa.

A ação de andar para trás foi omitida por ser redundante, pois o agente pode girar e avançar na direção oposta. Essa simplificação reduz o espaço de ações e afeta igualmente todas as condições experimentais.




Figura 9 – Etapas de pré-processamento da observação visual do agente: imagem RGB original com resolução de 320×240 pixels, conversão para escala de cinza, redimensionamento para 84×84 pixels e normalização dos valores para o intervalo $[0, 1]$.

Fonte: Elaborada pelo autor

4.2.3 Recompensa

Na tarefa *Health-Gathering*, o agente recebe uma recompensa extrínseca de $+0,01$ a cada *tick* e de $+1$ para cada *medikit* utilizado. Essa formulação incentiva tanto a permanência no ambiente quanto o uso dos recursos responsáveis pela recuperação da vida.

Neste trabalho, entretanto, essa recompensa extrínseca será zerada. Essa decisão evita que a solução do problema seja introduzida diretamente na função de recompensa e permite investigar formas alternativas de orientação comportamental. A recompensa utilizada nos experimentos será detalhada nos próximos capítulos, especialmente na discussão sobre motivação intrínseca e curiosidade artificial.

4.3 Algoritmo de Aprendizado

A política do agente será treinada a partir do mecanismo de atualização do *Proximal Policy Optimization* (PPO). Como apresentado na Seção 2.2.3.3, o PPO busca atualizar a política de forma estável, evitando mudanças abruptas entre a política usada para coletar experiências e a nova política aprendida.

A implementação do treinamento utiliza a biblioteca Sample Factory (PETRENKO *et al.*, 2020), que fornece uma arquitetura assíncrona e de alto desempenho para algoritmos de Aprendizado por Reforço. Enquanto o PPO fornece o mecanismo de atualização da política, o Sample Factory paraleliza a coleta de experiências em múltiplas instâncias do ambiente e separa os componentes responsáveis pela simulação, pela inferência da política e pela atualização da rede. O treinamento deixa, assim, de depender de uma execução estritamente sequencial entre

coleta de dados e otimização.

Essa arquitetura foi escolhida por sua elevada eficiência no aproveitamento dos recursos computacionais. A execução assíncrona reduz períodos de ociosidade, permite utilizar simultaneamente múltiplos núcleos de CPU para simular ambientes e agrupa inferências e atualizações na GPU. O Sample Factory foi projetado para alcançar alto volume de interações em uma única máquina e em hardware amplamente disponível, evitando a necessidade de grandes infraestruturas distribuídas (PETRENKO *et al.*, 2020). Embora o desempenho efetivo dependa da configuração utilizada, essa eficiência torna viável realizar milhões de passos de interação e repetir treinamentos em equipamentos menos robustos. Neste trabalho, o PPO define o mecanismo de otimização da política, enquanto o Sample Factory fornece a infraestrutura utilizada para executar o treinamento de forma paralela e eficiente.

Nesta seção, serão descritos os principais elementos necessários para a implementação do algoritmo de aprendizado, incluindo os hiperparâmetros utilizados e a arquitetura da rede neural.

4.3.1 Hiperparâmetros

O Sample Factory oferece numerosos parâmetros de configuração, mas nem todos são relevantes para a descrição metodológica. A Tabela 1 reúne os parâmetros que afetam diretamente a atualização da política, a estimativa dos retornos e a estabilidade do aprendizado.

Tabela 1 – Hiperparâmetros de aprendizado utilizados no PPO.

Parâmetro	Valor	Descrição
batch_size	1024	Número de transições em cada minilote de otimização.
num_epochs	1	Número de passagens de otimização sobre cada conjunto de experiências coletado.
learning_rate	0,0001	Magnitude das atualizações realizadas pelo otimizador.
gamma	0,999	Fator de desconto aplicado às recompensas futuras.
ppo_clip_ratio	0,1	Limita a alteração da política entre atualizações consecutivas.
ppo_clip_value	0,2	Limita a alteração da estimativa produzida pela função de valor.

4.3.2 Arquitetura da Rede Neural

A arquitetura da rede neural será responsável por transformar a observação visual pré-processada em uma representação latente utilizada pela política do agente. Como a entrada é uma imagem em escala de cinza, o modelo utiliza um codificador convolucional. A Tabela 2 apresenta a arquitetura utilizada.

Tabela 2 – Arquitetura da rede neural utilizada pelo agente.

Etapa	Camada	Configuração	Saída
1	Convolutacional 2D	$1 \rightarrow 32$, kernel 8×8 , stride 4×4	32 mapas de características
2	ReLU		32 mapas de características
3	Convolutacional 2D	$32 \rightarrow 64$, kernel 4×4 , stride 2×2	64 mapas de características
4	ReLU		64 mapas de características
5	Convolutacional 2D	$64 \rightarrow 128$, kernel 3×3 , stride 2×2	128 mapas de características
6	ReLU		128 mapas de características
7	Flatten	Vetorização das ativações	2048 unidades
8	Linear	$2048 \rightarrow 512$	512 unidades
9	ReLU		512 unidades
10	Política (linear)	$512 \rightarrow 4$	4 valores de ação

A Figura 10 apresenta uma representação visual do fluxo de processamento da política, desde a observação de entrada até os valores associados às ações.




Figura 10 – Arquitetura da rede neural utilizada pela política do agente, composta por três camadas convolucionais, uma etapa de vetorização, uma camada totalmente conectada com 512 unidades e a camada de saída.

Fonte: Elaborada pelo autor.

O codificador convolucional extrai características espaciais da observação visual,

enquanto a camada linear projeta essas características para uma representação compacta de 512 unidades. A primeira camada não convolucional utiliza essa representação para produzir os valores associados às ações disponíveis para a política.

A escolha dessa arquitetura convolucional é deliberadamente simples. O objetivo dos experimentos não é obter o melhor desempenho possível na tarefa nem propor uma nova arquitetura de percepção, mas avaliar, de maneira controlada, o efeito geral da relação entre glaucoma artificial, curiosidade e viabilidade. Para esse propósito, a CNN é suficiente para extrair características espaciais relevantes das observações e fornecer à política informações necessárias à navegação e à identificação de recursos. Técnicas mais sofisticadas não foram consideradas porque acrescentariam componentes desnecessários para o objetivo do trabalho. Assim, a arquitetura adotada privilegia simplicidade, sem pretensão de alcançar o estado da arte em desempenho.

4.4 Configuração Experimental do Treinamento

Todos os experimentos utilizarão a mesma configuração básica de observação e execução, apresentada na Tabela 3. Cada treinamento será realizado por 10 000 000 de passos de interação com o ambiente. A adoção do mesmo limite em todas as condições garante que os agentes disponham do mesmo orçamento de experiência, permitindo atribuir as diferenças observadas às formas de recompensa e aos níveis de glaucoma, em vez de a durações distintas de treinamento.

Para acelerar a geração dessas experiências, foram utilizados 4 processos paralelos, definidos pelo parâmetro `num_workers`. Cada processo executa duas instâncias independentes do ambiente, conforme definido por `num_envs_per_worker`, totalizando até 8 instâncias em execução simultânea. Essa configuração permite coletar transições de diferentes episódios ao mesmo tempo, aproveitando melhor os núcleos da CPU e reduzindo o tempo necessário para alcançar os 10 000 000 de passos. Esses parâmetros alteram a velocidade de coleta das experiências, mas não o número total de passos nem o objetivo de aprendizado do agente.

Também foi utilizado `env_frameskip` igual a 4. Com essa configuração, cada ação escolhida pelo agente é mantida durante quatro quadros consecutivos do ambiente antes que uma nova decisão seja calculada. Isso reduz a frequência de inferências da rede neural e a quantidade de observações que precisam ser processadas para avançar o mesmo intervalo de tempo no jogo, acelerando a simulação e o treinamento. Embora valores maiores possam

eliminar mudanças visuais importantes entre duas decisões, o valor 4 oferece um equilíbrio entre eficiência computacional e controle do agente. Como o mesmo valor é empregado em todas as condições experimentais, seus efeitos permanecem constantes nas comparações realizadas.

Tabela 3 – Configurações de execução do treinamento.

Parâmetro	Valor	Descrição
env_frameskip	4	Mantém cada ação durante quatro quadros consecutivos do ambiente.
num_workers	4	Número de processos utilizados para executar ambientes em paralelo.
num_envs_per_worker	2	Número de instâncias do ambiente executadas por cada processo.
train_for_env_steps	10 000 000	Número total de passos de interação realizados em cada experimento.

4.5 Estratégia de Recompensa

4.5.1 O Problema da Recompensa

A escolha da recompensa é um dos pontos centrais desta proposta metodológica. Um personagem artificial considerado inteligente não deve apenas repetir um comportamento fixo independentemente do que ocorre ao seu redor. Pelo contrário, espera-se que ele seja capaz de perceber mudanças no ambiente, compreender a dinâmica da situação em que está inserido e agir de maneira flexível. Nesse sentido, a inteligência não é entendida apenas como a execução eficiente de uma ação previamente desejada, mas como a capacidade de encontrar formas de ação adequadas diante de diferentes condições.

Reforçar diretamente um comportamento específico tende a produzir agentes que executam apenas aquele comportamento. Embora isso possa resolver uma tarefa delimitada, também pode tornar o agente monótono e limitar a descoberta de soluções melhores, que talvez não tenham sido previstas pelo projetista durante a engenharia de recompensas. Assim, quando a recompensa força uma solução, ela pode impedir que o agente explore outras possibilidades de ação que também resolveriam o problema, ou até o resolveriam de maneira mais robusta.

Esse problema retoma a discussão apresentada na fundamentação teórica sobre Aprendizado por Reforço, na qual a recompensa aparece como o sinal que orienta a atualização da política do agente (Seção 2.2.1). Como o agente aprende a maximizar a recompensa acumulada, a forma como esse sinal é definido não é um detalhe apenas técnico, pois ela delimita o que

será considerado desejável dentro do processo de aprendizagem. Por isso, a engenharia de recompensas pode resolver tarefas específicas, mas também pode introduzir diretamente a solução esperada pelo projetista.

Essa distinção conduz ao problema conceitual discutido na fundamentação filosófica. Se a inteligência pode ser entendida como um fenômeno emergente da vida, isto é, como algo que surge de uma organização capaz de manter a si mesma em relação contínua com o ambiente (Seção 2.1.2), então não basta associar a palavra “vida” a uma variável numérica do ambiente. Em Aprendizado por Reforço, o agente não está propriamente trabalhando para se manter vivo. O que ele faz é maximizar um sinal numérico de recompensa acumulada. Mesmo quando a recompensa está associada ao tempo de sobrevivência, o agente não compreende esse número como vida. Para o algoritmo, trata-se apenas de um valor a ser aumentado.

Assim, dizer que o agente “quer sobreviver” é apenas uma metáfora. O problema em si não possui significado para ele, a menos que a própria organização do agente e de sua interação com o ambiente produza algum domínio de relevância. Por isso, recompensar diretamente a coleta de *medikits*, a navegação até uma região ou o tempo de sobrevivência resolveria parte do problema experimental, mas manteria a orientação do comportamento inteiramente dependente de uma especificação externa. A proposta, portanto, não é eliminar a recompensa, pois ela continua sendo necessária ao funcionamento do Aprendizado por Reforço, mas deslocar seu papel, para que, em vez de funcionar como uma instrução direta sobre qual ação executar, ela favoreça a exploração e a busca por soluções.

4.5.2 Autopoiese, IA Enativa e Perspectiva de Solução

É nesse ponto que a Inteligência Artificial Enativa oferece uma motivação conceitual importante. Na perspectiva de Maturana e Varela (1980), a vida não é apenas a posse de uma variável chamada vida, mas uma dinâmica de autoprodução e manutenção de uma unidade que se diferencia do ambiente. Um ser vivo existe porque há uma dinâmica interna que trabalha continuamente para manter sua própria organização. Essa dinâmica depende do ambiente, pois os recursos necessários à sua continuidade precisam ser encontrados e incorporados. Por isso, a vida possui uma dimensão intencional, na qual o organismo se orienta no ambiente a partir daquilo que importa para a manutenção de sua própria existência.

A noção de autopoiese permite compreender essa relação. Um sistema autopoietico é uma dinâmica que produz e mantém a si mesma, distinguindo-se do meio em que está inse-

rida. Essa manutenção, porém, não está garantida de antemão. O sistema permanece exposto a perturbações e depende de condições de viabilidade para continuar existindo. Neste trabalho, precariedade designa essa dependência contínua de condições que podem ser perdidas. Um sistema é precário quando sua organização não está assegurada e precisa ser constantemente mantida por meio de sua própria atividade e de suas interações com o ambiente. Portanto, precariedade não significa apenas fragilidade ou dificuldade imposta externamente. Ela corresponde à possibilidade de que determinadas perturbações comprometam a continuidade da organização do próprio sistema.

Essa definição pode ser aproximada da noção de idiosincrasia, entendida como uma predisposição particular do organismo que faz com que ele responda de maneira própria à influência de agentes externos. Um mesmo elemento do ambiente pode produzir efeitos diferentes conforme a organização e a condição interna daquele que o encontra. Dessa maneira, o valor de uma interação não pertence exclusivamente ao objeto externo, mas emerge da relação entre esse objeto e as necessidades particulares do sistema. A precariedade fornece, assim, a condição pela qual certas perturbações adquirem relevância, enquanto a idiosincrasia ajuda a compreender por que essa relevância depende da constituição específica do agente.

Em termos de viabilidade, a precariedade pode ser compreendida pela proximidade de um sistema em relação à fronteira além da qual sua organização não pode mais ser mantida. Quanto mais próximo dessa fronteira um indivíduo se encontra, mais precária é sua condição, pois menor é sua margem para absorver perturbações sem comprometer sua continuidade. Inversamente, quanto mais distante da fronteira de viabilidade, maior é sua margem de estabilidade. A precariedade não constitui, portanto, uma propriedade simplesmente presente ou ausente, mas uma condição gradual e dinâmica que varia conforme o estado do indivíduo e sua relação com o ambiente.

Com base nessa leitura, a perspectiva de solução adotada neste trabalho consiste em introduzir uma forma artificial de precariedade no agente. A função dessa precariedade é fazer com que a condição interna do agente tenha consequências sobre sua relação com o ambiente. Em vez de dizer diretamente que coletar *medikits* é desejável, busca-se criar uma dinâmica em que ficar muito tempo sem recuperar sua condição interna afete suas possibilidades de perceber, explorar e continuar interagindo.

Dessa forma, a precariedade serve como mediação entre a condição interna do agente, sua relação com o ambiente e suas ações. Ela transforma a viabilidade em uma condição prática

para a continuidade da interação. A coleta de recursos pode então tornar-se relevante não porque foi imposta como objetivo final pela função de recompensa, mas porque contribui para afastar o agente da fronteira de viabilidade e preservar suas possibilidades de ação.

A questão metodológica passa a ser, portanto, como introduzir a precariedade no agente. Se a proposta é fazer com que a condição interna afete a própria relação perceptiva com o ambiente, é necessário definir um mecanismo capaz de degradar e recuperar a percepção de acordo com essa condição. No experimento proposto, esse papel será desempenhado pelo glaucoma artificial, apresentado na seção seguinte.

4.6 Glaucoma como Precariedade

O glaucoma é um conjunto de doenças oculares que danificam o nervo óptico, estrutura responsável por transmitir ao cérebro as informações captadas pelo olho. Em suas formas mais comuns, a perda visual tende a ocorrer lentamente e pode não ser percebida em seus estágios iniciais. O comprometimento geralmente começa pela visão periférica e pode avançar para o estreitamento do campo visual, produzindo uma percepção semelhante à visão em túnel. Em estágios avançados, a doença pode atingir a visão central e causar perda visual irreversível ou cegueira (National Eye Institute, 2025). A Figura 11 apresenta uma comparação ilustrativa entre uma visão sem comprometimento e a perda de visão periférica associada ao glaucoma.



Figura 11 – Comparação ilustrativa entre uma visão sem comprometimento, à esquerda, e a perda de visão periférica associada ao glaucoma, à direita.

Fonte: American Optometric Association (American Optometric Association, s.d.).

4.6.1 *Glaucoma Artificial*

A forma de precariedade artificial proposta neste trabalho foi inspirada no comprometimento do campo visual causado pelo glaucoma apresentado anteriormente. Essa inspiração, entretanto, não corresponde a uma reprodução clínica da doença. Enquanto o glaucoma humano costuma comprometer inicialmente a visão periférica, o glaucoma artificial adotado no experimento começa no centro da observação e se expande progressivamente em direção às bordas. O termo é utilizado, portanto, como uma analogia para representar uma perda gradual da capacidade visual, e não como uma simulação fisiologicamente fiel do glaucoma.

O glaucoma artificial é o mecanismo escolhido para materializar uma forma específica da precariedade discutida na seção anterior. Neste experimento, ele é compreendido como precariedade perceptiva, pois a aproximação da fronteira de viabilidade se manifesta pela perda progressiva das condições de percepção do agente. Enquanto o agente permanece sem coletar *medikits*, sua visão se degrada gradualmente. Quando coleta um *medikit*, essa degradação é removida. Desse modo, a precariedade não aparece apenas como uma penalidade externa na função de recompensa, mas atua diretamente sobre a forma como o agente acessa o ambiente.

Essa escolha é importante porque conecta o problema da recompensa à perspectiva enativa adotada neste trabalho. Se o agente recebesse uma recompensa direta por coletar *medikits*, o comportamento esperado estaria explicitamente especificado pelo projetista. Com o glaucoma artificial, por outro lado, a coleta de recursos passa a ter importância indireta, pois preserva as condições perceptivas necessárias para que o agente continue explorando o ambiente. Assim, o glaucoma funciona como uma forma computacional de precariedade, pois traduz a passagem do tempo sem recuperação interna em perda progressiva de capacidade perceptiva.

A Figura 12 ilustra a evolução do efeito visual esperado em quatro momentos. A primeira imagem apresenta a visão limpa do agente, após 0 *frames* sem comer, ou seja, o agente acabou de usar um *medikit*. A segunda mostra um glaucoma inicial, após 1 *frame* sem comer. A terceira mostra uma degradação mais acentuada, após 20 *frames* sem comer. A quarta e última mostra uma degradação severa, após 50 *frames* sem comer. Esse tipo de transformação representa a ideia de que um agente em pior condição interna não deixa apenas de receber pontos, mas passa a perceber o mundo de modo mais limitado.

Do ponto de vista implementacional, a velocidade de crescimento do glaucoma será controlada por uma variável do programa, chamada força do glaucoma. Essa variável define quantos pixels passam a sofrer degradação a cada *tick* em que o agente permanece sem coletar




Figura 12 – Evolução da percepção visual do agente com glaucoma artificial de força 100. Da esquerda para a direita, a figura mostra a visão limpa após 0 *frames* sem comer, glaucoma inicial após 1 *frame*, degradação intermediária após 20 *frames* e degradação severa após 50 *frames*.

Fonte: Elaborada pelo autor

um *medikit*. Por exemplo, se a força do glaucoma tiver valor 100, então, a cada *tick* sem comer, mais 100 pixels serão afetados pelo glaucoma. De modo geral, se a força do glaucoma tiver valor x , então o glaucoma crescerá x pixels por *tick* sem recuperação. Quando o agente coleta um *medikit*, o nível de glaucoma é reiniciado e a percepção volta ao estado sem degradação.

Os pixels afetados pelo glaucoma seguem um padrão espacial definido do centro para as bordas da imagem. A degradação começa ao redor do ponto central da observação e se expande progressivamente formando um quadrado em torno de si mesmo. A cada atualização, novos pixels são incorporados à região degradada, aumentando o tamanho desse quadrado pixel a pixel. Dessa forma, o glaucoma não surge aleatoriamente na imagem, mas cresce de maneira ordenada, produzindo uma perda visual progressiva e espacialmente estruturada.

Formalmente, a evolução do glaucoma pode ser representada por uma variável g_t , que indica a quantidade acumulada de pixels afetados no instante t . Se o agente não coleta um *medikit*, então $g_{t+1} = g_t + x$, em que x representa a força do glaucoma definida no programa. Se ocorre a coleta, então $g_{t+1} = 0$. Esse valor determina o tamanho da região quadrada degradada aplicada à observação antes que ela seja entregue à rede neural do agente.

Com isso, o glaucoma estabelece uma relação direta entre estado interno e percepção. Quanto maior o tempo sem recuperação, maior a degradação visual. Quanto mais cedo o agente encontra um recurso, mais rapidamente recupera sua percepção. A hipótese metodológica é que essa relação possa favorecer comportamentos adaptativos sem que a coleta de *medikits* precise ser recompensada diretamente. O modo proposto para transformar essa precariedade corporal em sinal de recompensa será apresentado na seção seguinte, por meio de recompensa intrínseca baseada em curiosidade e implementada com RND.

4.7 Recompensa Intrínseca por Curiosidade

Esta seção apresenta o ponto em que a precariedade corporal introduzida pelo glaucoma artificial é transformada em sinal de recompensa. Como discutido na Seção 4.5.1, o agente de Aprendizado por Reforço não age porque compreende a vida ou a sobrevivência como valores próprios. Ele ajusta sua política para maximizar uma recompensa acumulada, conforme a formulação de Aprendizado por Reforço apresentada na Seção 2.2.1. Por isso, a contribuição metodológica deste trabalho consiste em deslocar a recompensa de uma instrução direta, como coletar *medikits*, para uma consequência indireta da precariedade corporal.

A ideia central é que quanto mais precário estiver o corpo artificial do agente, menor deve ser a recompensa obtida por sua interação com o ambiente. De modo complementar, quanto menos precário estiver esse corpo, maior tende a ser a recompensa. Com isso, o agente não é recompensado diretamente por estar vivo ou por coletar um recurso específico. Ele é levado a buscar condições menos precárias porque essas condições preservam sua capacidade de perceber um ambiente mais rico e informativo. Assim, a recompensa passa a favorecer a manutenção do agente dentro de restrições de viabilidade, retomando a discussão sobre autopoiese, precariedade e IA Enativa desenvolvida na Seção 4.5.2.

Essa formulação também dialoga com os trabalhos relacionados discutidos no Capítulo 3. Em particular, trabalhos de Aprendizado por Reforço Profundo mostraram a eficácia de agentes treinados a partir de entradas visuais e recompensas escalares, mas permaneceram fortemente dependentes de objetivos externos definidos pelo ambiente ou pelo projetista. Já trabalhos relacionados à autonomia e à motivação intrínseca indicam a importância de sinais internos para orientar o comportamento, mas ainda deixam em aberto como relacionar esses sinais a uma condição corporal de precariedade. Este trabalho procura ocupar justamente esse espaço, articulando percepção degradada, viabilidade e recompensa.

A recompensa total utilizada pelo agente será definida como a soma entre recompensa extrínseca e recompensa intrínseca, conforme a formulação discutida na fundamentação teórica sobre recompensa intrínseca:

$$r_t = r_t^{\text{ext}} + r_t^{\text{int}}.$$

Neste experimento, entretanto, a recompensa extrínseca será zerada, como definido na Subseção 4.5.1 e na formulação da recompensa do ambiente. Assim, tem-se:

$$r_t^{\text{ext}} = 0$$

e, conseqüentemente:

$$r_t = r_t^{\text{int}}.$$

4.7.1 Calculando a Recompensa Intrínseca

A recompensa intrínseca será calculada por meio do método *Random Network Distillation* (RND), apresentado na Seção 2.2.4.2. No RND, uma rede alvo fixa produz uma representação da observação, enquanto uma rede preditora tenta aproximar essa representação. O erro de predição entre essas redes funciona como medida de novidade. Observações mais ricas, variadas ou menos conhecidas tendem a produzir maior erro de predição e, portanto, maior recompensa intrínseca.

As redes alvo e preditora possuem a mesma arquitetura, apresentada na Figura 13 e detalhada na Tabela 4. Ambas recebem como entrada a observação pré-processada em escala de cinza, com resolução de 84×84 pixels, e produzem um vetor de características com 512 unidades. A diferença entre elas não está na estrutura, mas no processo de aprendizado: os parâmetros da rede alvo são inicializados aleatoriamente e permanecem fixos, enquanto os parâmetros da rede preditora são atualizados para aproximar a representação produzida pela rede alvo.

Tabela 4 – Arquitetura das redes alvo e preditora utilizadas no RND.

Etapa	Camada	Configuração	Saída
1	Convolutacional 2D	$1 \rightarrow 32$, kernel 8×8 , stride 4×4	$32 \times 20 \times 20$
2	ReLU		$32 \times 20 \times 20$
3	Convolutacional 2D	$32 \rightarrow 64$, kernel 4×4 , stride 2×2	$64 \times 9 \times 9$
4	ReLU		$64 \times 9 \times 9$
5	Convolutacional 2D	$64 \rightarrow 64$, kernel 3×3 , stride 1×1	$64 \times 7 \times 7$
6	ReLU		$64 \times 7 \times 7$
7	Flatten	Vetorização das ativações	3136 unidades
8	Linear	$3136 \rightarrow 512$	512 unidades
9	ReLU		512 unidades
10	Linear	$512 \rightarrow 512$	512 unidades

A escolha dessa arquitetura segue o princípio de simplicidade adotado na rede da




Figura 13 – Arquitetura compartilhada pelas redes alvo e preditora do RND, composta por três camadas convolucionais, uma etapa de vetorização e duas camadas totalmente conectadas.

Fonte: Elaborada pelo autor.

política. As três camadas convolucionais são suficientes para extrair características espaciais das observações, enquanto as camadas lineares transformam essas características em uma representação compacta sobre a qual o erro de predição pode ser calculado. Como o objetivo do RND neste trabalho é fornecer um sinal de novidade perceptiva, e não investigar novas arquiteturas de representação, uma estrutura mais sofisticada acrescentaria complexidade e custo computacional sem contribuir diretamente para a hipótese avaliada. O uso da mesma arquitetura nas redes alvo e preditora também torna a comparação entre suas saídas direta e controlada.

O treinamento da rede preditora do RND utilizará `batch_size` igual a 1024 e `learning_rate` igual a 0,0001. O primeiro parâmetro define a quantidade de amostras utilizada em cada atualização, enquanto o segundo controla a magnitude das alterações aplicadas aos parâmetros da rede preditora.

4.7.2 Recompensa Intrínseca e sua Relação com o Glaucoma

Esta subseção apresenta o mecanismo central pelo qual se busca converter a precariedade corporal em recompensa. Em vez de atribuir diretamente um valor positivo à coleta de *medikits*, a proposta permite que o valor da recompensa se constitua a partir da experiência perceptiva do agente e do erro de predição produzido pelo RND. A condição interna modifica a observação, a observação modifica sua previsibilidade e essa previsibilidade determina a recompensa intrínseca utilizada pelo PPO.

No início do treinamento, a política ainda não aprendeu a navegar ou buscar recursos. Por essa razão, espera-se que a coleta de *medikits* seja inicialmente rara. Como a ausência prolongada de coleta permite o crescimento contínuo do glaucoma artificial, o agente tende a permanecer com frequência em estados de elevada degradação visual. Essas observações tornam-se predominantes no conjunto de experiências utilizado para treinar a rede preditora do RND.

A repetição dessas imagens permite que a rede preditora aprenda progressivamente a reproduzir o vetor de características gerado pela rede alvo para observações com glaucoma avançado. Além de serem frequentes, essas observações possuem grande parte da imagem escurecida, ocultando elementos e variações do ambiente que poderiam ser mais difíceis de prever. A combinação entre alta frequência e menor riqueza perceptiva tende, portanto, a reduzir o erro de predição do RND. Como esse erro define a recompensa intrínseca, estados de maior precariedade tendem a produzir recompensas menores.

Quando o agente coleta um *medikit*, o glaucoma é removido e a observação volta a apresentar o ambiente de forma completa. Durante as etapas iniciais do treinamento, essas observações limpas tendem a ser menos frequentes, pois dependem de um evento que a política ainda não aprendeu a provocar regularmente. Além disso, a imagem sem glaucoma contém maior diversidade de objetos, texturas e relações espaciais. Por ser simultaneamente menos frequente e perceptivamente mais rica, essa observação tende a gerar um vetor de características mais difícil de prever, aumentando o erro da rede preditora e, consequentemente, a recompensa intrínseca.

Forma-se, assim, uma relação indireta entre viabilidade e recompensa. Quanto mais precária é a condição perceptiva do agente, mais frequentes e previsíveis tendem a ser suas observações e menor tende a ser sua recompensa intrínseca. Quanto menos precária é essa condição, mais completa e relativamente rara tende a ser sua experiência do ambiente, favorecendo maior erro de predição e maior recompensa. A coleta de *medikits* não é recompensada diretamente, mas pode adquirir relevância porque restaura uma condição perceptiva na qual há maior possibilidade de novidade.

4.7.3 Limites da Recompensa Intrínseca

Pode-se questionar se o uso do RND não equivale apenas a impor outra recompensa ou uma penalidade indireta, contrariando a hipótese proposta. Em sentido estritamente algorítmico, o RND continua produzindo um sinal numérico definido a partir de um mecanismo

escolhido pelo projetista, pois o Aprendizado por Reforço depende de alguma forma de reforço para atualizar a política. A proposta, portanto, não elimina a recompensa nem afirma que ela seja autonomamente criada pelo agente.

A diferença está no conteúdo prescrito por esse sinal. Uma recompensa extrínseca por sobrevivência ou por coleta de *medikits* informa diretamente quais resultados devem ser buscados e incorpora parte da solução desejada à função de recompensa. O RND, por sua vez, recompensa apenas o erro de predição das observações, sem conter uma regra que atribua valor à coleta de recursos, à vida ou à redução do glaucoma.

Da mesma forma, nenhum valor negativo é programado para estados de glaucoma avançado. Esses estados produzem menor recompensa apenas na medida em que se tornam frequentes e previsíveis para a rede preditora, enquanto observações menos precárias podem produzir maior recompensa por serem mais raras e perceptivamente ricas. A relação entre precariedade e recompensa não é inserida diretamente como uma regra numérica, mas resulta da interação entre degradação perceptiva e aprendizado da rede preditora.

Assim, não se trata de remover toda influência do projetista, mas de deslocar a orientação do comportamento de uma recompensa que descreve diretamente a solução para um sinal cuja relação com a viabilidade emerge do acoplamento entre corpo artificial, história de experiências e ambiente. A hipótese metodológica consiste precisamente em avaliar se esse deslocamento é suficiente para favorecer condições menos precárias sem recompensá-las ou penalizá-las explicitamente.

4.8 Configurações Experimentais

Para avaliar a proposta, pretende-se comparar o desempenho do agente em três condições principais de recompensa, cada uma desempenhando uma função específica no experimento. A primeira condição utilizará recompensa zerada, isto é, sem qualquer sinal extrínseco ou intrínseco orientando diretamente o aprendizado. Essa condição funcionará como um controle negativo, permitindo verificar se, na ausência de reforço, o algoritmo se comporta conforme o esperado e não aprende sistematicamente a coletar *medikits* ou a prolongar sua sobrevivência.

A segunda condição utilizará a recompensa extrínseca padrão da tarefa *Health-Gathering*, definida pelo VizDoom. Essa configuração funcionará como um controle positivo, pois indicará se o agente é capaz de aprender quando o projetista especifica diretamente o

comportamento desejado, atribuindo recompensa à permanência no ambiente e à utilização dos *medikits*. Espera-se, portanto, que o agente aprenda a coletar os recursos porque essa ação foi explicitamente valorizada pela função de recompensa.

A terceira condição utilizará apenas recompensa intrínseca, calculada por meio do método *Random Network Distillation* (RND), e corresponde à proposta central desta dissertação. Nessa configuração, a coleta de *medikits*, a sobrevivência e a redução do glaucoma não serão diretamente recompensadas. O objetivo será investigar se esses comportamentos podem ser favorecidos indiretamente pela relação entre curiosidade artificial e precariedade perceptiva. A comparação com os controles negativo e positivo permitirá situar os resultados do RND entre a ausência de aprendizado orientado e o aprendizado produzido por uma recompensa que prescreve explicitamente a solução da tarefa.

Cada uma dessas condições será avaliada sob diferentes intensidades de glaucoma artificial. Serão utilizadas forças de glaucoma iguais a 0, 50, 100 e 200, permitindo observar como o grau de degradação perceptiva interfere no aprendizado e no tempo de sobrevivência do agente. As forças 0 e 200 representam os extremos do intervalo experimental. Na primeira, a observação não sofre degradação, enquanto, na segunda, a visão é comprometida rapidamente. As forças 50 e 100 representam níveis intermediários, escolhidos para analisar o comportamento do agente sob uma degradação moderada e sob uma condição intermediária mais intensa, sem alcançar o comprometimento extremo produzido pela força 200. Desse modo, os experimentos combinam diferentes formas de recompensa com níveis contrastantes e progressivos de precariedade visual.

Essas configurações permitirão investigar se a precariedade perceptiva modifica o comportamento do agente. Em especial, busca-se observar se o agente passa a coletar *medikits* não porque essa ação foi diretamente recompensada, mas porque evitar o crescimento do glaucoma favorece a continuidade da exploração e da obtenção de recompensa intrínseca.

4.9 Métricas de Avaliação

A avaliação será organizada em três dimensões complementares, destinadas a examinar o desempenho, o comportamento e o funcionamento do mecanismo proposto. A duração média dos episódios permitirá comparar a capacidade de sobrevivência entre as diferentes condições experimentais. A análise das trajetórias buscará identificar se a política aprendida responde à disposição espacial dos recursos ou apenas reproduz padrões fixos de movimentação. Por sua vez, a relação entre recompensa intrínseca e precariedade permitirá verificar se a degradação

perceptiva produz o efeito esperado sobre o sinal de curiosidade. Em conjunto, essas análises oferecem uma avaliação mais ampla do agente, evitando que as conclusões dependam de uma única medida quantitativa.

4.9.1 *Duração Média dos Episódios*

A avaliação dos agentes deverá considerar tanto métricas quantitativas quanto análises qualitativas do comportamento aprendido. A principal métrica quantitativa será a duração média dos episódios, utilizada como medida do tempo de sobrevivência alcançado em cada configuração experimental. Para cada condição, serão realizadas cinco execuções independentes, utilizando as sementes aleatórias 42, 43, 44, 45 e 46. O uso de múltiplas sementes reduz a dependência dos resultados em relação a uma inicialização específica, pois fatores estocásticos como os pesos iniciais das redes, a amostragem de ações, a disposição dos recursos e a ordem das experiências podem produzir trajetórias de aprendizado diferentes. Dessa forma, torna-se possível avaliar se o comportamento observado é recorrente e robusto ou se resulta de uma execução excepcional.

O Sample Factory registra a duração média dos episódios em intervalos temporais de execução. Como a velocidade de coleta de experiências pode variar entre os treinamentos, esses registros não ocorrem necessariamente nos mesmos números de passos do ambiente para todas as sementes. A comparação direta dos valores seria, portanto, inadequada, pois não haveria correspondência exata entre os pontos registrados em cada execução. Para construir uma grade comum, as curvas serão alinhadas por interpolação linear em intervalos de 10000 passos, desde o início do treinamento até o orçamento total de 10000000 de passos. A interpolação estima, para cada semente, o valor da duração média nos mesmos pontos do eixo horizontal, permitindo realizar a agregação ponto a ponto. Esse procedimento não acrescenta novas observações experimentais, mas padroniza os instantes de comparação entre registros produzidos de forma assíncrona.

Após o alinhamento, será calculada, em cada passo comum s , a média das cinco curvas interpoladas. Seja $L_i(s)$ a duração média interpolada da execução associada à semente i e seja $N = 5$ o número de sementes. A curva principal será dada por

$$\bar{L}(s) = \frac{1}{N} \sum_{i=1}^N L_i(s).$$

A média resume a tendência central das execuções e reduz a influência de oscilações particulares de uma única semente. Entretanto, a média isolada pode ocultar diferenças relevantes entre os treinamentos. Por essa razão, também será calculado o desvio padrão entre as cinco curvas em cada passo comum, conforme

$$\sigma_L(s) = \sqrt{\frac{1}{N} \sum_{i=1}^N (L_i(s) - \bar{L}(s))^2}.$$

Nos gráficos, a região sombreada corresponderá ao intervalo $\bar{L}(s) \pm \sigma_L(s)$. Uma faixa estreita indica que as diferentes sementes produziram resultados semelhantes naquele estágio do treinamento, sugerindo maior estabilidade e reprodutibilidade. Uma faixa ampla indica maior sensibilidade aos fatores aleatórios e maior variabilidade entre as execuções. Essa região deve ser interpretada como uma representação da dispersão observada entre as sementes, e não como um intervalo de confiança estatístico.

Os valores de recompensa acumulada não serão utilizados para comparar diretamente as condições experimentais, pois os agentes são treinados com sinais de naturezas distintas. A recompensa extrínseca, a recompensa intrínseca produzida pelo RND e a ausência de recompensa não possuem a mesma escala nem representam o mesmo critério de aprendizado. A duração média dos episódios, por outro lado, constitui uma medida comum a todas as configurações. Dessa forma, será possível comparar quanto os agentes sobrevivem ao longo do treinamento quando orientados por diferentes formas de recompensa e submetidos às diferentes forças de glaucoma.

4.9.2 Análise Comportamental das Trajetórias

Também serão realizadas análises comportamentais a partir de diferentes distribuições espaciais dos *medikits* no ambiente. Os recursos serão organizados em formatos de quadrado, círculo, *grid* e seno, conforme ilustrado na Figura 14, permitindo observar a trajetória do agente em cada arranjo. Essa análise buscará verificar se o caminho percorrido pelo agente se modifica de maneira coerente com a disposição dos recursos ou se a política apenas repete uma estratégia fixa de movimentação.

A adoção de distribuições fixas tem como objetivo tornar a análise das trajetórias mais controlada e comparável entre diferentes execuções. Durante o treinamento, os *medikits* surgem em posições aleatórias. Por isso, um agente pode obter bom desempenho sem aprender a se




Figura 14 – Distribuições espaciais dos *medikits* utilizadas nas análises comportamentais. Da esquerda para a direita, são apresentadas as distribuições em quadrado, círculo, *grid* e seno. Os sinais de “+” indicam os *medikits*, enquanto o ponto vermelho indica a posição inicial do agente no episódio.

Fonte: Elaborada pelo autor.

orientar intencionalmente em direção aos recursos, adotando apenas um padrão de deslocamento que ocasionalmente encontra *medikits*. Na distribuição circular, por exemplo, o agente poderia aprender simplesmente a girar ou percorrer uma trajetória circular. Na distribuição em quadrado, poderia permanecer próximo às paredes e coletar recursos incidentalmente ao longo do percurso.

A comparação entre diferentes arranjos permite identificar esse tipo de comportamento estereotipado. Se o agente repetir praticamente a mesma trajetória independentemente da distribuição, a coleta pode ser consequência acidental de uma estratégia geral de movimentação. Se a trajetória variar de acordo com a organização espacial dos *medikits*, haverá evidências de que a política utiliza informações do ambiente para orientar sua navegação. Essa análise não demonstra, por si só, intenção no sentido forte, mas ajuda a distinguir uma política sensível à disposição dos recursos de uma política que apenas os encontra aleatoriamente.

4.9.3 *Relação entre Recompensa Intrínseca e Precariedade*

Além dessas comparações, será analisado o gráfico de recompensa intrínseca nas execuções que utilizam RND. Esse gráfico será apresentado juntamente com uma medida de precariedade perceptiva, calculada pela razão entre a quantidade de pixels escurecidos pelo glaucoma e a quantidade total de pixels da observação. O valor resultante expressa a porcentagem da visão comprometida em cada instante, variando entre uma observação sem degradação e uma observação amplamente obstruída. A visualização conjunta permitirá examinar como a recompensa intrínseca varia conforme o grau de precariedade perceptiva. A ocorrência de recompensas menores em estados mais degradados e de recompensas maiores em estados menos precários constituirá um indício de que o mecanismo proposto consegue converter a precariedade corporal em um sinal relevante para o aprendizado. Essa análise não será utilizada para comparar

diretamente as escalas das diferentes formas de recompensa, mas para avaliar a relação interna entre glaucoma e curiosidade nas configurações baseadas em RND.

4.10 Análise Visual da Política Aprendida

Para complementar a avaliação, pretende-se utilizar técnicas de interpretabilidade visual, como Grad-CAM, discutido na Seção 2.2.5.1. O objetivo é identificar quais regiões da observação influenciam as decisões do agente. A Figura 15 apresenta um exemplo ilustrativo desse tipo de visualização na tarefa *Health-Gathering*. Essa análise é especialmente importante porque o agente atua a partir de imagens e porque a proposta do trabalho depende da relação entre percepção, curiosidade e viabilidade.

A escolha do Grad-CAM segue o mesmo princípio de simplicidade adotado na arquitetura da política. O objetivo não é comparar métodos de interpretabilidade nem obter a explicação visual mais sofisticada possível, mas produzir uma indicação espacial suficientemente clara das regiões da observação que influenciam as decisões do agente. Como a política utiliza camadas convolucionais, o Grad-CAM pode ser aplicado diretamente aos mapas de características da rede e gerar mapas de calor sobrepostos à imagem original, facilitando a interpretação qualitativa do comportamento. Métodos mais sofisticados exigiriam, desnecessariamente, maior custo de processamento. A adoção de uma única técnica simples e compatível com a CNN mantém a análise visual alinhada ao objetivo central do experimento.

Com o Grad-CAM, será possível investigar se o agente direciona sua atenção para elementos relevantes do ambiente, como *medikits*, regiões navegáveis ou obstáculos. Também será possível comparar mapas de ativação em diferentes níveis de degradação perceptiva, buscando compreender como a precariedade visual altera os elementos considerados relevantes pela política.

Essa etapa não tem apenas função técnica, mas também conceitual. Se a proposta busca discutir autonomia e produção de relevância, é necessário analisar não apenas se o agente obtém bom desempenho, mas também como ele utiliza as informações disponíveis para agir. A interpretabilidade visual, portanto, servirá como ferramenta auxiliar para compreender a política aprendida.




Figura 15 – Exemplo ilustrativo de mapa de calor inspirado em Grad-CAM aplicado à tarefa *Health-Gathering*. As regiões mais quentes indicam as áreas da observação com maior relevância para a decisão do agente, isto é, aquelas que mais importam na análise visual da política aprendida.

Fonte: Elaborada pelo autor.

5 RESULTADOS

Este capítulo apresenta e discute os resultados obtidos a partir dos experimentos descritos no Capítulo 4. A análise busca verificar como as diferentes formas de recompensa e intensidades de glaucoma artificial influenciam o aprendizado, a sobrevivência e o comportamento dos agentes na tarefa *Health-Gathering*. Para isso, são comparadas as condições sem recompensa, com recompensa extrínseca padrão e com recompensa intrínseca baseada em *Random Network Distillation* (RND), conforme descrito na Seção 4.8.

Conforme definido na Seção 4.9, os resultados são examinados por meio de dimensões complementares. Inicialmente, a duração média dos episódios é utilizada para comparar a evolução da capacidade de sobrevivência dos agentes ao longo do treinamento. Em seguida, as trajetórias produzidas diante de diferentes distribuições espaciais dos *medikits* são analisadas para identificar se as políticas respondem à organização dos recursos ou apenas reproduzem padrões fixos de movimentação. Nas configurações baseadas em RND, também é investigada a relação entre recompensa intrínseca e precariedade perceptiva, com o objetivo de avaliar se a degradação da visão é efetivamente convertida em um sinal relevante para o aprendizado. Por fim, os mapas produzidos pelo Grad-CAM são examinados para identificar quais regiões das observações apresentam maior relevância para as decisões das políticas aprendidas. Essas análises permitem discutir não apenas o desempenho alcançado, mas também em que medida o mecanismo proposto favorece comportamentos relacionados à manutenção das condições de viabilidade do agente.

5.1 Resultados por Força de Glaucoma

Esta seção organiza os resultados de acordo com as configurações experimentais descritas na Seção 4.8 e com a força do glaucoma artificial aplicada ao agente. Serão analisadas, nesta ordem, as forças 50, 100, 200 e 0, permitindo observar como diferentes intensidades de degradação perceptiva afetam o aprendizado e o comportamento. Para manter um critério comum de comparação, cada condição será examinada a partir de quatro dimensões complementares. Serão consideradas a duração média dos episódios ao longo do treinamento, as trajetórias produzidas diante das diferentes distribuições de *medikits*, a relação temporal entre recompensa intrínseca e precariedade nas execuções que utilizam RND e a análise visual das políticas por meio do Grad-CAM. Essa organização permite avaliar separadamente cada intensidade de

glaucoma e, ao mesmo tempo, identificar padrões e diferenças entre as condições experimentais.

5.1.1 Glaucoma de Força 50

5.1.1.1 Duração Média dos Episódios

A Figura 16 apresenta a evolução da duração média dos episódios para as três condições de recompensa sob glaucoma de força 50. As linhas representam as médias obtidas ao longo das diferentes sementes experimentais, enquanto as regiões sombreadas indicam a variabilidade entre as execuções. Como a duração máxima de um episódio é de 2100 *ticks*, valores próximos desse limite indicam que o agente conseguiu sobreviver durante praticamente todo o tempo disponível.




Figura 16 – Duração média dos episódios ao longo do treinamento nas condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca baseada em RND, sob glaucoma de força 50. As regiões sombreadas representam a variabilidade entre as sementes experimentais.

Fonte: Elaborada pelo autor.

Na condição sem recompensa, a duração dos episódios cresce apenas nas etapas iniciais e se estabiliza em torno de 500 *ticks*. A ausência de crescimento posterior indica que o PPO, sem um sinal de reforço que diferencie as experiências, não aprende uma política capaz de prolongar sistematicamente a sobrevivência. Esse resultado é compatível com a função dessa condição como controle negativo do experimento.

Com a recompensa extrínseca, a duração aumenta rapidamente e se aproxima do limite máximo antes de 2 milhões de passos. Depois desse período, o desempenho permanece estável em torno de 2000 a 2100 *ticks*, com baixa variabilidade entre as sementes. Esse comportamento indica que o agente aprende a coletar *medikits* e, como consequência, prolongar sua permanência no ambiente quando essas ações são diretamente valorizadas pelo projetista.

Na condição com recompensa intrínseca calculada pelo RND, o crescimento é mais lento. A duração permanece abaixo de 1000 *ticks* durante aproximadamente os primeiros 1,5 milhão de passos e aumenta de forma acentuada entre 1,5 e 3 milhões de passos. Após esse período, estabiliza-se próxima de 1900 *ticks*, abaixo da recompensa extrínseca, mas muito acima da condição sem recompensa. A maior dispersão observada durante a fase de crescimento indica que a velocidade de aprendizado varia entre as sementes. Ainda assim, a convergência para episódios longos mostra que a recompensa intrínseca associada à precariedade foi suficiente para favorecer uma política sem recompensar diretamente a coleta de *medikits*.

5.1.1.2 Análise das Trajetórias

A Figura 17 apresenta as trajetórias dos agentes nas distribuições em quadrado, círculo, seno e *grid*. As trajetórias foram obtidas em episódios de avaliação executados com as políticas salvas após 9 633 792 passos de treinamento. Esse checkpoint corresponde a um estágio avançado e próximo do orçamento total de 10 milhões de passos, no qual as curvas de duração dos episódios já se encontravam estabilizadas. Sua utilização permite examinar o comportamento desenvolvido pelas políticas após uma quantidade ampla de experiências. As colunas correspondem às condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca calculada pelo RND. A comparação permite verificar se as políticas respondem à organização espacial dos recursos ou apenas reproduzem uma forma geral de deslocamento.

Os agentes treinados sem recompensa percorrem trajetórias curtas e semelhantes nas quatro distribuições, afastando-se da posição inicial sem acompanhar a disposição dos *medikits*. Esse comportamento reforça o resultado da duração dos episódios e não apresenta evidências de uma política orientada pela localização dos recursos.

Os agentes treinados com recompensa extrínseca exibem deslocamentos mais extensos, mas a correspondência com as distribuições varia entre os arranjos. Na configuração circular, as trajetórias acompanham claramente o círculo formado pelos recursos. Nas distribuições




Figura 17 – Trajetórias produzidas pelas políticas salvas após 9 633 792 passos de treinamento nas distribuições em quadrado, círculo, seno e *grid*, sob as condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca baseada em RND, para glaucoma de força 50.

Fonte: Elaborada pelo autor.

em quadrado, seno e *grid*, porém, aparecem percursos amplos que atravessam regiões sem *medikits* ou se concentram em apenas parte do ambiente. Mesmo sem reproduzir precisamente a geometria das distribuições, o agente consegue interceptar e coletar recursos, como indica a elevada duração dos episódios, prolongando sua permanência no ambiente. Uma possível explicação para os percursos mais amplos é a perda progressiva de visão causada pelo glaucoma. Com a observação parcialmente obstruída, o agente pode deixar de perceber *medikits* próximos e continuar se deslocando até encontrar recursos ainda visíveis ou cruzá-los durante sua trajetória.

Na condição com recompensa intrínseca, as trajetórias acompanham de maneira clara os contornos das distribuições em quadrado, círculo e *grid*. Na distribuição em seno, os percursos são mais dispersos e atravessam regiões externas à curva formada pelos *medikits*. Esses resultados indicam que a política treinada com recompensas calculadas pelo RND utiliza informações espaciais do ambiente em parte das configurações e não se limita a repetir um único padrão de movimento.

5.1.1.3 Relação entre Recompensa Intrínseca e Precariedade

A Figura 18 apresenta a evolução conjunta da recompensa intrínseca e da precariedade perceptiva durante um episódio. As recompensas intrínsecas apresentadas foram calculadas pelo módulo RND após 200704 passos de treinamento. Esse checkpoint, situado nas etapas iniciais do treinamento, foi utilizado porque o agente ainda não havia desenvolvido uma política altamente eficiente de coleta. Consequentemente, o episódio contém um intervalo prolongado sem contato com *medikits*, durante o qual é possível observar o crescimento da precariedade e a redução da recompensa intrínseca. A coleta posterior permite examinar, no mesmo episódio, a restauração da visão e a resposta imediata do RND. Em estágios mais avançados, a coleta frequente dos recursos reduziria os intervalos de degradação contínua e dificultaria a visualização desse contraste. A linha tracejada representa o avanço do glaucoma, enquanto a estrela indica o instante em que um *medikit* é coletado e a visão do agente é restaurada.

No início do episódio, a precariedade cresce continuamente, enquanto a recompensa intrínseca diminui até atingir valores próximos de zero. Quando a visão se encontra amplamente comprometida, a recompensa permanece praticamente nula. Esse comportamento indica que as observações degradadas se tornam previsíveis para a rede preditora do RND e deixam de produzir um sinal significativo de novidade.

Após a coleta do *medikit*, aproximadamente no instante 170, a precariedade retorna




Figura 18 – Evolução da recompensa intrínseca calculada pelo módulo RND após 200704 passos de treinamento e da precariedade perceptiva ao longo de um episódio com glaucoma de força 50. A estrela indica a coleta de um *medikit* e a consequente restauração da visão.

Fonte: Elaborada pelo autor.

ao valor mínimo e a recompensa intrínseca apresenta seu maior pico no episódio. À medida que o glaucoma volta a crescer, a recompensa diminui novamente, aproximando-se de zero quando a precariedade alcança seu nível máximo. A repetição desse padrão antes e depois da coleta evidencia uma relação inversa entre as duas variáveis.

O resultado constitui um indício direto do mecanismo proposto nesta dissertação. A coleta do recurso não recebe uma recompensa programada, mas restaura uma condição perceptiva que produz maior erro de predição e, consequentemente, maior recompensa intrínseca. Assim, a condição menos precária adquire maior valor para o aprendizado por meio de seus efeitos sobre a percepção. Embora esse gráfico isolado não seja suficiente para estabelecer uma relação causal geral, sua dinâmica é consistente com a hipótese de conversão da precariedade corporal em recompensa.

5.1.1.4 Análise Visual com Grad-CAM

A Figura 19 apresenta mapas de Grad-CAM, método discutido na Seção 2.2.5.1, para as três condições de recompensa sob glaucoma de força 50. A linha superior corresponde às políticas após 100352 passos e a inferior às políticas após 9633792 passos. As cores mais quentes indicam regiões com maior contribuição para a saída analisada da política, enquanto as mais frias indicam menor contribuição.

Na condição sem recompensa, os mapas inicial e final concentram as ativações nas porções inferiores da imagem e nas transições entre chão e paredes. O *medikit* à esquerda no estágio inicial e o recurso na parede direita no estágio final não coincidem com as regiões de maior intensidade. Esse padrão, possivelmente relacionado a características visuais de baixo nível,




Figura 19 – Mapas de Grad-CAM para as condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca calculada pelo RND, sob glaucoma de força 50. A linha superior apresenta as políticas após 100352 passos de treinamento, e a linha inferior apresenta as políticas após 9633792 passos. As regiões mais quentes possuem maior relevância para a saída analisada da política segundo o Grad-CAM. **Fonte:** Elaborada pelo autor.

como limites entre superfícies, texturas do chão e áreas próximas ao campo de deslocamento, é compatível com a ausência de evidências de que a política utilize os recursos para prolongar a sobrevivência.

Na condição com recompensa extrínseca, o mapa inicial se concentra em uma região vertical nas bordas da área escurecida pelo glaucoma, sem indicar direcionamento claro para os *medikits* e aparentemente respondendo ao contraste nos limites da degradação visual. No estágio final, há relevância tanto sobre o recurso na região inferior quanto sobre a parede direita. A parede pode ser importante para evitar que o agente caminhe contra uma superfície ou mantenha a visão direcionada apenas para ela, deixando de observar o restante do ambiente. A política parece, portanto, combinar informações sobre recursos e geometria da sala, o que é coerente com trajetórias que permitem coletar itens e sobreviver sem reproduzir precisamente todas as distribuições.

Na condição com recompensa intrínseca, o mapa inicial é difuso, sem uma região

dominante, e distribui relevância pelo corredor central, pelo chão e pela extremidade direita. No estágio final, as ativações tornam-se mais localizadas sobre elementos da parte inferior, incluindo um *medikit* próximo ao centro e um objeto visualmente saliente à direita. Essa mudança é compatível com uma política que passou a diferenciar elementos potencialmente relevantes.

A comparação sugere usos distintos das informações visuais. A condição sem recompensa permanece associada a regiões genéricas do cenário, a recompensa extrínseca combina elementos de navegação e áreas próximas aos recursos, e a condição intrínseca passa a concentrar-se em objetos da região imediatamente navegável. Esse padrão constitui evidência qualitativa de que a política com recompensa intrínseca não responde apenas à degradação global, mas também utiliza estruturas espaciais e objetos da observação.

5.1.2 Glaucoma de Força 100

5.1.2.1 Duração Média dos Episódios

A Figura 20 apresenta a evolução da duração média dos episódios para as três condições de recompensa sob glaucoma de força 100. Assim como na análise anterior, as linhas representam as médias entre as sementes experimentais e as regiões sombreadas mostram a dispersão correspondente a um desvio padrão.

Na condição sem recompensa, a duração dos episódios se mantém próxima de 500 *ticks* durante praticamente todo o treinamento. A pequena variação observada não se transforma em uma tendência sustentada de crescimento, indicando novamente que a ausência de um sinal de reforço não permite ao agente aprender uma política capaz de coletar recursos e prolongar sua permanência no ambiente.

Com a recompensa extrínseca, a duração cresce rapidamente durante o primeiro milhão de passos, ultrapassando 1500 *ticks*. O crescimento continua de forma mais gradual até aproximadamente 3 milhões de passos, quando a curva se aproxima de 1900 a 2000 *ticks*. A variabilidade entre as sementes é elevada nas etapas iniciais, mas diminui à medida que as execuções convergem para episódios próximos da duração máxima. Esse resultado indica que, mesmo com a degradação mais rápida produzida pela força 100, os agentes aprendem a coletar *medikits* quando essa ação é diretamente recompensada.

Na condição com recompensa intrínseca calculada pelo RND, a duração permanece próxima de 500 *ticks* durante aproximadamente o primeiro milhão de passos. Entre 1 e 3 milhões




Figura 20 – Duração média dos episódios ao longo do treinamento nas condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca calculada pelo RND, sob glaucoma de força 100. As regiões sombreadas representam a variabilidade entre as sementes experimentais.

Fonte: Elaborada pelo autor.

de passos, observa-se um crescimento acentuado, acompanhado por uma faixa de desvio padrão mais ampla, o que indica diferenças na velocidade de aprendizado entre as sementes. Após esse período, a duração continua aumentando gradualmente e se aproxima da condição extrínseca entre 6 e 7 milhões de passos. Ao final do treinamento, ambas alcançam valores próximos de 2000 *ticks*. Portanto, embora o aprendizado orientado pela recompensa intrínseca seja mais lento, seus resultados finais mostram que o agente consegue desenvolver uma política de sobrevivência sem receber recompensa direta pela coleta de recursos.

5.1.2.2 Análise das Trajetórias

A Figura 21 apresenta as trajetórias obtidas nas quatro distribuições de *medikits*. Os episódios de avaliação foram executados com as políticas salvas após 9 533 440 passos de treinamento. Esse checkpoint está próximo do orçamento total de 10 milhões de passos e corresponde a uma etapa na qual o desempenho das condições extrínseca e intrínseca já havia alcançado valores elevados e relativamente estáveis. Dessa forma, as trajetórias permitem examinar políticas em estágio avançado de treinamento, reduzindo a influência de comportamentos transitórios das etapas iniciais.




Figura 21 – Trajetórias produzidas pelas políticas salvas após 9 533 440 passos de treinamento nas distribuições em quadrado, círculo, seno e *grid*, sob as condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca calculada pelo RND, para glaucoma de força 100.

Fonte: Elaborada pelo autor.

Os agentes sem recompensa repetem trajetórias curtas nas quatro distribuições, deslocando-se da posição inicial até uma região próxima à extremidade do ambiente. A semelhança entre esses percursos, apesar da alteração na posição dos recursos, indica que a política não responde à organização dos *medikits*. Esse padrão é coerente com a baixa duração média dos episódios observada durante o treinamento.

Com recompensa extrínseca, os deslocamentos tornam-se extensos. A distribuição circular apresenta a correspondência mais clara entre trajetória e posição dos recursos. Nas distribuições em quadrado e seno, os agentes percorrem grandes polígonos que alcançam diferentes regiões do ambiente, mas não reproduzem precisamente os arranjos. Na distribuição em *grid*, as trajetórias concentram-se principalmente na região central. Apesar dessas diferenças, a elevada duração dos episódios indica que os percursos permitem coletar recursos suficientes para sustentar o agente. A força 100 compromete a visão mais rapidamente, de modo que a perda de *medikits* próximos do campo visual constitui uma possível explicação para movimentos amplos e menos aderentes às distribuições.

As políticas treinadas com recompensas intrínsecas calculadas pelo RND também produzem trajetórias extensas. Na distribuição circular, os percursos formam um contorno aproximadamente circular. Nas demais distribuições, predominam movimentos amplos próximos às regiões externas do ambiente, com menor correspondência à geometria exata dos recursos. Ainda assim, as trajetórias diferem entre os arranjos e não reproduzem uma única estratégia fixa. Em conjunto com a duração média próxima de 2000 *ticks*, esse resultado indica que os agentes conseguem encontrar *medikits* mesmo quando a degradação perceptiva dificulta uma navegação diretamente orientada para cada recurso visível.

5.1.2.3 Relação entre Recompensa Intrínseca e Precariedade

A Figura 22 apresenta a relação entre recompensa intrínseca e precariedade perceptiva para o glaucoma de força 100. As recompensas foram calculadas pelo módulo RND após 200704 passos de treinamento. A escolha desse checkpoint inicial facilita a observação do mecanismo porque o agente ainda coleta *medikits* com menor frequência. Dessa forma, o episódio apresenta tanto um período suficientemente longo de degradação perceptiva quanto uma coleta posterior, permitindo comparar a recompensa intrínseca antes e depois da restauração da visão. Em checkpoints mais tardios, a maior capacidade de coleta tende a interromper o avanço do glaucoma com maior frequência, tornando menos evidente a relação temporal entre as duas

variáveis.




Figura 22 – Evolução da recompensa intrínseca calculada pelo módulo RND após 200 704 passos de treinamento e da precariedade perceptiva ao longo de um episódio com glaucoma de força 100. A estrela indica a coleta de um *medikit* e a consequente restauração da visão.

Fonte: Elaborada pelo autor.

No início do episódio, o glaucoma alcança seu nível máximo aproximadamente no instante 70, mais rapidamente do que na condição de força 50. Durante esse crescimento, a recompensa intrínseca diminui progressivamente até atingir valores próximos de zero. Enquanto a precariedade permanece máxima, a recompensa também permanece praticamente nula.

Próximo ao instante 200, a coleta de um *medikit* restaura a visão e produz uma elevação abrupta da recompensa intrínseca, que alcança o maior valor do episódio. Em seguida, conforme a precariedade volta a crescer, a recompensa diminui novamente e retorna a valores próximos de zero por volta do instante 270. A maior força do glaucoma reduz, portanto, o intervalo durante o qual a observação restaurada permanece pouco degradada e capaz de produzir recompensa elevada.

O padrão observado reforça a relação inversa identificada na força 50. Estados de elevada precariedade estão associados a recompensas intrínsecas reduzidas, enquanto a restauração da percepção após a coleta de um recurso produz um aumento imediato do erro de predição do RND. Esse resultado constitui mais um indício de que a condição corporal simulada modifica o sinal utilizado pelo aprendizado. A repetição do padrão em diferentes forças de glaucoma fortalece a hipótese de que a precariedade perceptiva está sendo convertida em recompensa.

5.1.2.4 Análise Visual com Grad-CAM

A Figura 23 apresenta mapas de Grad-CAM, método discutido na Seção 2.2.5.1, para as três condições de recompensa sob glaucoma de força 100. A linha superior corresponde às políticas após 100352 passos e a inferior às políticas após 9533440 passos. As cores mais quentes indicam regiões com maior contribuição para a saída analisada da política.




Figura 23 – Mapas de Grad-CAM para as condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca calculada pelo RND, sob glaucoma de força 100. A linha superior apresenta as políticas após 100352 passos de treinamento, e a linha inferior apresenta as políticas após 9533440 passos. As regiões mais quentes possuem maior relevância para a saída analisada da política segundo o Grad-CAM.

Fonte: Elaborada pelo autor.

Na condição sem recompensa, o mapa inicial distribui relevância por grande parte da região inferior, com maior intensidade sobre a parede e o chão à esquerda, enquanto a área central obstruída pelo glaucoma recebe baixa ativação. No estágio final, o foco torna-se mais localizado junto à borda superior da região escurecida e a uma transição entre paredes. A permanência das ativações sobre contrastes, superfícies e limites do glaucoma, sem concentração clara em recursos, é compatível com uma política que não desenvolveu comportamento consistente de coleta.

Na condição com recompensa extrínseca, o mapa inicial destaca principalmente a região inferior central e o chão imediatamente navegável. O *medikit* visível à direita não corresponde ao ponto de maior intensidade. No estágio final, as ativações tornam-se mais amplas e se concentram sobre a parede esquerda, a passagem central e a borda do glaucoma. A região destacada também contém elementos relevantes para a coleta e para a orientação espacial, sugerindo que a política combina informações sobre recursos, superfícies navegáveis e paredes para evitar bloqueios e manter o deslocamento pelo ambiente.

Na condição com recompensa intrínseca, o mapa inicial apresenta um foco intenso e localizado próximo à borda superior esquerda do glaucoma, sem direcionamento evidente para o *medikit* visível na parede direita. Após o treinamento, a relevância se distribui pelas duas laterais da observação, nas quais aparecem partes de *medikits*. A região esquerda, que contém uma porção de um recurso, recebe a maior ativação, enquanto o *medikit* parcialmente visível à direita também é destacado. Esse padrão sugere que a política passou a atribuir relevância aos recursos e aos limites da sala, em vez de responder predominantemente ao contraste produzido pela degradação perceptiva.

Em comparação com a força 50, os mapas iniciais da força 100 apresentam influência mais evidente das bordas do glaucoma, coerente com a degradação mais rápida da observação. Nos estágios finais, as condições extrínseca e intrínseca passam a distribuir relevância por elementos do ambiente que podem auxiliar tanto a coleta quanto a navegação, enquanto a condição sem recompensa permanece associada principalmente a características genéricas do cenário e aos limites da obstrução visual.

5.1.3 Glaucoma de Força 200

5.1.3.1 Duração Média dos Episódios

A Figura 24 apresenta a evolução da duração média dos episódios para as três condições de recompensa sob glaucoma de força 200. As linhas correspondem às médias entre as sementes experimentais, enquanto as regiões sombreadas representam a dispersão de um desvio padrão.

Na condição sem recompensa, a duração permanece próxima de 500 *ticks* ao longo de todo o treinamento. A estabilidade da curva indica que as pequenas variações entre as execuções não correspondem a uma melhoria sistemática da capacidade de sobrevivência. Assim como nas




Figura 24 – Duração média dos episódios ao longo do treinamento nas condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca calculada pelo RND, sob glaucoma de força 200. As regiões sombreadas representam a variabilidade entre as sementes experimentais.

Fonte: Elaborada pelo autor.

forças anteriores, a ausência de um sinal de reforço impede o desenvolvimento de uma política capaz de coletar recursos de forma consistente.

Com recompensa extrínseca, a duração aumenta rapidamente entre 1 e 3 milhões de passos, alcançando aproximadamente 1700 *ticks*. A partir desse ponto, o crescimento torna-se gradual, e a curva se aproxima de 2000 *ticks* ao final do treinamento. A faixa de desvio padrão é mais ampla durante a fase inicial de aprendizado e diminui conforme as sementes convergem. Esse resultado mostra que os agentes conseguem aprender a coletar *medikits* e prolongar sua permanência no ambiente mesmo quando a força 200 produz uma degradação perceptiva muito rápida.

Na condição com recompensa intrínseca calculada pelo RND, o crescimento ocorre mais lentamente. A duração aumenta de maneira acentuada entre aproximadamente 1,5 e 3,5 milhões de passos, quando ultrapassa 1500 *ticks*. Em seguida, continua crescendo de forma gradual, com oscilações entre 6 e 8 milhões de passos, até se aproximar de 1900 *ticks*. Embora permaneça ligeiramente abaixo da recompensa extrínseca ao final do treinamento, a condição intrínseca apresenta episódios muito mais longos do que a condição sem recompensa. Isso indica que o sinal calculado pelo RND continua sendo suficiente para favorecer uma política de sobrevivência mesmo sob a intensidade mais elevada de glaucoma analisada.

5.1.3.2 Análise das Trajetórias

A Figura 25 apresenta as trajetórias produzidas nas quatro distribuições de *medikits*. Os episódios de avaliação foram executados com as políticas salvas após 9533440 passos de treinamento. Esse checkpoint corresponde a um estágio próximo do limite de 10 milhões de passos e posterior à fase principal de crescimento das curvas de duração dos episódios. Assim, a análise se concentra no comportamento desenvolvido em uma etapa avançada do aprendizado, quando as políticas já haviam sido expostas a uma quantidade ampla de experiências sob a degradação perceptiva mais intensa.

Os agentes sem recompensa realizam percursos curtos e pouco relacionados à disposição dos recursos. Nas distribuições em quadrado, círculo e seno, as trajetórias se limitam a pequenos arcos iniciados no centro do ambiente. Na distribuição em *grid*, observa-se um movimento circular igualmente restrito. A alteração do percurso não acompanha as diferentes organizações dos *medikits* e não produz coleta suficiente para aumentar a duração dos episódios.

Com recompensa extrínseca, os agentes percorrem regiões amplas do ambiente. A distribuição circular apresenta novamente a maior correspondência entre as trajetórias e a posição dos recursos. Nas distribuições em quadrado e *grid*, os percursos formam contornos extensos que interceptam diferentes *medikits*, embora não reproduzam exatamente os arranjos. Na distribuição em seno, as trajetórias alcançam parte da curva formada pelos recursos, mas também atravessam regiões externas. A elevada duração média dos episódios indica que esses deslocamentos permitem coletar recursos suficientes, apesar da baixa aderência à geometria de algumas distribuições.

As políticas treinadas com recompensas intrínsecas calculadas pelo RND também produzem trajetórias extensas, mas predominantemente poligonais e próximas aos limites do ambiente. Na distribuição circular, os percursos contornam grande parte dos recursos, ainda que de maneira menos regular do que na condição extrínseca. Nas demais distribuições, a correspondência com a disposição dos *medikits* é limitada. Ainda assim, as diferenças entre os percursos e a duração média próxima de 1900 *ticks* mostram que os agentes conseguem interceptar recursos e manter-se no ambiente. Uma possível explicação para a menor precisão espacial é que, sob glaucoma de força 200, os *medikits* deixam rapidamente de ser visíveis, favorecendo estratégias de deslocamento amplo que aumentam a probabilidade de encontrá-los durante o percurso.




Figura 25 – Trajetórias produzidas pelas políticas salvas após 9 533 440 passos de treinamento nas distribuições em quadrado, círculo, seno e *grid*, sob as condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca calculada pelo RND, para glaucoma de força 200.

Fonte: Elaborada pelo autor.

5.1.3.3 Relação entre Recompensa Intrínseca e Precariedade

A Figura 26 apresenta a evolução conjunta da recompensa intrínseca e da precariedade perceptiva sob glaucoma de força 200. As recompensas foram calculadas pelo módulo RND após 200 704 passos de treinamento. Esse estágio inicial foi utilizado para que o episódio incluísse períodos prolongados sem coleta, nos quais a degradação perceptiva pudesse alcançar seu nível máximo, e um evento posterior de coleta que permitisse observar a restauração da visão. Como o agente ainda não havia aprendido a encontrar recursos com elevada frequência, o contraste entre os estados anteriores e posteriores à coleta torna-se mais claro. Em políticas mais avançadas, a sucessão de coletas reduziria a duração desses intervalos e dificultaria a análise isolada do efeito de cada *medikit*.




Figura 26 – Evolução da recompensa intrínseca calculada pelo módulo RND após 200 704 passos de treinamento e da precariedade perceptiva ao longo de um episódio com glaucoma de força 200. A estrela indica a coleta de um *medikit* e a consequente restauração da visão.

Fonte: Elaborada pelo autor.

No início do episódio, a precariedade alcança seu nível máximo aproximadamente no instante 35. Durante esse intervalo, a recompensa intrínseca apresenta uma elevação inicial e, em seguida, diminui até atingir valores próximos de zero. A recompensa permanece praticamente nula enquanto a visão está totalmente degradada, indicando que essas observações produzem pouco erro de predição para o RND.

Próximo ao instante 162, a coleta de um *medikit* restaura a visão e produz o maior pico de recompensa intrínseca do episódio. Após a restauração, a precariedade volta a crescer rapidamente e alcança novamente o nível máximo por volta do instante 198. No mesmo intervalo, a recompensa diminui progressivamente até retornar a valores próximos de zero. Em comparação com as forças 50 e 100, o período durante o qual a observação permanece pouco degradada é ainda menor.

O resultado mantém o padrão observado nas demais intensidades de glaucoma. A

restauração da visão está associada a um aumento abrupto da recompensa intrínseca, enquanto a degradação perceptiva reduz esse sinal. Na força 200, porém, a rápida perda de visão limita temporalmente a oportunidade de obter recompensas elevadas após a coleta. A reprodução dessa relação inversa na intensidade mais extrema analisada reforça o indício de que a precariedade perceptiva modifica sistematicamente a recompensa calculada pelo RND.

5.1.3.4 Análise Visual com Grad-CAM

A Figura 27 apresenta mapas de Grad-CAM, método discutido na Seção 2.2.5.1, para as três condições de recompensa sob glaucoma de força 200. A linha superior corresponde às políticas após 100352 passos e a inferior às políticas após 9533440 passos. As cores mais quentes indicam regiões com maior contribuição para a saída analisada da política.




Figura 27 – Mapas de Grad-CAM para as condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca calculada pelo RND, sob glaucoma de força 200. A linha superior apresenta as políticas após 100352 passos de treinamento, e a linha inferior apresenta as políticas após 9533440 passos. As regiões mais quentes possuem maior relevância para a saída analisada da política segundo o Grad-CAM. **Fonte:** Elaborada pelo autor.

Na condição sem recompensa, os mapas inicial e final distribuem relevância por regiões amplas do chão, das paredes e das bordas do glaucoma. No estágio final, a maior ativação

permanece próxima à área escurecida e às transições entre superfícies, sem concentração clara sobre recursos. Esse padrão é compatível com uma política que responde a características genéricas do cenário e não desenvolve uma estratégia consistente de coleta.

Na condição com recompensa extrínseca, o mapa inicial destaca a passagem central e a borda inferior da região obstruída. Após o treinamento, a ativação se distribui principalmente pela parede direita, pelo chão e pela parte superior da observação, enquanto o *medikit* parcialmente visível não constitui isoladamente o principal foco. Esse padrão sugere que a política atribui maior relevância a referências que auxiliam na navegação, como paredes, limites entre superfícies e a região do céu, do que diretamente aos recursos. Sob glaucoma de força 200, orientar-se enquanto a visão ainda está disponível é especialmente importante, pois a degradação rápida pode impedir a identificação posterior dos *medikits*. A utilização da geometria do ambiente pode, portanto, ajudar o agente a manter uma direção de deslocamento e alcançar regiões nas quais os recursos provavelmente serão encontrados.

Na condição com recompensa intrínseca, o mapa inicial concentra-se na lateral esquerda e na borda do glaucoma. No estágio final, a ativação torna-se extensa e abrange a parte superior da observação, as paredes e os limites da região degradada, enquanto o recurso parcialmente visível à direita recebe menor relevância. Assim como na condição extrínseca, o foco parece estar menos nos *medikits* individualmente e mais nas referências espaciais que permitem ao agente orientar seu movimento antes que a visão seja amplamente comprometida. A estrutura do céu, das paredes e das passagens pode fornecer uma direção geral para alcançar novas regiões do ambiente, aumentando a possibilidade de interceptar recursos mesmo quando eles deixam de ser diretamente visíveis. Esse comportamento é compatível com trajetórias amplas e pouco aderentes às distribuições, mas ainda capazes de prolongar a sobrevivência.

Em comparação com as forças 50 e 100, a força 200 produz mapas mais dominados por regiões amplas, pela área escurecida e por referências estruturais do cenário. Tanto na condição extrínseca quanto na intrínseca, céu, paredes, chão e passagens parecem exercer maior influência do que os *medikits* isoladamente. Essa diferença indica que a perda rapidamente iminente da visão altera a estratégia visual da política. Em vez de depender apenas da identificação precisa dos recursos, o agente utiliza a geometria disponível para se orientar em direção a regiões onde poderá encontrá-los. Dessa forma, a navegação baseada na estrutura geral do ambiente pode compensar parcialmente a curta janela durante a qual os *medikits* permanecem visíveis.

5.1.4 Glaucoma de Força 0

A condição de força 0 é analisada por último por constituir uma ablação do mecanismo proposto. Nessa configuração, o agente mantém a visão inalterada durante todo o episódio, de modo que a ausência de coleta de *medikits* não produz degradação perceptiva e a coleta não restaura qualquer capacidade visual. O RND continua calculando recompensas intrínsecas a partir das observações, mas essas recompensas deixam de estar acopladas à manutenção da condição perceptiva do agente. Essa condição permite avaliar se a curiosidade, isoladamente, é suficiente para produzir uma política de sobrevivência ou se a precariedade é necessária para relacionar a coleta de recursos à continuidade da obtenção de recompensa intrínseca.

5.1.4.1 Duração Média dos Episódios

A Figura 28 apresenta a evolução da duração média dos episódios na ausência de glaucoma. As linhas representam as médias entre as sementes experimentais e as regiões sombreadas correspondem à dispersão de um desvio padrão.




Figura 28 – Duração média dos episódios ao longo do treinamento nas condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca calculada pelo RND, sob glaucoma de força 0. As regiões sombreadas representam a variabilidade entre as sementes experimentais.

Fonte: Elaborada pelo autor.

Na condição sem recompensa, a duração aumenta apenas no início do treinamento e

se estabiliza próxima de 480 *ticks*. Esse comportamento é semelhante ao observado nas demais forças e confirma que o PPO não desenvolve uma política de sobrevivência quando não recebe um sinal capaz de distinguir ações ou estados relevantes para a tarefa.

Com recompensa extrínseca, a duração cresce rapidamente e alcança o limite de 2100 *ticks* antes de 1 milhão de passos. A curva permanece estável nesse nível durante praticamente todo o restante do treinamento, com baixa variabilidade entre as sementes. Esse é o aprendizado mais rápido entre as forças analisadas, o que é compatível com a ausência de degradação visual. Como o agente mantém acesso integral às observações e recebe recompensa direta pela coleta, pode localizar os *medikits* e aprender a utilizá-los sem enfrentar a perda progressiva de informação perceptiva presente nas demais condições.

O comportamento da condição com recompensa intrínseca é substancialmente diferente. A duração inicialmente se aproxima de 500 *ticks*, mas não apresenta a transição consistente para episódios próximos do limite máximo observada nas forças 50, 100 e 200. A média cresce lentamente após aproximadamente 3,5 milhões de passos e alcança cerca de 900 *ticks* ao final do treinamento. Entretanto, esse aumento é acompanhado por uma faixa de desvio padrão muito ampla, especialmente após 4 milhões de passos. A elevada dispersão indica que o resultado não é reproduzido de forma consistente entre as sementes e que parte das execuções permanece próxima ao desempenho da condição sem recompensa.

Portanto, o crescimento da média não deve ser interpretado como evidência de uma política robusta de sobrevivência. Sem glaucoma, o RND ainda incentiva a exploração de observações novas, e essa exploração pode levar algumas execuções a encontrar *medikits* incidentalmente ou a desenvolver padrões de movimento que prolonguem parcialmente os episódios. Contudo, não existe um mecanismo que atribua valor específico à manutenção da visão, pois ela nunca é perdida. A diferença em relação às forças positivas de glaucoma está tanto no desempenho final quanto na reprodutibilidade. Com precariedade perceptiva, as sementes convergem para episódios longos. Sem precariedade, o ganho é limitado e altamente dependente da semente.

5.1.4.2 Análise das Trajetórias

A Figura 29 apresenta as trajetórias produzidas nas quatro distribuições de *medikits*. Os episódios de avaliação foram executados com as políticas salvas após 9 132 032 passos de treinamento. Esse checkpoint representa uma política em estágio avançado e próximo do

orçamento total de treinamento. Sua utilização permite verificar se, mesmo após milhões de interações, a ausência de precariedade ainda impede a emergência de uma estratégia consistente na condição com recompensa intrínseca. O ponto analisado não pressupõe que todas as condições tenham convergido, mas permite examinar o comportamento adquirido em uma etapa tardia do treinamento.

Os agentes treinados sem recompensa realizam deslocamentos muito curtos a partir da posição inicial. As trajetórias são semelhantes nas quatro distribuições e terminam antes de alcançar a maior parte dos recursos. Esse resultado é coerente com a duração média próxima de 480 *ticks* e não apresenta evidências de que a política utilize a disposição dos *medikits* para orientar suas ações.

A condição com recompensa extrínseca apresenta um contraste claro. Na distribuição em quadrado, as trajetórias acompanham os quatro lados formados pelos recursos. Na distribuição circular, os agentes percorrem o contorno do círculo. Na distribuição em seno, os caminhos reproduzem a curva com elevada proximidade. Na distribuição em *grid*, as trajetórias percorrem principalmente o perímetro do arranjo, interceptando sucessivos *medikits*. A correspondência entre os caminhos e as diferentes geometrias mostra que a arquitetura e o algoritmo são capazes de aprender políticas sensíveis à organização espacial dos recursos quando o sinal de recompensa fornece diretamente essa orientação. Esse resultado também afasta a possibilidade de que o baixo desempenho da condição intrínseca seja explicado apenas por limitações do ambiente, do espaço de ações ou da rede utilizada.

Nas políticas treinadas com recompensas intrínsecas calculadas pelo RND, os agentes permanecem praticamente imóveis nas quatro distribuições. Os pequenos deslocamentos próximos à posição inicial não acompanham os recursos e são insuficientes para caracterizar uma estratégia de busca. Além disso, a semelhança das trajetórias diante de arranjos distintos indica que a política avaliada não utiliza a organização espacial dos *medikits* para orientar seu comportamento. Esse resultado ajuda a interpretar a elevada variabilidade observada no gráfico de duração. Ainda que algumas sementes possam alcançar episódios mais longos, a política representada na análise comportamental não desenvolve uma estratégia consistente de coleta.

A comparação com as forças positivas de glaucoma é central para a hipótese do trabalho. Quando há degradação perceptiva, deixar de coletar recursos compromete progressivamente as observações e reduz a recompensa intrínseca disponível. A coleta restaura a visão e cria uma consequência relevante para o mecanismo de curiosidade. Na força 0, a percepção




Figura 29 – Trajetórias produzidas pelas políticas salvas após 9 132 032 passos de treinamento nas distribuições em quadrado, círculo, seno e *grid*, sob as condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca calculada pelo RND, para glaucoma de força 0.

Fonte: Elaborada pelo autor.

permanece preservada independentemente das ações do agente. Assim, coletar ou ignorar um *medikit* não altera sua capacidade futura de perceber novidades. O recurso deixa de participar da dinâmica da recompensa intrínseca, e a curiosidade não se converte de maneira confiável em comportamento de manutenção da viabilidade.

5.1.4.3 Relação entre Recompensa Intrínseca e Precariedade

A Figura 30 apresenta a recompensa intrínseca calculada pelo módulo RND após 301 056 passos de treinamento. Esse checkpoint inicial foi utilizado porque o agente ainda não coletava *medikits* com frequência, permitindo observar um intervalo prolongado sem coleta e um evento posterior de obtenção do recurso. Essa configuração facilita verificar se a coleta, por si só, produz alguma alteração sistemática na recompensa intrínseca. Diferentemente das forças positivas, entretanto, a ausência de coleta não causa degradação visual e a obtenção do recurso não restaura a percepção. Como a força do glaucoma é igual a 0, a precariedade permanece nula durante todo o episódio.




Figura 30 – Evolução da recompensa intrínseca calculada pelo módulo RND após 301 056 passos de treinamento e da precariedade perceptiva ao longo de um episódio com glaucoma de força 0. A estrela indica a coleta de um *medikit*.

Fonte: Elaborada pelo autor.

Ao contrário das condições com forças 50, 100 e 200, a linha de precariedade permanece constante no valor mínimo. A recompensa intrínseca continua apresentando oscilações porque o RND responde à novidade das observações produzidas durante a interação. Entretanto, essas variações não acompanham qualquer alteração da condição perceptiva, uma vez que a visão não se degrada nem é restaurada.

A coleta de um *medikit*, indicada aproximadamente no instante 218, não é seguida por um pico abrupto de recompensa. Os valores posteriores permanecem na mesma faixa de variação observada antes da coleta e chegam a diminuir imediatamente após o evento. Isso

contrasta com as forças positivas de glaucoma, nas quais a coleta restaura a visão e produz uma elevação clara do erro de predição. Na força 0, o *medikit* recupera a vida do agente, mas não transforma a observação visual por meio do mecanismo proposto. Consequentemente, o RND não recebe um sinal perceptivo que diferencie sistematicamente o instante posterior à coleta.

Esse resultado esclarece que a simples existência de recompensa intrínseca não é suficiente para orientar o agente à manutenção de sua viabilidade. O RND continua produzindo valores diferentes de zero, mas tais valores refletem novidades visuais gerais e não a necessidade de coletar recursos. Sem precariedade, não há perda de uma condição que precise ser restaurada e, portanto, não se estabelece a relação funcional entre manutenção corporal, percepção e curiosidade pretendida neste trabalho.

5.1.4.4 *Análise Visual com Grad-CAM*

A Figura 31 apresenta mapas de Grad-CAM, método discutido na Seção 2.2.5.1, para as três condições de recompensa sob glaucoma de força 0. A linha superior corresponde às políticas após 100352 passos e a inferior às políticas após 9132032 passos. As cores mais quentes indicam regiões com maior contribuição para a saída analisada da política.

Na condição sem recompensa, os mapas distribuem relevância por regiões amplas do cenário. No estágio inicial, as maiores ativações aparecem próximas à parede direita e às transições entre céu, paredes e chão. No estágio final, os focos permanecem associados às laterais e ao piso, sem concentração consistente sobre os *medikits* visíveis. Esse padrão é compatível com uma política guiada por características genéricas do ambiente e sem uma estratégia de coleta.

Na condição com recompensa extrínseca, o mapa inicial apresenta focos localizados sobre os *medikits* visíveis nas regiões central superior e inferior. Após o treinamento, o recurso próximo à parte inferior continua recebendo a maior ativação, enquanto outros itens presentes na observação também recebem relevância. Como não há degradação perceptiva, os recursos permanecem visíveis e podem ser utilizados diretamente para orientar as ações. Esse resultado é coerente com as trajetórias que acompanham as distribuições e com a rápida convergência para episódios de duração máxima.

Na condição com recompensa intrínseca, o mapa inicial é amplo e concentra-se principalmente no chão e nas paredes, sem um foco preciso sobre recursos. No estágio final, um *medikit* visível à direita recebe alguma relevância, mas a maior ativação permanece distribuída pela região inferior e pelas transições entre superfícies. Assim, embora a política seja capaz de




Figura 31 – Mapas de Grad-CAM para as condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca calculada pelo RND, sob glaucoma de força 0. A linha superior apresenta as políticas após 100 352 passos de treinamento, e a linha inferior apresenta as políticas após 9 132 032 passos. As regiões mais quentes possuem maior relevância para a saída analisada da política segundo o Grad-CAM. **Fonte:** Elaborada pelo autor.

utilizar partes da observação que contêm recursos, os mapas não indicam uma priorização visual tão clara quanto na condição extrínseca. Esse comportamento é compatível com as trajetórias curtas e com a ausência de aprendizado robusto de coleta.

A comparação é especialmente relevante porque, na força 0, nenhuma parte da observação é ocultada pelo glaucoma. A condição extrínseca demonstra que a arquitetura e o Grad-CAM conseguem produzir focos claros sobre os *medikits* quando esses itens estão diretamente associados à recompensa. Na condição intrínseca, porém, a manutenção da visão independe da coleta e os recursos não provocam uma transformação perceptiva relevante para o RND. A ausência de um foco consistente nos *medikits* reforça, portanto, que a curiosidade isolada não estabelece o mesmo vínculo entre percepção, coleta e sobrevivência observado nas condições com precariedade.

5.2 Síntese Comparativa dos Resultados

A comparação entre as forças 0, 50, 100 e 200 mostra que a variável de vida, isoladamente, não orienta o aprendizado. Seu valor apenas determina o encerramento do episódio e não é fornecido à política nem utilizado no cálculo da recompensa. Na condição sem recompensa, os agentes permanecem próximos de 500 *ticks* em todas as forças, o que indica que a possibilidade de morte não é suficiente para produzir uma política de manutenção. Com recompensa extrínseca, todas as forças alcançam durações próximas do limite de 2100 *ticks*, pois a permanência no ambiente e a coleta são diretamente valorizadas. A recompensa resolve a tarefa, mas também informa previamente a solução esperada.

A comparação mais importante ocorre entre as configurações intrínsecas. O PPO, a arquitetura, o RND e a definição da recompensa permanecem inalterados, enquanto apenas a força do glaucoma modifica a velocidade de deterioração do corpo perceptivo. Mesmo assim, as forças 50, 100 e 200 convergem para episódios próximos de 1900 a 2000 *ticks*, enquanto a força 0 apresenta menor desempenho e elevada variabilidade entre as sementes. As diferenças comportamentais não foram produzidas por uma nova regra de aprendizado nem por uma recompensa específica para cada força. Elas surgiram da alteração do corpo artificial e da forma como ele passou a se relacionar com o ambiente.

Esse contraste mostra como a curiosidade pode ser modulada por meio do corpo. Na força 0, coletar ou ignorar um *medikit* não modifica a percepção e, portanto, não altera de maneira sistemática a recompensa produzida pelo RND. Nas forças positivas, permanecer sem coletar degrada a visão, torna as observações mais pobres e reduz a recompensa intrínseca. A coleta restaura a percepção e produz um aumento do erro de predição. Desse modo, o *medikit* deixa de ser apenas um objeto presente no cenário e adquire significado funcional por recuperar uma condição necessária à continuidade da exploração.

As trajetórias e os mapas de Grad-CAM reforçam que corpos perceptivos diferentes favorecem comportamentos distintos. Com o aumento da força do glaucoma, as políticas passam de uma navegação mais orientada pela posição visível dos recursos para estratégias mais amplas, apoiadas também em paredes, chão, céu e limites da obstrução. Esse resultado é consistente com a perspectiva apresentada por Nogueira *et al.* (2020) e Nogueira *et al.* (2016), segundo a qual alterações no corpo, na percepção e no ambiente modificam as regularidades disponíveis ao agente e os comportamentos que podem emergir.

Se o único objetivo fosse resolver a tarefa, a recompensa extrínseca seria uma

solução mais direta. A contribuição da proposta está em mostrar que um mecanismo geral de curiosidade pode ser orientado pela construção do corpo e do ambiente, sem alterar o algoritmo de aprendizado ou introduzir recompensas específicas para os comportamentos desejados nas diferentes forças. Em vez de informar ao agente que deve coletar recursos, o experimento cria condições nas quais a coleta modifica sua própria capacidade de continuar percebendo e obtendo novidade.

Essa dinâmica oferece uma aproximação limitada à ideia de autoconstrução. O agente não produz seus componentes, não define seus limites de viabilidade e não realiza autopoiese. Contudo, precisa agir para recuperar uma capacidade corporal que se deteriora ao longo do tempo. Nas configurações avaliadas, essa exigência de reconstrução funcional foi suficiente para favorecer políticas de sobrevivência e constitui um pequeno passo experimental na direção de agentes cujo comportamento dependa das consequências de suas ações sobre sua própria condição.

6 CONCLUSÃO

Este trabalho investigou uma forma de aproximar a ideia de autoconstrução dos sistemas vivos ao Aprendizado por Reforço Profundo. Para isso, foi proposta uma configuração experimental que relaciona precariedade perceptiva, curiosidade artificial e manutenção de um corpo artificial. A vida do agente funcionou apenas como uma variável de controle responsável por encerrar o episódio quando seu valor chegava a zero. Ela não foi fornecida à política, não participou do cálculo da recompensa e não informou diretamente o comportamento que deveria ser aprendido. Na condição intrínseca, a coleta de *medikits* também não recebeu recompensa específica. Seu efeito relevante para o aprendizado ocorreu por meio da restauração da percepção e da consequente modificação das observações processadas pelo RND.

Os resultados permitem responder positivamente à questão central dentro do escopo das configurações avaliadas. Nas forças de glaucoma 50, 100 e 200, os agentes treinados apenas com recompensa intrínseca aprenderam políticas capazes de alcançar episódios longos e próximos da duração obtida com recompensa extrínseca. Esse comportamento não ocorreu de maneira consistente na condição sem glaucoma. Com força 0, a recompensa produzida pelo RND continuou incentivando a exploração, mas permaneceu desacoplada da manutenção da percepção. O desempenho final foi menor, apresentou maior variabilidade entre as sementes e não resultou em uma estratégia clara de coleta na política analisada.

A comparação entre as condições de controle foi essencial para essa interpretação. A ausência de recompensa confirmou que o algoritmo não aprende sistematicamente a prolongar a sobrevivência sem um sinal de orientação. A recompensa extrínseca demonstrou que a arquitetura, o espaço de ações e a tarefa permitem aprender a coleta de recursos quando esse comportamento é valorizado diretamente. A condição intrínseca com glaucoma mostrou que parte desse comportamento também pode emergir quando a recompensa está relacionada às consequências perceptivas da precariedade, em vez de estar diretamente associada aos *medikits*.

Se o único objetivo fosse obter o maior desempenho possível na tarefa, a recompensa extrínseca constituiria uma solução mais simples e direta. A contribuição da proposta está em outro ponto. Nas comparações entre forças de glaucoma, o PPO, o RND, a arquitetura e a definição da recompensa intrínseca permaneceram inalterados. O que mudou foi o corpo perceptivo e a velocidade de sua deterioração. Os comportamentos distintos observados entre as forças indicam que a curiosidade pode ser modulada por meio das condições corporais e ambientais, sem exigir uma nova regra de aprendizado ou uma recompensa específica para cada

comportamento desejado.

A relação temporal entre recompensa intrínseca e precariedade forneceu o indício mais direto do funcionamento do mecanismo. Nas forças positivas, o avanço do glaucoma foi acompanhado pela redução da recompensa do RND. A coleta de um recurso restaurou a visão e produziu um aumento abrupto do erro de predição, seguido por nova redução conforme a degradação perceptiva retornava. Na força 0, a coleta não modificou a percepção e também não produziu uma alteração sistemática na recompensa intrínseca. Dessa forma, os resultados mostram que a relevância dos recursos dependeu da transformação que eles produziram na condição do agente.

As trajetórias e os mapas de Grad-CAM complementaram essa conclusão. As políticas com recompensa apresentaram deslocamentos mais extensos e sensíveis ao ambiente do que as políticas sem recompensa. À medida que a força do glaucoma aumentou, as trajetórias se tornaram menos aderentes à geometria exata dos recursos e mais associadas a estratégias gerais de navegação. Os mapas de Grad-CAM indicaram uma mudança semelhante. Com a visão preservada, os *medikits* puderam receber relevância mais localizada. Sob degradação intensa, paredes, chão, céu, passagens e limites da obstrução assumiram maior importância, pois forneciam referências para o deslocamento antes que a percepção fosse amplamente comprometida.

Em termos conceituais, a precariedade tornou o ambiente significativo para o agente. O *medikit* deixou de ser apenas um elemento visual disponível no cenário e adquiriu significado funcional por restaurar uma condição necessária à continuidade da percepção e da exploração. Esse significado não foi atribuído ao objeto de forma isolada. Ele surgiu da relação entre o recurso, a organização artificial do agente e as consequências da coleta sobre sua experiência futura. O resultado se aproxima da perspectiva enativa adotada como inspiração teórica, segundo a qual a relevância emerge do acoplamento entre agente e ambiente.

As diferenças produzidas pelas forças de glaucoma também são consistentes com os trabalhos de Nogueira *et al.* (2020) e Nogueira *et al.* (2016). Esses estudos mostram que mudanças na energia, na percepção, no corpo e no ambiente alteram as possibilidades de comportamento disponíveis ao agente. Nesta dissertação, a modificação da velocidade de degradação perceptiva produziu diferenças na aprendizagem e na navegação mesmo com a manutenção do mecanismo de curiosidade.

Essa aproximação deve ser compreendida de forma restrita. O agente desenvolvido não é autopoietico, não produz sua própria organização e não determina autonomamente suas

condições de viabilidade. O glaucoma, o RND, a arquitetura e a dinâmica de restauração foram definidos pelo projetista. A proposta também não elimina a recompensa do processo de aprendizagem. Sua contribuição consiste em deslocar a orientação do comportamento de uma recompensa que descreve diretamente a solução para um sinal que depende da relação entre condição interna, percepção, história de experiências e ambiente.

6.1 Contribuições do Trabalho

A principal contribuição deste trabalho é a construção de um mecanismo computacional que relaciona precariedade perceptiva e curiosidade artificial. A proposta permite investigar como uma condição corporal pode modificar a percepção e, por consequência, alterar a recompensa intrínseca utilizada pelo aprendizado. Essa formulação oferece uma alternativa experimental à atribuição direta de valor para a ação de coletar recursos.

Essa contribuição representa um deslocamento da engenharia da recompensa para a construção das condições corporais e ambientais. Depois de definido o mecanismo geral de curiosidade, diferentes comportamentos podem ser investigados por meio de alterações no corpo perceptivo sem modificar o PPO ou introduzir recompensas específicas para cada força de glaucoma. O trabalho mostra, assim, uma forma de orientar a curiosidade por meio do corpo do personagem.

Outra contribuição é a organização de uma configuração controlada com condições sem recompensa, com recompensa extrínseca e com recompensa intrínseca. A inclusão da força 0 como ablação permitiu distinguir os efeitos gerais da curiosidade dos efeitos produzidos por seu acoplamento à precariedade. A avaliação de diferentes forças de glaucoma também mostrou que o mecanismo permanece funcional sob velocidades distintas de degradação, embora intensidades maiores tornem o aprendizado mais lento e a navegação menos precisa.

O trabalho também contribui ao combinar medidas quantitativas e qualitativas. A duração média dos episódios permitiu comparar sobrevivência e estabilidade entre sementes. As trajetórias mostraram como as políticas respondiam a diferentes distribuições espaciais dos recursos. A análise temporal da recompensa permitiu observar o efeito imediato da degradação e da restauração da visão. O Grad-CAM forneceu indícios sobre as regiões utilizadas pelas políticas durante a tomada de decisão. Em conjunto, essas análises reduziram a dependência de uma única métrica e ofereceram uma interpretação mais ampla do comportamento aprendido.

Por fim, os resultados oferecem evidências experimentais de que a curiosidade pode

favorecer comportamentos de manutenção quando está vinculada a uma condição que precisa ser preservada. Nas configurações avaliadas, a precariedade transformou a coleta em uma ação relevante sem que uma recompensa específica fosse atribuída ao recurso, à sobrevivência ou à restauração da visão.

Essa contribuição deve ser compreendida como um passo limitado na direção da autonomia artificial. O trabalho não resolve o problema da autonomia nem implementa autopoiese, autonomia constitutiva ou adaptatividade em sentido forte. Ele investiga como uma exigência simplificada de reconstrução funcional pode ser incorporada ao Aprendizado por Reforço e modificar o comportamento aprendido.

6.2 Limitações

Os resultados estão limitados à tarefa *Health-Gathering* e à dinâmica específica implementada no VizDoom. O ambiente possui uma única sala, espaço de ações reduzido, regras fixas de perda de vida e apenas um tipo principal de recurso. Não é possível afirmar que o mecanismo produziria resultados equivalentes em ambientes mais complexos, com múltiplas necessidades, recursos escassos ou de diferentes naturezas, como alimento, energia, abrigo, ferramentas e itens prejudiciais, além de ameaças móveis ou formas distintas de interação.

O glaucoma artificial representa somente uma forma particular e simplificada de precariedade. A degradação segue uma regra fixa, afeta apenas a percepção e é removida integralmente após a coleta. Outros componentes corporais não se deterioram, não interagem entre si e não exigem regulação simultânea.

A aproximação com a autoconstrução também possui limites claros. O agente não produz seus componentes, não reorganiza sua estrutura, não define sua identidade e não estabelece seus próprios limites de viabilidade. A restauração da visão corresponde a uma reconstrução funcional previamente programada pelo ambiente. Por isso, os resultados não demonstram autopoiese, autonomia constitutiva, adaptatividade em sentido forte ou produção de sentido equivalente à observada em sistemas vivos.

O trabalho também não elimina a recompensa numérica. O RND foi escolhido e implementado pelo projetista, e sua saída continua sendo utilizada pelo PPO para atualizar a política. A contribuição consiste em não atribuir valor direto aos *medikits*, à vida ou à restauração da visão. Ainda assim, o mecanismo pode ser interpretado como uma forma indireta de modelagem da recompensa, pois a estrutura corporal foi projetada de modo a alterar as

observações das quais o sinal intrínseco depende.

Outra limitação decorre das escolhas algorítmicas. Os experimentos utilizaram PPO, RND, uma arquitetura convolucional e um conjunto específico de hiperparâmetros. Os resultados não permitem concluir que o mesmo padrão ocorrerá com outros algoritmos, métodos de curiosidade ou arquiteturas. Em particular, modelos recorrentes podem utilizar memória para compensar a perda visual, enquanto outros sinais intrínsecos podem responder de maneira diferente às observações degradadas.

6.3 Trabalhos Futuros

Como continuidade, o mecanismo pode ser avaliado em outros ambientes e tarefas que exijam navegação, manipulação de objetos e manutenção de diferentes condições internas. A introdução de necessidades simultâneas, como energia, integridade corporal e temperatura, permitiria investigar como o agente organiza comportamentos quando diferentes dimensões de viabilidade competem entre si.

Também seria relevante comparar o RND com outros métodos de motivação intrínseca já discutidos neste trabalho, como a exploração baseada em pseudocontagens (BELLE-MARE *et al.*, 2016) e o *Intrinsic Curiosity Module* (ICM) (PATHAK *et al.*, 2017). Também poderiam ser avaliadas diferentes representações para o cálculo da curiosidade, como as características aleatórias e aprendidas investigadas por Burda *et al.* (2018a). Essas comparações permitiriam verificar se a relação observada depende especificamente do erro de predição do RND ou se pode ser reproduzida por diferentes medidas de novidade, surpresa e controlabilidade. O uso de arquiteturas recorrentes também poderia esclarecer se a memória permite compensar parcialmente a degradação visual e produzir estratégias mais eficientes sob glaucoma intenso.

Também seria importante comparar diretamente a eficiência da recompensa extrínseca e do mecanismo corporal sob diferentes alterações da tarefa. Essa avaliação poderia verificar se a vantagem da proposta não está apenas em resolver a configuração atual, mas em reutilizar o mesmo mecanismo de curiosidade quando o corpo ou o ambiente são modificados.

Os experimentos realizados não resolvem o problema geral da autonomia artificial. Ainda assim, demonstram que modificar a relação entre condição interna, percepção e curiosidade altera de maneira significativa o comportamento aprendido. Ao tornar a continuidade da percepção dependente das ações do agente, a precariedade permitiu que os recursos adquirissem relevância funcional sem uma recompensa direta para sua coleta. Esse resultado constitui um

passo experimental em direção a agentes cujo comportamento seja orientado não apenas por objetivos externos, mas também pelas consequências de suas ações sobre suas próprias condições de interação com o mundo.

REFERÊNCIAS

- American Optometric Association. **Glaucoma**. s.d. Acessado em: 25 de julho de 2026. Disponível em: <<https://www.aoa.org/healthy-eyes/eye-and-vision-conditions/glaucoma>>.
- AMODEI, D.; OLAH, C.; STEINHARDT, J.; CHRISTIANO, P.; SCHULMAN, J.; MANÉ, D. Concrete problems in ai safety. **CoRR**, abs/1606.06565, 2016. Disponível em: <<https://arxiv.org/abs/1606.06565>>.
- BARANDIARAN, X.; PAOLO, E. D.; ROHDE, M. Defining agency: Individuality, normativity, asymmetry, and spatio-temporality in action. **Adaptive Behavior**, v.17, 367-386 (2009), v. 17, 09 2009.
- BELLEMARE, M. G.; SRINIVASAN, S.; OSTROVSKI, G.; SCHAUL, T.; SAXTON, D.; MUNOS, R. Unifying count-based exploration and intrinsic motivation. In: **Proceedings of the 30th International Conference on Neural Information Processing Systems**. Red Hook, NY, USA: Curran Associates Inc., 2016. (NIPS'16), p. 1479–1487. ISBN 9781510838819.
- BERNER, C.; BROCKMAN, G.; CHAN, B.; CHEUNG, V.; DęBIAK, P.; DENNISON, C.; FARHI, D.; FISCHER, Q.; HASHME, S.; HESSE, C.; JÓZEFOWICZ, R.; GRAY, S.; OLSSON, C.; PACHOCKI, J.; PETROV, M.; PINTO, H.; RAIMAN, J.; SALIMANS, T.; SCHLATTER, J.; ZHANG, S. Dota 2 with large scale deep reinforcement learning. **arXiv preprint arXiv:1912.06680**, 12 2019.
- BURDA, Y.; EDWARDS, H.; PATHAK, D.; STORKEY, A. J.; DARRELL, T.; EFROS, A. A. Large-scale study of curiosity-driven learning. **CoRR**, abs/1808.04355, 2018. Disponível em: <<http://arxiv.org/abs/1808.04355>>.
- BURDA, Y.; EDWARDS, H.; STORKEY, A. J.; KLIMOV, O. Exploration by random network distillation. **CoRR**, abs/1810.12894, 2018. Disponível em: <<http://arxiv.org/abs/1810.12894>>.
- Di Paolo, E. Autopoiesis, adaptivity, teleology, agency. 12 2005. Disponível em: <https://sussex.figshare.com/articles/journal_contribution/Autopoiesis_adaptivity_teleology_agency/23368025>.
- FILHO, C. R.; NOGUEIRA, Y. L. B. Analyzing enactive ai implementations on enactive ai terms. **Research Square**, 2022. Disponível em: <<https://doi.org/10.21203/rs.3.rs-2251292/v1>>.
- FILHO, R. F. F.; SANTOS, A. M. M.; RODRIGUES, H. R.; NOGUEIRA, Y. L. B.; VIDAL, C. A.; CAVALCANTE-NETO, J. B.; SERAFIM, P. B. S. Using curriculum to train multisensory foraging DRL agents. In: **Anais do XXIII Simpósio Brasileiro de Jogos e Entretenimento Digital (SBGames)**. Porto Alegre, RS, Brasil: SBC, 2024. p. 456–473.
- FROESE, T.; ZIEMKE, T. Enactive artificial intelligence: Investigating the systemic organization of life and mind. **Artificial Intelligence**, v. 173, n. 3, p. 466–500, 2009. ISSN 0004-3702. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0004370208002105>>.
- GEORGEON, O. L.; WOLF, C.; GAY, S. An enactive approach to autonomous agent and robot learning. In: **2013 IEEE Third Joint International Conference on Development and Learning and Epigenetic Robotics (ICDL)**. [S.l.: s.n.], 2013. p. 1–6.

GIGNAC, G. E.; SZODORAI, E. T. Defining intelligence: Bridging the gap between human and artificial perspectives. **Intelligence**, v. 104, p. 101832, 2024. ISSN 0160-2896. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0160289624000266>>.

HESSEL, M.; MODAYIL, J.; HASSELT, H. van; SCHAUL, T.; OSTROVSKI, G.; DABNEY, W.; HORGAN, D.; PIOT, B.; AZAR, M.; SILVER, D. Rainbow: combining improvements in deep reinforcement learning. In: **Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence and Thirtieth Innovative Applications of Artificial Intelligence Conference and Eighth AAAI Symposium on Educational Advances in Artificial Intelligence**. [S.l.]: AAAI Press, 2018. (AAAI'18/IAAI'18/EAAI'18). ISBN 978-1-57735-800-8.

KRAKOVNA, V.; UESATO, J.; MIKULIK, V.; RAHTZ, M.; EVERITT, T.; KUMAR, R.; KENTON, Z.; LEIKE, J.; LEGG, S. **Specification gaming: the flip side of AI ingenuity**. 2020. <<https://deepmind.google/discover/blog/specification-gaming-the-flip-side-of-ai-ingenuity/>>. Acessado em: 18 de maio de 2026.

LECUN, Y.; BOSER, B.; DENKER, J. S.; HENDERSON, D.; HOWARD, R. E.; HUBBARD, W.; JACKEL, L. D. Backpropagation applied to handwritten zip code recognition. **Neural Computation**, v. 1, n. 4, p. 541–551, 1989.

LEHMAN, J.; CLUNE, J.; MISEVIC, D.; ADAMI, C.; ALTENBERG, L.; BEAULIEU, J.; BENTLEY, P. J.; BERNARD, S.; BESLON, G.; BRYSON, D. M.; CHENEY, N.; CULLY, A.; DONCIEUX, S.; DYER, F. C.; ELLEFSEN, K. O.; FELDT, R.; FISCHER, S.; FORREST, S.; FRÉNOY, A.; GAGNÉ, C.; GOFF, L. L.; GRABOWSKI, L. M.; HODJAT, B.; HUTTER, F.; KELLER, L.; KNIBBE, C.; KRCAH, P.; LENSKI, R. E.; LIPSON, H.; MACCUDY, R.; MAESTRE, C.; MIIKKULAINEN, R.; MITRI, S.; MORIARTY, D. E.; MOURET, J.-B.; NGUYEN, A.; OFRIA, C.; PARIZEAU, M.; PARSONS, D.; PENNOCK, R. T.; PUNCH, W. F.; RAY, T. S.; SCHOENAUER, M.; SCHULTE, E.; SIMS, K.; STANLEY, K. O.; TADDEI, F.; TARAPORE, D.; THIBAUT, S.; WEIMER, W.; WATSON, R.; YOSINSKI, J. The surprising creativity of digital evolution: A collection of anecdotes from the evolutionary computation and artificial life research communities. **Artificial Life**, v. 26, n. 2, p. 274–306, 2020.

MathWorks. **What Is a Convolutional Neural Network?** 2026. Acessado em: 8 de maio de 2026. Disponível em: <<https://www.mathworks.com/discovery/convolutional-neural-network.html>>.

MATURANA, H.; VARELA, F. **Autopoiesis and Cognition: The Realization of the Living**. [S.l.]: Reidel, 1980.

MESQUITA, A.; NOGUEIRA, Y.; VIDAL, C.; CAVALCANTE-NETO, J.; SERAFIM, P. Autonomous Foraging with SARSA-based Deep Reinforcement Learning. In: **2020 22nd Symposium on Virtual and Augmented Reality (SVR)**. Porto de Galinhas, Brazil: IEEE, 2020. p. 425–433. ISBN 978-1-7281-9231-4. Disponível em: <<https://ieeexplore.ieee.org/document/9262697/>>.

MNIH, V.; BADIA, A. P.; MIRZA, M.; GRAVES, A.; LILLICRAP, T.; HARLEY, T.; SILVER, D.; KAVUKCUOGLU, K. Asynchronous methods for deep reinforcement learning. In: BALCAN, M. F.; WEINBERGER, K. Q. (Ed.). **Proceedings of The 33rd International Conference on Machine Learning**. New York, New York, USA: PMLR, 2016. (Proceedings of Machine Learning Research, v. 48), p. 1928–1937. Disponível em: <<https://proceedings.mlr.press/v48/mniha16.html>>.

MNIH, V.; KAVUKCUOGLU, K.; SILVER, D.; GRAVES, A.; ANTONOGLU, I.; WIERSTRA, D.; RIEDMILLER, M. Playing atari with deep reinforcement learning. 12 2013.

Mnih, V.; Kavukcuoglu, K.; Silver, D.; Rusu, A. A.; Veness, J.; Bellemare, M. G.; Graves, A.; Riedmiller, M.; Fidjeland, A. K.; Ostrovski, G.; Petersen, S.; Beattie, C.; Sadik, A.; Antonoglou, I.; King, H.; Kumaran, D.; Wierstra, D.; Legg, S.; Hassabis, D. Human-level control through deep reinforcement learning. **Nature**, v. 518, n. 7540, p. 529–533, fev. 2015.

National Eye Institute. **Glaucoma**. 2025. Acessado em: 25 de julho de 2026. Disponível em: <<https://www.nei.nih.gov/eye-health-information/eye-conditions-and-diseases/glaucoma>>.

NOGUEIRA, Y. L. B.; BRITO, C. E. F. de; VIDAL, C. A.; CAVALCANTE-NETO, J. B. Towards intrinsic autonomy through evolutionary computation. **Artificial Intelligence Review**, v. 53, n. 6, p. 4449–4473, ago. 2020. ISSN 1573-7462. Disponível em: <<https://doi.org/10.1007/s10462-019-09798-1>>.

NOGUEIRA, Y. L. B.; Fisch de Brito, C. E.; VIDAL, C. A.; Cavalcante Neto, J. B. Emergent vision system of autonomous virtual characters. **Neurocomputing**, v. 173, p. 1851–1867, 2016. ISSN 0925-2312. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0925231215013922>>.

OUYANG, L.; WU, J.; JIANG, X.; ALMEIDA, D.; WAINWRIGHT, C.; MISHKIN, P.; ZHANG, C.; AGARWAL, S.; SLAMA, K.; RAY, A.; SCHULMAN, J.; HILTON, J.; KELTON, F.; MILLER, L.; SIMENS, M.; ASKELL, A.; WELINDER, P.; CHRISTIANO, P. F.; LEIKE, J.; LOWE, R. Training language models to follow instructions with human feedback. In: KOYEJO, S.; MOHAMED, S.; AGARWAL, A.; BELGRAVE, D.; CHO, K.; OH, A. (Ed.). **Advances in Neural Information Processing Systems**. Curran Associates, Inc., 2022. v. 35, p. 27730–27744. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2022/file/b1efde53be364a73914f58805a001731-Paper-Conference.pdf>.

PATHAK, D.; AGRAWAL, P.; EFROS, A. A.; DARRELL, T. Curiosity-driven exploration by self-supervised prediction. In: **Proceedings of the 34th International Conference on Machine Learning - Volume 70**. [S.l.]: JMLR.org, 2017. (ICML'17), p. 2778–2787.

PETRENKO, A.; HUANG, Z.; KUMAR, T.; SUKHATME, G. S.; KOLTUN, V. Sample factory: Egocentric 3d control from pixels at 100000 FPS with asynchronous reinforcement learning. **CoRR**, abs/2006.11751, 2020. Disponível em: <<https://arxiv.org/abs/2006.11751>>.

POPOV, I.; HEES, N.; LILLICRAP, T. P.; HAFNER, R.; BARTH-MARON, G.; VECERÍK, M.; LAMPE, T.; TASSA, Y.; EREZ, T.; RIEDMILLER, M. A. Data-efficient deep reinforcement learning for dexterous manipulation. **CoRR**, abs/1704.03073, 2017. Disponível em: <<http://arxiv.org/abs/1704.03073>>.

POZZA, N. D.; BUFFONI, L.; MARTINA, S.; CARUSO, F. Quantum reinforcement learning: the maze problem. **Quantum Machine Intelligence**, Springer Science and Business Media LLC, v. 4, n. 1, maio 2022. ISSN 2524-4914. Disponível em: <<http://dx.doi.org/10.1007/s42484-022-00068-y>>.

RYAN, R. M.; DECI, E. L. Intrinsic and extrinsic motivations: Classic definitions and new directions. **Contemporary Educational Psychology**, v. 25, n. 1, p. 54–67, 2000. ISSN 0361-476X. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0361476X99910202>>.

SCHULMAN, J.; LEVINE, S.; MORITZ, P.; JORDAN, M. I.; ABBEEL, P. Trust region policy optimization. **CoRR**, abs/1502.05477, 2015. Disponível em: <<http://arxiv.org/abs/1502.05477>>.

SCHULMAN, J.; WOLSKI, F.; DHARIWAL, P.; RADFORD, A.; KLIMOV, O. Proximal policy optimization algorithms. **CoRR**, abs/1707.06347, 2017. Disponível em: <<http://dblp.uni-trier.de/db/journals/corr/corr1707.html#SchulmanWDRK17>>.

SEARLE, J. R. Minds, brains, and programs. Cambridge University Press, v. 3, n. 3, p. 417–424, 1980. ISSN 0140525X. Disponível em: <<https://www.cambridge.org/core/article/minds-brains-and-programs/DC644B47A4299C637C89772FACC2706A>>.

SELVARAJU, R. R.; DAS, A.; VEDANTAM, R.; COGSWELL, M.; PARIKH, D.; BATRA, D. Grad-cam: Why did you say that? visual explanations from deep networks via gradient-based localization. **CoRR**, abs/1610.02391, 2016. Disponível em: <<http://arxiv.org/abs/1610.02391>>.

SUTTON, R. S.; BARTO, A. G. **Reinforcement Learning: An Introduction**. 2. ed. Cambridge, MA: MIT Press, 2018. Disponível em: <<http://incompleteideas.net/book/the-book-2nd.html>>.

SUTTON, R. S.; MCALLESTER, D.; SINGH, S.; MANSOUR, Y. Policy gradient methods for reinforcement learning with function approximation. In: **Proceedings of the 13th International Conference on Neural Information Processing Systems**. Cambridge, MA, USA: MIT Press, 1999. (NIPS'99), p. 1057–1063.

THEOCHARIS, S. **easy-explain: Explainable AI with GradCam**. 2024. <<https://pub.towardsai.net/easy-explain-explainable-ai-with-gradcam-e187f85a697c>>. Acessado em: 12 de maio de 2026.

TURING, A. M. Computing machinery and intelligence. **Mind**, Oxford University Press on behalf of the Mind Association, v. 59, n. 236, p. 433–460, 1950. ISSN 00264423. Disponível em: <<http://www.jstor.org/stable/2251299>>.

VARELA, F. J. **Autopoiesis and a Biology of Intentionality**. 1991. Unpublished manuscript.

WYDMUCH, M.; KEMPKA, M.; JAŚKOWSKI, W. Vizdoom competitions: Playing doom from pixels. **IEEE Transactions on Games**, IEEE, 2018. IEEE Transactions on Games outstanding paper award 2022.

YANG, L.; LI, Y.; CHEN, L. Clothppo: a proximal policy optimization enhancing framework for robotic cloth manipulation with observation-aligned action spaces. In: **Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence**. [s.n.], 2024. (IJCAI '24). ISBN 978-1-956792-04-1. Disponível em: <<https://doi.org/10.24963/ijcai.2024/762>>.

ZHOU, B.; KHOSLA, A.; LAPEDRIZA, À.; OLIVA, A.; TORRALBA, A. Learning deep features for discriminative localization. **CoRR**, abs/1512.04150, 2015. Disponível em: <<http://arxiv.org/abs/1512.04150>>.