



UNIVERSIDADE FEDERAL DO CEARÁ
CENTRO DE CIÊNCIAS
DEPARTAMENTO DE COMPUTAÇÃO
PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO
MESTRADO ACADÊMICO EM CIÊNCIA DA COMPUTAÇÃO

PAULO ROBERTO PINTO COSTA

MORTE ARTIFICIAL: PRECARIEDADE É TUDO QUE VOCÊ PRECISA

FORTALEZA

2026

RESUMO

A autonomia artificial exige repensar o papel da recompensa no Aprendizado por Reforço. Em abordagens tradicionais, o agente aprende a partir de recompensas externas definidas pelo projetista, o que pode produzir comportamentos eficientes, mas limita a emergência de formas mais autônomas de ação. Inspirado pela Inteligência Artificial Enativa, este trabalho investiga agentes cuja ação é orientada por condições internas de viabilidade. Para isso, utiliza-se o cenário *Health-Gathering*, da plataforma VizDoom, no qual um agente perde vida continuamente em uma sala com chão ácido e percebe o ambiente por meio da visão. Em vez de recompensar explicitamente a coleta de *medikits*, itens que restauram a vida do agente, introduz-se uma forma artificial de precariedade corporal. À medida que o agente permanece sem coletar *medikits*, sua visão é degradada, sendo restaurada quando ele os coleta. A motivação do agente é produzida por uma recompensa intrínseca baseada em curiosidade, calculada por meio do método *Random Network Distillation* (RND). Como a curiosidade depende das observações visuais, a degradação perceptiva reduz a capacidade do agente de obter recompensa intrínseca. Assim, manter-se viável torna-se condição para continuar percebendo, explorando e agindo. A política aprendida será analisada com técnicas de interpretabilidade visual, como Grad-CAM, buscando compreender como precariedade, percepção e curiosidade podem favorecer comportamentos adaptativos sem impor diretamente uma solução por recompensas extrínsecas. Sendo assim, se a autonomia nasce da precariedade, então ser inteligente é, fundamentalmente, estar engajado em um processo contínuo de negociação com a possibilidade de deixar de existir.

Palavras-chave: Agentes autônomos. Inteligência Artificial Enativa. Curiosidade. Aprendizado por Reforço Profundo. Precariedade. Motivação intrínseca

SUMÁRIO

1	INTRODUÇÃO	4
1.1	Motivação	4
1.2	Objetivos	5
2	FUNDAMENTAÇÃO TEÓRICA	6
2.1	Fundamentação Filosófica	6
2.1.1	<i>Inteligência Como Resolução de Problemas</i>	6
2.1.2	<i>Inteligência: Um Fenômeno Emergente da Vida</i>	7
2.1.3	<i>Inteligência e a Dinâmica da Sobrevivência</i>	9
2.2	Fundamentação Computacional	12
2.2.1	Aprendizado por Reforço	12
2.2.1.1	<i>Definição Matemática</i>	13
2.2.1.2	<i>Função Valor de Estado</i>	14
2.2.2	Aprendizado por Reforço Profundo	14
2.2.2.1	<i>Redes Neurais Convolucionais</i>	17
2.2.3	Aprendizado Contínuo	18
2.2.3.1	<i>Métodos de Gradiente de Política</i>	19
2.2.3.2	<i>Trust Region Policy Optimization</i>	21
2.2.3.3	<i>Proximal Policy Optimization</i>	22
2.2.4	Exploração, Motivação Intrínseca e Curiosidade	24
2.2.4.1	<i>Recompensa Intrínseca</i>	24
2.2.4.2	<i>Random Network Distillation</i>	25
2.2.5	Análise Visual da Política Aprendida	27
2.2.5.1	<i>Gradient-weighted Class Activation Mapping</i>	27
3	TRABALHOS RELACIONADOS	30
3.1	Aprendizado por Reforço Profundo	30
3.2	Função de Recompensa e Suas Implicações	34
3.3	Aprendizado Enativo	36
3.4	Aprendizado por Curiosidade	39
4	METODOLOGIA	42
4.1	Ambiente Experimental	42

4.2	Formulação em Aprendizado por Reforço	44
4.2.1	<i>Observação</i>	44
4.2.2	<i>Ação</i>	45
4.2.3	<i>Recompensa</i>	45
4.3	Algoritmo de Aprendizado	45
4.3.1	<i>Hiperparâmetros</i>	46
4.3.2	<i>Arquitetura da Rede Neural</i>	46
4.4	Estratégia de Recompensa	47
4.4.1	<i>O Problema da Recompensa</i>	47
4.4.2	<i>Autopoiese, IA Enativa e Perspectiva de Solução</i>	48
4.5	Glaucoma como Precariedade	49
4.6	Recompensa Intrínseca por Curiosidade	51
4.6.1	<i>Calculando a Recompensa Intrínseca</i>	52
4.6.2	<i>Hipótese</i>	53
4.7	Configurações Experimentais	54
4.8	Métricas de Avaliação	54
4.9	Análise Visual da Política Aprendida	55
5	RESULTADOS	57
5.1	Resultados Iniciais	57
6	CONCLUSÃO	59
	REFERÊNCIAS	60

1 INTRODUÇÃO

1.1 Motivação

A Inteligência Artificial contemporânea tem alcançado resultados expressivos em tarefas de percepção, planejamento e tomada de decisão (BERNER *et al.*, 2019; OUYANG *et al.*, 2022; YANG *et al.*, 2024). No Aprendizado por Reforço, porém, o comportamento do agente ainda costuma depender de recompensas externas definidas pelo projetista. Embora essa estratégia seja eficiente em problemas bem delimitados, ela limita a investigação de formas mais autônomas de agência, pois o valor das ações é imposto de fora, em vez de emergir da própria relação entre agente, corpo e ambiente.

Esta proposta parte dessa limitação para investigar um cenário em que a orientação do comportamento não dependa apenas de uma recompensa extrínseca. O ponto central é construir um agente visual cuja capacidade de perceber o ambiente seja afetada por uma condição interna de viabilidade. Desse modo, a manutenção dessa condição deixa de ser apenas um objetivo externo e passa a interferir diretamente na possibilidade de o agente explorar, perceber novidades e continuar interagindo com o mundo.

Para isso, propõe-se combinar Aprendizado por Reforço Profundo, motivação intrínseca por curiosidade e um mecanismo artificial de precariedade perceptiva. A precariedade será representada por um glaucoma artificial, que degrada progressivamente a observação visual do agente quando ele permanece sem coletar recursos no ambiente. Ao recuperar esses recursos, a percepção é restaurada. Assim, a proposta busca criar uma relação prática entre corpo artificial, percepção e recompensa intrínseca, inspirada por discussões da Inteligência Artificial Enativa sobre autonomia, viabilidade e acoplamento agente-ambiente (FROESE; ZIEMKE, 2009; MATURANA; VARELA, 1980; VARELA, 1991).

O trabalho, portanto, não se limita a revisar fundamentos teóricos ou trabalhos relacionados. Seu objetivo principal é apresentar uma proposta experimental para investigar se a relação entre precariedade, percepção degradada e curiosidade artificial pode favorecer comportamentos adaptativos em um agente treinado em ambiente visual. A fundamentação teórica e os trabalhos relacionados são utilizados como base para justificar a proposta, mas o foco do documento está na definição do experimento, de suas condições de avaliação e dos primeiros indícios de viabilidade.

1.2 Objetivos

O objetivo geral deste trabalho é propor e avaliar inicialmente um cenário experimental para investigar a relação entre precariedade perceptiva, motivação intrínseca e comportamento adaptativo em agentes de Aprendizado por Reforço Profundo.

De forma específica, este trabalho tem como objetivos:

- Formular uma tarefa experimental no cenário *Health-Gathering*, da plataforma VizDoom, adequada à investigação de sobrevivência, busca por recursos e percepção visual;
- Implementar um mecanismo de glaucoma artificial capaz de degradar e restaurar a percepção do agente conforme sua interação com os *medikits*;
- Treinar agentes com PPO sob diferentes condições de recompensa, incluindo ausência de recompensa, recompensa extrínseca padrão e recompensa intrínseca baseada em RND;
- Avaliar o efeito de diferentes forças de glaucoma sobre o tempo de sobrevivência, a exploração e o comportamento aprendido;
- Comparar trajetórias do agente em distribuições fixas de *medikits*, permitindo analisar qualitativamente se o comportamento acompanha a organização espacial dos recursos;
- Relacionar a recompensa intrínseca produzida pelo RND às cenas observadas pelo agente, investigando se a precariedade visual interfere no sinal de curiosidade; e
- Utilizar ferramentas de análise visual, como Grad-CAM, para investigar quais regiões da observação influenciam as decisões da política aprendida.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 Fundamentação Filosófica

2.1.1 *Inteligência Como Resolução de Problemas*

A palavra inteligência vem do latim *intelligentia*, derivada do verbo *intelligere* (*inter*, “entre” e *legere*, “escolher”, “colher”, “separar”, “ler”). Portanto, em sua origem, inteligência significa a capacidade de escolher entre várias opções ou, mais profundamente, “ler entre” (as linhas, os fatos, as aparências). Não é apenas processar o que está lá, mas discernir o que é relevante e o que não é.

Entretanto, na Inteligência Artificial (IA) atual, a concepção de “inteligência” é frequentemente reduzida a resolução de problemas, tarefas específicas, otimização ou desempenho em benchmarks, em detrimento de aspectos mais amplos da inteligência humana, como compreensão profunda, criatividade ou raciocínio contextual. A IA atual demonstra mais “conquista artificial” (conquistas em tarefas específicas) do que inteligência genuína, pois é limitada a problemas treinados, sem capacidade de resolver problemas novos como humanos. (GIGNAC; SZODORAI, 2024).

Um dos maiores e mais famosos exemplos desta concepção de inteligência pode ser vista em Turing (1950). Nesse texto, Alan Turing propõe uma reformulação da pergunta clássica “As máquinas podem pensar?” para evitar debates semânticos sobre os termos “máquina” e “pensar”. Em vez de definir diretamente o que é inteligência, ele introduz o jogo da imitação, hoje conhecido como Teste de Turing. No teste, um interrogador humano conversa por texto, sem ver ou ouvir os interlocutores, com dois participantes: um humano e uma máquina. O objetivo é determinar se a máquina consegue imitar respostas humanas de forma tão convincente que o interrogador não consiga distinguir qual é a máquina. Se a máquina passar no teste, Turing sugere que seria razoável dizer que ela “pensa” ou exibe inteligência. Todavia, o Teste de Turing representa o início da visão contemporânea de inteligência, baseada em resolução de problemas específicos previamente definidos, como responder perguntas de forma indistinguível de um humano, sem exigir “leitura entre as linhas” (*intelligere*) ou consciência, sendo o “Argumento do Quarto Chinês” (SEARLE, 1980) o principal argumento a favor disto.

O “Argumento do Quarto Chinês” propõe um cenário hipotético destinado a ilustrar que a manipulação sintática (símbolos), por si só, não produz compreensão semântica (signifi-

cado). Imagine uma pessoa que não fala chinês (como um falante nativo de português) trancada em uma sala. Essa pessoa recebe perguntas em chinês por uma fresta. Ela tem um manual em português com regras puramente sintáticas para manipular símbolos chineses (sem entender seu significado) e produzir respostas corretas em chinês. Seguindo rigorosamente as regras, as respostas saem indistinguíveis das de um falante nativo de chinês, ou seja, o sistema passa no Teste de Turing na imitação de uma pessoa falante de chinês. No entanto, a pessoa na sala não entende uma palavra de chinês, ela apenas manipula símbolos formais (sintaxe) sem qualquer semântica, incapaz de explicar o que lhe foi perguntado.

Searle (1980) distingue entre IA fraca (máquinas que simulam aspectos da cognição humana, como ferramentas úteis) e IA forte (a ideia de que um computador programado adequadamente literalmente entende, tem mente e consciência, como um humano). Mesmo com excelência em simulação de resolução de problemas (passar no teste), a IA atual permanece no nível sintático, processa símbolos sem discernir relevância profunda, sem criatividade ou raciocínio genuíno. Ela otimiza resultados, mas não “lê entre” os fatos com compreensão semântica, como sugere a raiz etimológica da inteligência.

Essas dificuldades sugerem que o desafio talvez não resida apenas em desenvolver algoritmos mais sofisticados ou métodos mais eficientes de aprendizado, mas em reconsiderar a própria natureza da inteligência. Em vez de concebê-la apenas como resolução de problemas ou manipulação de símbolos, a inteligência pode ser entendida como um fenômeno que emerge da dinâmica organizacional da vida.

2.1.2 *Inteligência: Um Fenômeno Emergente da Vida*

Uma abordagem alternativa para compreender a natureza da inteligência consiste em abordá-la a partir da biologia, ampliando o escopo das interpretações tradicionalmente associadas à computação. Nessa linha, a inteligência não é tratada apenas como a capacidade de resolver problemas previamente definidos, mas como um fenômeno emergente das propriedades fundamentais dos sistemas vivos. Essa perspectiva tem origem no conceito de *autopoiese*, introduzido por Maturana e Varela (1980).

Autopoiese (do grego *auto*, “si mesmo”, e *poiesis*, “produção” ou “criação”) descreve a organização característica dos sistemas vivos. Um sistema autopoietico é uma rede de processos que produz continuamente os próprios componentes que, por sua vez, mantêm essa mesma rede de produção. Em outras palavras, um organismo vivo não é simplesmente uma coleção de partes

organizadas externamente, mas uma rede dinâmica que produz e mantém a si mesma. Essa auto-produção contínua estabelece uma identidade operacional que distingue o sistema de seu ambiente.

Entretanto, essa identidade não implica isolamento. Pelo contrário, sistemas vivos dependem de interações constantes com o meio para manter sua organização. Essa relação é descrita por Maturana e Varela como *acoplamento estrutural*. O acoplamento estrutural refere-se à história recorrente de interações entre um organismo e seu ambiente, na qual perturbações externas desencadeiam mudanças estruturais no sistema, enquanto o próprio sistema responde a essas perturbações de acordo com sua organização interna. O ambiente não determina diretamente o comportamento do organismo, ele apenas desencadeia mudanças possíveis dentro das limitações estruturais do sistema (VARELA, 1991).

Ao longo do tempo, essas interações recorrentes levam a uma congruência estrutural entre o organismo e o ambiente no qual ele vive. O organismo torna-se adaptado ao domínio de interações que encontra regularmente, e sua própria estrutura reflete essa história de acoplamento. Dessa forma, a relação entre organismo e ambiente não é simplesmente de estímulo e resposta, mas de influência mútua.

Essa perspectiva tem implicações profundas para a compreensão da cognição. Segundo essa abordagem, cognição não deve ser entendida primariamente como manipulação de representações internas ou processamento de informações simbólicas. Em vez disso, cognição pode ser vista como um aspecto inerente da própria vida. Um sistema vivo, ao manter sua identidade autopoietica em interação contínua com o ambiente, deve constantemente distinguir entre interações que contribuem para sua continuidade e aquelas que ameaçam sua organização.

Esse processo de distinção é frequentemente descrito como “produção de sentido”. Um organismo não encontra no ambiente significados prontos ou informações previamente estruturadas. Em termos puramente físicos, o ambiente consiste apenas em fluxos de matéria e energia. Entretanto, para o organismo, certas interações tornam-se relevantes ou irrelevantes dependendo de sua relação com a manutenção da própria identidade. Uma molécula de açúcar, por exemplo, possui apenas propriedades físico-químicas no ambiente, contudo, para uma bactéria capaz de metabolizá-la, essa mesma molécula adquire significado como fonte de energia (VARELA, 1991).

Assim, o significado não está no ambiente em si, nem é simplesmente projetado pelo organismo de forma arbitrária. Ele emerge da relação dinâmica entre o sistema autopoietico e

seu meio. Essa relação dá origem ao que alguns autores distinguem como o *ambiente* observado externamente e o *mundo* vivido pelo organismo. O ambiente refere-se ao domínio físico descrito por um observador externo, enquanto o mundo corresponde ao domínio de interações significativas que surgem da perspectiva do próprio sistema vivo.

A partir dessa perspectiva, a cognição pode ser entendida como a atividade contínua pela qual um sistema vivo produz e mantém um mundo significativo enquanto preserva sua própria identidade. Essa atividade envolve uma tensão fundamental: por um lado, o organismo depende de seu ambiente e deve manter acoplamento com ele, por outro, é justamente essa atividade que estabelece a distinção entre o sistema e o ambiente, dando origem a um domínio próprio de significações.

Consequentemente, a inteligência pode ser vista como um fenômeno emergente da vida. Em vez de ser apenas a capacidade de resolver problemas formais ou executar tarefas específicas, inteligência estaria enraizada na dinâmica fundamental pela qual sistemas vivos mantêm sua autonomia, adaptam-se ao ambiente e produzem sentido em suas interações. Sob essa perspectiva, processos cognitivos complexos, como percepção, aprendizado e raciocínio, podem ser compreendidos como extensões de mecanismos mais básicos presentes na própria organização da vida.

2.1.3 *Inteligência e a Dinâmica da Sobrevivência*

A abordagem autopoietica apresentada anteriormente fornece uma base poderosa para repensar a natureza da cognição. Ao identificar a vida como um processo de auto-produção e manutenção de identidade, ela permite compreender o surgimento do significado como inerente à própria organização dos sistemas vivos. Entretanto, como discutido, essa perspectiva, por si só, permanece limitada ao estabelecer apenas uma normatividade binária: algo é bom apenas na medida em que contribui para a continuidade da identidade do sistema e ruim caso contrário.

Essa limitação torna-se evidente quando consideramos que organismos vivos não apenas sobrevivem ou deixam de sobreviver, mas operam continuamente em um espectro de diferentes graus de viabilidade, respondendo a perturbações, antecipando riscos e, em muitos casos, melhorando suas próprias condições de existência. Em outras palavras, a vida não é apenas manutenção, mas também regulação e adaptação.

É nesse contexto que emerge a abordagem da Inteligência Artificial Enativa, que busca estender os princípios da autopoiese em direção a uma teoria mais robusta da cognição

natural e artificial (FROESE; ZIEMKE, 2009). Enação refere-se à ideia de que a cognição não consiste na representação de um mundo pré-dado, mas emerge da interação dinâmica entre um sistema autônomo e seu ambiente, por meio de suas ações corporificadas, nas quais o organismo “traz à tona” (enata) um domínio de significados relevante para sua própria viabilidade. Em vez de abandonar a noção de autonomia introduzida por Maturana e Varela, a IA Enativa a toma como ponto de partida, propondo dois princípios de design que visam orientar a construção de sistemas artificiais capazes de exibir formas mais genuínas de cognição:

1. **Autonomia Constitutiva:** O primeiro desses princípios, estabelece que um agente artificial deve ser constitutivamente autônomo, isto é, deve possuir uma organização interna capaz de produzir e manter sua própria identidade. Esse princípio é diretamente enraizado na noção de autopoiese discutida anteriormente. Assim como nos sistemas vivos, a identidade do agente não deve ser imposta externamente, mas emergir de uma rede de processos internos que se sustentam mutuamente. Nesse sentido, o agente não é apenas um sistema que executa funções pré-definidas, mas um sistema cuja própria existência depende da continuidade de sua organização.
2. **Adaptatividade:** Segundo Di Paolo (2005), um sistema adaptativo é aquele capaz de regular sua própria dinâmica em resposta a perturbações internas e externas, mantendo-se dentro de limites de viabilidade. Essa noção introduz o conceito de “restrição de viabilidade”, que se refere ao conjunto de condições que devem ser satisfeitas para que o sistema continue existindo, permitindo que ele identifique tendências (positivas ou negativas) e aja para se afastar de estados fatais.

De acordo com Froese e Ziemke (2009), essa noção de restrição de viabilidade mantida em aberto, permite duas interpretações distintas. Por um lado, a restrição de viabilidade pode ser imposta externamente, como em sistemas projetados ou algoritmos evolutivos. Por outro lado, e mais profundamente, essa restrição pode ser entendida como intrínseca à própria identidade do sistema, o que implica que o agente não apenas segue regras de sobrevivência, mas constitui essas regras a partir de sua própria organização.

Essa segunda interpretação radicaliza a proposta autopoietica e torna o problema da cognição artificial significativamente mais desafiador. Como afirmam os autores, a combinação entre autonomia constitutiva e adaptatividade é condição necessária para o surgimento da produção de sentido. Nessa perspectiva, o significado não emerge apenas da distinção entre o que preserva ou destrói o sistema, mas da forma como diferentes perturbações adquirem valores

distintos em relação à sua viabilidade.

Essa ideia revela um aspecto fundamental frequentemente negligenciado nas abordagens tradicionais da inteligência: o papel constitutivo da precariedade. Sistemas vivos não são entidades estáveis em equilíbrio permanente, mas processos dinâmicos continuamente expostos ao risco de desintegração. A possibilidade de falha, em última instância, a possibilidade de morte, não é um acidente, mas uma condição essencial para o surgimento da cognição.

Sob essa ótica, a inteligência pode ser reinterpretada como a capacidade de um sistema de lidar com sua própria precariedade. Um organismo inteligente não é aquele que resolve problemas previamente definidos, mas aquele que consegue manter-se viável em um mundo incerto, atribuindo relevância às interações que afetam sua continuidade. Assim, a cognição emerge como uma atividade normativa, orientada pela necessidade constante de evitar a perda da própria identidade.

Essa concepção é aprofundada por autores como Barandiaran *et al.* (2009), que enfatizam que a agência requer não apenas autonomia, mas também a capacidade de modular ativamente a relação com o ambiente em função de condições internas. Como mostrado na Figura 1, essa modulação não é externa ao sistema, mas emerge de sua própria dinâmica interna, orientando suas interações de acordo com sua viabilidade. Nesse sentido, a inteligência não está localizada em um mecanismo específico, mas na dinâmica global do sistema enquanto ele regula sua existência.



Figura 1 – Ilustração esquemática da agência: o sistema é formado por uma rede de processos autossustentados (círculo à esquerda) em interação com o ambiente, na qual mecanismos internos de regulação modulam esse acoplamento, configurando o comportamento do agente para manter a sua identidade.

Fonte: Adaptado de Barandiaran *et al.* (2009).

A IA Enativa, portanto, propõe uma mudança paradigmática na forma de conceber sistemas inteligentes. Em vez de projetar máquinas capazes de resolver problemas em domínios previamente especificados, o objetivo passa a ser a construção de sistemas capazes de constituir

seus próprios domínios de relevância a partir de sua interação com o ambiente.

Dessa forma, um sistema artificial que incorpore simultaneamente autonomia constitutiva e adaptatividade representaria um avanço significativo em direção a modelos mais fiéis da cognição natural. Tal sistema não apenas processaria informações, mas produziria sentido, não apenas executaria tarefas, mas sustentaria sua própria existência diante das constantes ameaças impostas pelo mundo.

Em última instância, a IA Enativa sugere que a inteligência não pode ser dissociada da vida. Ser inteligente é, fundamentalmente, estar engajado em um processo contínuo de negociação com a possibilidade de deixar de existir.

2.2 Fundamentação Computacional

2.2.1 *Aprendizado por Reforço*

O Aprendizado por Reforço (AR) é um paradigma de aprendizado de máquina no qual um agente interage continuamente com um ambiente, tomando ações e recebendo, como consequência, sinais de feedback na forma de recompensas e novos estados. Essa interação ocorre de maneira sequencial: a cada instante, o agente observa o estado atual do ambiente, escolhe uma ação e, como resultado, o ambiente evolui para um novo estado e fornece uma recompensa associada à ação executada, conforme ilustrado na Figura 2.




Figura 2 – Diagrama do ciclo de interação no aprendizado por reforço. O agente observa o estado do ambiente, seleciona uma ação com base em sua política e a executa no ambiente. Como consequência, o ambiente transita para um novo estado e fornece ao agente um sinal numérico de recompensa. Esse ciclo de percepção–ação–*feedback* se repete continuamente, permitindo que o agente ajuste seu comportamento ao longo do tempo de forma a maximizar a recompensa acumulada.

Fonte: Adaptado de Sutton e Barto (2018).

O objetivo central dos algoritmos de aprendizado por reforço é aprender uma estratégia de decisão que maximize uma medida acumulada de recompensa ao longo do tempo. Diferentemente do aprendizado supervisionado, no qual pares entrada-saída são explicitamente

fornecidos, no AR o agente não recebe instruções diretas sobre qual ação tomar. Em vez disso, ele deve inferir, a partir do sinal de recompensa, tentativa e erro, quais comportamentos são mais adequados, explorando o ambiente e ajustando suas decisões com base nas consequências observadas. Nos casos mais interessantes e desafiadores, as ações podem afetar não apenas a recompensa imediata, mas também a próxima situação e, por consequência, todas as recompensas subsequentes. Essas duas características, busca por tentativa e erro e recompensa atrasada, são os dois aspectos mais importantes que distinguem o aprendizado por reforço (SUTTON; BARTO, 2018).

2.2.1.1 Definição Matemática

Formalmente, o problema de aprendizado por reforço é frequentemente modelado como um *Processo de Decisão de Markov* (PDM), definido pela tupla:

$$\mathcal{M} = (S, A, P, R, \gamma)$$

em que:

- S é o conjunto de estados possíveis do ambiente.
- A é o conjunto de ações disponíveis ao agente.
- $P(s' | s, a)$ é a função de transição de estados, que define a probabilidade de transitar para o estado s' ao executar a ação a no estado s . Esta função satisfaz a *Propriedade de Markov*, onde a probabilidade de ir para o próximo estado depende apenas do estado atual, sendo independente da trajetória passada. Matematicamente, isso significa que:

$$P(s_{t+1} | s_t, a_t, s_{t-1}, \dots, s_0) = P(s_{t+1} | s_t, a_t);$$

- $R(s, a)$ é a função de recompensa, que associa um valor escalar ao par estado-ação;
- $\gamma \in [0, 1)$ é o fator de desconto, responsável por controlar a importância relativa das recompensas futuras no cálculo do retorno acumulado. Na equação do retorno, o termo γ^k decai exponencialmente à medida que k aumenta, fazendo com que recompensas mais distantes no tempo contribuam menos para o valor total. Dessa forma, o fator de desconto estabelece um equilíbrio entre recompensas imediatas e ganhos de longo prazo.

A dinâmica do AR ocorre em etapas discretas de tempo. Em cada instante t , o agente observa um estado $s_t \in S$, seleciona uma ação $a_t \in A$ de acordo com uma política π , recebe uma recompensa r_t e transita para um novo estado s_{t+1} , como ilustrado na Figura 2.

A política $\pi(a | s)$ define o comportamento do agente, isto é, a probabilidade de escolher a ação a no estado s . O objetivo do agente é encontrar uma política ótima π^* que maximize o retorno esperado, sendo este, o grande desafio dos algoritmos de aprendizagem por reforço. O retorno, por sua vez, pode ser definido em função da recompensa e do fator de desconto de recompensas futuras. Assim, o retorno a partir do tempo t é definido como:

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$$

2.2.1.2 Função Valor de Estado

Embora o objetivo do agente seja maximizar o retorno acumulado ao longo do tempo, essa quantidade, por si só, não é diretamente utilizável para a tomada de decisão em cada instante, uma vez que depende de recompensas futuras ainda desconhecidas. Dessa forma, torna-se necessário introduzir mecanismos que permitam avaliar, de maneira antecipada, a qualidade das situações nas quais o agente pode se encontrar. Nesse contexto, define-se a função valor de estado, que fornece uma medida da qualidade de um estado ao quantificar o retorno esperado a partir dele, assumindo que o agente seguirá uma determinada política π . Intuitivamente, o valor de um estado reflete o quão promissor ele é em termos de recompensas futuras, ou seja, estados com valores mais elevados indicam maior potencial de retorno, enquanto estados com valores mais baixos sugerem situações menos favoráveis. Permitindo, assim, comparar estados e orientar o agente na escolha de ações que o conduzam, de forma consistente, a regiões mais vantajosas do espaço de estados. Formalmente, a função valor de estado é definida como:

$$V_{\pi}(s) = \mathbb{E}_{\pi}[G_t | s_t = s]$$

2.2.2 Aprendizado por Reforço Profundo

Embora a fundamentação matemática do Aprendizado por Reforço forneça a base para a tomada de decisão sequencial, a aplicação desses conceitos em ambientes complexos e de alta dimensionalidade enfrenta o desafio da chamada *maldição da dimensionalidade*. Esse termo refere-se ao crescimento exponencial da quantidade de estados possíveis à medida que aumenta a dimensionalidade do espaço de estados. Em problemas reais, pequenas variações contínuas nas observações do ambiente podem gerar um número extremamente elevado de configurações distintas, tornando inviável armazenar explicitamente informações para cada estado possível.

Essa limitação torna-se particularmente evidente em métodos tabulares, nos quais funções de políticas são representadas por tabelas contendo estimativas associadas a cada estado. Em cenários onde o espaço de estados S é contínuo ou composto por entradas sensoriais brutas, como pixels de imagens, o número de combinações possíveis cresce rapidamente, tornando impraticável tanto o armazenamento quanto o aprendizado eficiente dessas representações.

O Aprendizado por Reforço Profundo (ARP) (MNIH *et al.*, 2013) resolve essa limitação ao integrar os princípios do AR com o poder de representação das Redes Neurais Profundas. Nesse paradigma, as redes neurais atuam como aproximadores de funções universais, sendo capazes de aprender representações compactas e generalizáveis a partir de dados complexos.

A principal mudança introduzida pelo ARP é a parametrização dos componentes do agente. A política π , que antes era uma distribuição de probabilidade definida em uma tabela, passa a ser representada por uma rede neural com um conjunto de parâmetros θ , denotada como $\pi_{\theta}(a | s)$. O objetivo do aprendizado, portanto, desloca-se para a busca dos parâmetros θ que maximizam o retorno esperado. A figura 3 mostra o desenho esquemático de um algoritmo de ARP.




Figura 3 – Esquema de Aprendizado por Reforço Profundo. Uma Rede Neural Profunda aprende a política π que o agente utiliza para executar uma ação no ambiente. Uma recompensa e a informação sobre o novo estado do sistema são devolvidas ao agente, que aprimora e aprende sua política de acordo.

Fonte: Adaptado de Pozza *et al.* (2022).

Entretanto, para que a rede neural consiga representar adequadamente a política do agente, é necessário um mecanismo capaz de ajustar seus parâmetros internos com base nas experiências adquiridas durante a interação com o ambiente. Em redes neurais profundas, esse aprendizado ocorre por meio de um processo de otimização iterativa, no qual os parâmetros θ

são atualizados de forma a minimizar uma função de perda que mede o erro entre as previsões da rede e os valores desejados.

De maneira geral, uma rede neural pode ser entendida como uma função parametrizada $f_{\theta}(x)$, na qual x representa a entrada da rede e θ o conjunto de pesos e vieses que determinam seu comportamento. Durante o treinamento, o objetivo consiste em encontrar os valores de θ que minimizam uma função objetivo $\mathcal{L}(\theta)$, frequentemente definida em termos do erro de predição da rede.

A atualização dos parâmetros é realizada por métodos de otimização baseados em gradiente, sendo o Gradiente Descendente uma das abordagens mais utilizadas. Nesse método, calcula-se o gradiente da função de perda em relação aos parâmetros da rede,

$$\nabla_{\theta}\mathcal{L}(\theta),$$

o qual indica a direção de maior crescimento da função objetivo. Assim, para minimizar a perda, os parâmetros são atualizados iterativamente na direção oposta ao gradiente:

$$\theta \leftarrow \theta - \alpha \nabla_{\theta}\mathcal{L}(\theta),$$

em que α representa a taxa de aprendizado, responsável por controlar o tamanho das atualizações realizadas a cada etapa de treinamento.

O cálculo eficiente desses gradientes é realizado por meio do algoritmo de retropropagação do erro, que aplica a regra da cadeia para propagar o erro da saída da rede em direção às camadas internas, permitindo determinar a contribuição de cada parâmetro para o erro total. Dessa forma, a rede neural ajusta progressivamente suas representações internas, tornando-se capaz de aproximar funções altamente não lineares e extrair padrões relevantes dos dados observados.

No contexto do Aprendizado por Reforço Profundo, esse mecanismo de otimização é utilizado para ajustar os parâmetros da política $\pi_{\theta}(a | s)$ ou das funções de valor aproximadas pela rede neural. Assim, a experiência adquirida pelo agente durante sua interação com o ambiente é convertida em sinais de treinamento que orientam a atualização dos parâmetros θ , permitindo que o comportamento do agente evolua progressivamente em direção a políticas mais eficientes.

2.2.2.1 Redes Neurais Convolucionais

Em muitos problemas de Aprendizado por Reforço Profundo, o agente não recebe como entrada estados simbólicos ou vetores de baixa dimensionalidade, mas sim dados perceptuais complexos, como imagens provenientes de câmeras ou quadros de jogos digitais. Nesses cenários, torna-se necessário um mecanismo capaz de extrair automaticamente representações relevantes a partir dos dados brutos de entrada. As Redes Neurais Convolucionais (LECUN *et al.*, 1989), do inglês, CNNs, desempenham papel fundamental nesse contexto, sendo amplamente utilizadas em tarefas de visão computacional devido à sua capacidade de aprender características espaciais diretamente de imagens.

Diferentemente de redes totalmente conectadas, nas quais cada neurônio está ligado a todos os elementos da entrada, as CNNs exploram a estrutura espacial dos dados por meio da operação de convolução. Nessa operação, pequenos filtros percorrem a imagem realizando produtos internos locais, produzindo mapas de ativação que destacam padrões específicos presentes na entrada. Formalmente, a convolução discreta bidimensional entre uma entrada I e um filtro K pode ser expressa como:

$$S(i, j) = (I \otimes K)(i, j) = \sum_m \sum_n I(i - m, j - n) K(m, n),$$

em que $S(i, j)$ representa o valor produzido na posição (i, j) do mapa de características resultante.

Durante o treinamento, os valores dos filtros convolucionais são aprendidos automaticamente pela rede neural por meio da retropropagação do erro. Dessa forma, diferentes filtros passam a responder a diferentes padrões visuais presentes na imagem. Nas primeiras camadas da rede, os filtros tendem a detectar características simples, como bordas, texturas e contrastes. À medida que a informação se propaga para camadas mais profundas, a rede combina essas características elementares para representar estruturas progressivamente mais complexas, como formas, objetos ou regiões semanticamente relevantes.

Outra propriedade importante das CNNs é o compartilhamento de parâmetros. Como o mesmo filtro é aplicado em diferentes regiões da imagem, o número de parâmetros necessários torna-se significativamente menor em comparação com redes totalmente conectadas. Além de reduzir o custo computacional, essa característica permite que a rede desenvolva invariância translacional parcial, isto é, a capacidade de reconhecer padrões independentemente de sua posição exata na imagem.

Frequentemente, as camadas convolucionais são combinadas com operações de




Figura 4 – Representação esquemática de uma arquitetura CNN, destacando os blocos de extração de características (convolução e pooling) e os blocos de classificação final (camadas densas e softmax).

Fonte: Adaptado de MathWorks (2026).

subamostragem (*pooling*), responsáveis por reduzir a dimensionalidade espacial dos mapas de ativação e aumentar a robustez das representações aprendidas. Em particular, operações como *max-pooling* preservam apenas as ativações mais relevantes de uma região local, contribuindo para a redução de ruído e para a generalização do modelo. A arquitetura geral de uma CNN pode ser visto na figura 4.

No caso do ARP, a CNN atua como um mecanismo de percepção capaz de transformar imagens de alta dimensionalidade em representações compactas e semanticamente relevantes, que posteriormente são utilizadas pela política do agente para a tomada de decisão.

2.2.3 Aprendizado Contínuo

Dentro dos algoritmos de Aprendizado por Reforço, é possível distinguir dois tipos principais: métodos *on-policy* e *off-policy*. Segundo Sutton e Barto (2018), a principal diferença entre essas abordagens está na relação entre a política utilizada para gerar experiências no ambiente e a política efetivamente atualizada durante o aprendizado. Métodos *on-policy* avaliam ou aprimoram a mesma política responsável pela interação atual do agente com o ambiente. Já métodos *off-policy* permitem aprender uma política-alvo distinta daquela utilizada para coletar experiências, desacoplando a política de comportamento da política que está sendo otimizada.

Em algoritmos *on-policy*, a política utilizada para agir no ambiente é exatamente a mesma política que está sendo aprendida. Isso significa que o agente adapta seu comportamento diretamente a partir das experiências produzidas por sua política atual. O processo de aprendizado permanece continuamente alinhado ao modo como o agente percebe, age e interage no ambiente naquele momento específico.

Por outro lado, métodos *off-policy* permitem que o aprendizado utilize experiências

geradas por políticas diferentes da política atual do agente. Assim, a política-alvo pode continuar sendo otimizada utilizando dados coletados anteriormente, experiências produzidas sob estratégias mais exploratórias ou até trajetórias geradas por outros agentes. Dessa forma, o aprendizado deixa de depender exclusivamente da política atualmente em execução.

Essa distinção possui implicações importantes quando analisada sob a perspectiva da IA Enativa. Em abordagens *on-policy*, o aprendizado ocorre de forma fortemente acoplada à política atualmente incorporada pelo agente durante sua interação com o ambiente. A política utilizada para perceber, agir e explorar o mundo é a mesma política continuamente transformada pela experiência vivida. Assim, cognição e adaptação emergem conjuntamente da dinâmica de interação situada entre agente e ambiente.

Sob a ótica da IA Enativa, esse acoplamento reforça a ideia de que o conhecimento não é simplesmente armazenado ou processado de maneira abstrata, mas construído continuamente a partir da própria atividade do agente no mundo. O agente age sobre o ambiente, sofre diretamente as consequências de suas ações e modifica seu comportamento com base nos efeitos produzidos por essa interação contínua. Dessa forma, o aprendizado não aparece como um processo separado da ação, mas como parte integrante do ciclo contínuo de percepção, ação e adaptação, no qual a própria experiência vivida transforma continuamente a política utilizada pelo agente.

Em contraste, métodos *off-policy* introduzem uma separação parcial entre a política responsável pela experiência atual e a política efetivamente aprendida. Embora isso aumente significativamente a eficiência amostral e permita maior reutilização de experiências, o processo de adaptação torna-se menos diretamente dependente da interação presente do agente com o ambiente. Sob a perspectiva enativa, isso reduz parcialmente o vínculo imediato entre cognição e ação situada, aproximando o aprendizado de um processo mais mediado pela reutilização e processamento de experiências previamente coletadas.

2.2.3.1 Métodos de Gradiente de Política

No âmbito dos métodos *on-policy*, uma das primeiras abordagens consolidadas são os métodos de gradiente de política (*Policy Gradient Methods*) (SUTTON *et al.*, 1999). Diferentemente de métodos baseados em função valor, nos quais o agente aprende indiretamente uma política a partir da estimativa de valores de estados ou ações, os métodos de gradiente de política buscam otimizar diretamente a própria política do agente.

Nessa abordagem, a política é parametrizada por um conjunto de parâmetros θ , geralmente representados pelos pesos de uma rede neural, sendo denotada por $\pi_\theta(a|s)$. Essa política define uma distribuição de probabilidade sobre as ações possíveis em cada estado do ambiente. O objetivo do aprendizado consiste em encontrar os parâmetros θ que maximizem o retorno esperado obtido pelo agente ao interagir com o ambiente. Formalmente, deseja-se maximizar:

$$J(\pi_\theta) = \mathbb{E}_{\tau \sim \pi_\theta}[R(\tau)],$$

em que τ representa uma trajetória gerada pela interação entre agente e ambiente. Uma trajetória corresponde à sequência de estados, ações e recompensas observadas durante um episódio de interação, podendo ser representada por:

$$\tau = (s_0, a_0, r_1, s_1, a_1, r_2, \dots, s_T).$$

O termo $R(\tau)$ representa o retorno acumulado ao longo dessa trajetória. Assim, o objetivo do agente é ajustar sua política de modo que trajetórias com maiores retornos tornem-se mais prováveis.

Para isso, os métodos de gradiente de política utilizam o gradiente da função objetivo em relação aos parâmetros da política:

$$\nabla_\theta J(\pi_\theta).$$

A ideia central consiste em aumentar a probabilidade de ações que levaram a retornos elevados e reduzir a probabilidade de ações associadas a retornos menores. Intuitivamente, se determinadas escolhas resultaram em consequências favoráveis ao agente, a política deve ser atualizada para tornar tais ações mais prováveis em situações semelhantes futuras.

A partir do chamado Teorema do Gradiente da Política, é possível escrever o gradiente da política na forma:

$$\nabla_\theta J(\pi_\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^T \nabla_\theta \log \pi_\theta(a_t|s_t) R(\tau) \right].$$

Apesar de estabelecerem uma formulação teórica geral para otimização direta de políticas parametrizadas, métodos de gradiente de política apresentam limitações importantes na prática. Pequenas alterações nos parâmetros podem gerar mudanças significativas no comportamento da política, tornando o treinamento instável. De forma análoga, um pequeno ajuste na

direção de um veículo em alta velocidade pode alterar drasticamente sua trajetória. Em políticas parametrizadas por redes neurais, pequenas atualizações nos parâmetros podem modificar significativamente as probabilidades das ações executadas, fazendo com que o comportamento do agente varie abruptamente entre diferentes etapas do treinamento. Além disso, as estimativas do gradiente frequentemente apresentam alta variância, exigindo grande quantidade de interações com o ambiente para obtenção de aprendizado estável e eficiente.

2.2.3.2 *Trust Region Policy Optimization*

As limitações observadas nos métodos clássicos de gradiente de política motivaram o desenvolvimento de abordagens mais estáveis para atualização da política. Embora esses métodos permitam otimizar diretamente o comportamento do agente, pequenas atualizações nos parâmetros podem provocar mudanças abruptas na distribuição de ações da política, comprometendo o desempenho aprendido anteriormente. Em muitos casos, uma única atualização inadequada é suficiente para fazer o agente perder comportamentos que já haviam sido aprendidos.

Diante desse problema, o *Trust Region Policy Optimization* (TRPO) (SCHULMAN *et al.*, 2015) introduz a ideia de limitar explicitamente o quanto a política pode mudar a cada etapa de treinamento. Em vez de apenas seguir a direção do gradiente de maior recompensa esperada, o TRPO busca garantir que a nova política permaneça suficientemente próxima da política anterior. Assim, o agente continua aprendendo, mas de maneira mais controlada e estável.

Formalmente, o TRPO procura maximizar uma função objetivo associada à vantagem esperada da nova política em relação à política antiga, ao mesmo tempo em que impõe uma restrição sobre a divergência entre ambas:

$$\theta_{k+1} = \arg \max_{\theta} \mathcal{L}(\theta_k, \theta) \quad \text{sujeito a} \quad \bar{D}_{KL}(\theta \| \theta_k) \leq \delta.$$

Nesse contexto, $\mathcal{L}(\theta_k, \theta)$ representa uma aproximação do ganho esperado ao atualizar a política, enquanto $\bar{D}_{KL}$ corresponde à divergência de Kullback-Leibler média entre a política antiga e a nova política. Essa divergência atua como uma medida de diferença entre distribuições de probabilidade, permitindo controlar o quanto o comportamento do agente pode variar entre duas atualizações consecutivas.

Intuitivamente, o TRPO impede que o agente “mude de ideia” de maneira excess-

sivamente brusca. Mesmo que o gradiente indique uma direção potencialmente vantajosa, o algoritmo restringe o tamanho do passo de atualização, garantindo que a política evolua gradualmente. Isso reduz colapsos repentinos de desempenho e produz um processo de aprendizado mais estável.

Apesar de suas vantagens, o TRPO apresenta elevada complexidade computacional. O método exige resolver um problema de otimização restrita relativamente sofisticado, envolvendo aproximações de segunda ordem e cálculos relacionados à matriz Hessiana da divergência KL. Na prática, isso torna sua implementação mais difícil e computacionalmente mais custosa quando comparada a métodos mais simples de gradiente de política.

Ainda assim, o TRPO representou um avanço importante na evolução dos métodos *on-policy*, ao introduzir mecanismos explícitos de estabilidade no processo de atualização da política. Suas ideias serviram posteriormente de base para algoritmos mais simples e eficientes, como o *Proximal Policy Optimization* (PPO), que preserva a intuição central do TRPO, mas reduz significativamente sua complexidade computacional.

2.2.3.3 *Proximal Policy Optimization*

O *Proximal Policy Optimization* (PPO) (SCHULMAN *et al.*, 2017) surge como uma evolução natural das ideias introduzidas pelo TRPO. Assim como seu predecessor, o PPO busca evitar que atualizações excessivamente grandes da política provoquem degradações abruptas de desempenho. Entretanto, em vez de resolver um problema de otimização restrita complexo, o PPO adota uma estratégia significativamente mais simples e eficiente, baseada em um mecanismo denominado *clipping*.

A motivação central permanece a mesma: permitir que o agente aprenda continuamente sem alterar drasticamente seu comportamento entre duas atualizações consecutivas. Em métodos clássicos de gradiente de política, uma atualização muito intensa pode fazer com que a política passe a escolher ações completamente diferentes das anteriores, destruindo comportamentos úteis já aprendidos. O PPO procura limitar esse problema de forma prática e computacionalmente eficiente.

Formalmente, o algoritmo compara a nova política π_θ com a política anterior $\pi_{\theta_{\text{old}}}$ por meio da razão:

$$r_t(\theta) = \frac{\pi_\theta(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)}.$$

Essa razão mede o quanto a nova política aumentou ou reduziu a probabilidade de executar a ação a_t no estado s_t . Valores próximos de 1 indicam poucas mudanças entre as políticas, enquanto valores muito maiores ou menores indicam alterações mais agressivas no comportamento do agente.

A função objetivo do PPO incorpora então um mecanismo de *clipping*, definido por:

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right],$$

em que $\hat{A}_t$ representa a vantagem estimada da ação executada. Intuitivamente, essa vantagem mede o quanto uma ação produziu resultados melhores ou piores do que o esperado pela política atual. Em geral, a vantagem é estimada pela diferença entre o retorno efetivamente obtido após executar a ação e o valor esperado para o estado correspondente, podendo ser expressa por:

$$\hat{A}_t \approx \hat{R}_t - V(s_t),$$

onde $\hat{R}_t$ representa o retorno acumulado observado a partir do instante t , enquanto $V(s_t)$ corresponde à estimativa de valor do estado s_t , isto é, a recompensa esperada ao seguir a política atual a partir desse estado. Dessa forma, vantagens positivas indicam ações que produziram resultados melhores do que o esperado, enquanto vantagens negativas indicam ações menos vantajosas. Já o parâmetro ϵ define o limite permitido para a variação da política entre atualizações consecutivas.

Embora essa expressão matemática pareça complexa, sua ideia intuitiva é relativamente simples. O PPO recompensa mudanças que melhoram o desempenho da política, mas impede que essas mudanças se tornem excessivamente grandes. O mecanismo de *clipping* funciona como um limitador de segurança: quando a nova política tenta alterar demais a probabilidade de determinadas ações, o algoritmo interrompe o benefício adicional dessa mudança.

Por combinar simplicidade computacional, estabilidade de treinamento e boa eficiência empírica, o PPO tornou-se um dos algoritmos *on-policy* mais utilizados em Aprendizado por Reforço Profundo. Sua capacidade de manter um equilíbrio entre exploração, aprendizado contínuo e estabilidade fez com que ele fosse amplamente adotado em aplicações envolvendo ambientes complexos e de alta dimensionalidade.

2.2.4 Exploração, Motivação Intrínseca e Curiosidade

Um dos principais desafios no Aprendizado por Reforço é o chamado dilema de exploração versus exploração. Esse dilema consiste em decidir entre duas estratégias conflitantes: *explorar*, isto é, aproveitar o conhecimento atual para maximizar recompensas imediatas ou *explorar* o ambiente em busca de novas informações que possam levar a recompensas maiores no futuro. Enquanto a exploração tende a ser segura e eficiente no curto prazo, a exploração é essencial para evitar soluções sub-ótimas e descobrir estados potencialmente mais vantajosos.

Esse problema se torna particularmente crítico em ambientes com recompensas esparsas, onde sinais de recompensa são raros e difíceis de encontrar. Nesses cenários, agentes puramente orientados à exploração frequentemente falham, pois não conseguem coletar informação suficiente para aprender políticas eficazes. Assim, mecanismos que incentivem a exploração tornam-se fundamentais.

2.2.4.1 Recompensa Intrínseca

Uma forma de compreender esse desafio é por meio da distinção entre *motivação intrínseca* e *motivação extrínseca*, amplamente estudada na literatura psicológica (RYAN; DECI, 2000). Motivação intrínseca refere-se à realização de uma atividade por seu valor inerente, isto é, pelo interesse, curiosidade ou satisfação associada à própria execução da tarefa. Em contraste, a motivação extrínseca está associada à realização de uma atividade como meio para atingir um objetivo externo, como recompensas, reconhecimento ou evitar punições.

Essa distinção é particularmente relevante porque, embora ambas as formas de motivação possam levar à execução de uma mesma ação, elas diferem fundamentalmente em sua origem e nos comportamentos que incentivam. Enquanto a motivação extrínseca é guiada por consequências externas ao agente, a motivação intrínseca está relacionada a uma propensão natural à exploração, aprendizado e assimilação de novas informações. Em humanos, por exemplo, comportamentos exploratórios frequentemente emergem mesmo na ausência de recompensas explícitas, sendo impulsionados por curiosidade e interesse.

No contexto do Aprendizado por Reforço, essa distinção pode ser reinterpretada de forma análoga: recompensas extrínsecas correspondem aos sinais fornecidos diretamente pelo ambiente, enquanto recompensas intrínsecas são introduzidas artificialmente no agente como forma de incentivar comportamentos desejáveis, como a exploração de estados desconhecidos.

Essa perspectiva tem motivado o desenvolvimento de diversas técnicas que aumentam a função de recompensa com sinais internos ao agente, visando superar limitações impostas por recompensas esparsas ou pouco informativas. Com isso, a recompensa total pode ser definida como:

$$r_t = r_t^{\text{ext}} + r_t^{\text{int}},$$

onde r_t^{ext} é a recompensa extrínseca e r_t^{int} representa a recompensa intrínseca.

Na prática, a recompensa intrínseca pode ser implementada de diferentes maneiras, a depender de quais aspectos do processo de aprendizado se deseja enfatizar. Uma forma de implementar esse tipo de sinal é por meio da noção de *curiosidade* (PATHAK *et al.*, 2017). Nesse contexto, a curiosidade pode ser entendida como a tendência do agente em buscar experiências que revelem limitações em seu conhecimento atual, isto é, situações nas quais sua capacidade de previsão ou compreensão ainda é insuficiente. Dessa forma, estados que são difíceis de prever ou que diferem significativamente da experiência prévia do agente tornam-se mais atrativos.

A partir dessa perspectiva, a curiosidade pode ser formalizada como um tipo de recompensa intrínseca, na qual o agente recebe um bônus adicional ao interagir com estados considerados novos ou informativos. Esse tipo de formulação permite traduzir o comportamento exploratório em um sinal quantitativo, que pode ser incorporado diretamente à função de recompensa.

2.2.4.2 *Random Network Distillation*

Dentro desse contexto, destaca-se o método de *Random Network Distillation* (RND) (BURDA *et al.*, 2018b), proposto como uma forma simples e eficiente de incentivar a exploração em ambientes de alta dimensionalidade. A ideia central do RND é utilizar o erro de predição como medida de novidade.

O método consiste em duas redes neurais: uma rede alvo fixa, inicializada aleatoriamente, e uma rede preditora treinável. Em geral, ambas possuem a mesma arquitetura, normalmente implementada por redes neurais convolucionais quando as observações do ambiente são imagens. Nesse caso, as camadas convolucionais são responsáveis por extrair características espaciais relevantes da entrada, enquanto camadas totalmente conectadas projetam essas características em um espaço latente de menor dimensionalidade.

A rede alvo possui parâmetros fixos, inicializados aleatoriamente no início do treinamento e mantidos inalterados ao longo de toda a execução do algoritmo. Dessa forma, ela define

uma função determinística que mapeia observações do ambiente para representações vetoriais em um espaço de características. Já a rede preditora possui parâmetros treináveis e tem como objetivo aproximar a saída produzida pela rede alvo para uma determinada observação.

O treinamento da rede preditora é realizado por aprendizado supervisionado, utilizando como alvo a saída da rede fixa. Assim, a cada nova observação s_t , a rede preditora ajusta seus parâmetros por meio de descida do gradiente, minimizando o erro quadrático médio (*Mean Squared Error* – MSE) entre sua saída e a saída produzida pela rede alvo. Esse processo é ilustrado na Figura 5.




Figura 5 – Arquitetura do método *Random Network Distillation* (RND). O erro quadrático médio (MSE) entre a saída da Rede Alvo fixa ($f(s_t)$) e a Rede Preditora treinável ($\hat{f}(s_t)$) é utilizado como sinal de curiosidade ou recompensa intrínseca.

A intuição por trás dessa abordagem é que estados frequentemente visitados terão seus padrões bem aprendidos pela rede preditora, resultando em baixo erro de predição. Por outro lado, estados novos ou raros produzirão erros elevados, gerando um forte sinal de recompensa intrínseca que incentiva o agente a explorá-los.

Em síntese, a introdução de mecanismos de curiosidade e motivação intrínseca, como o RND, representa um avanço significativo na resolução do dilema exploração-exploração, permitindo que agentes aprendam de forma mais eficiente em ambientes desafiadores e pouco informativos.

2.2.5 *Análise Visual da Política Apreendida*

Embora mecanismos de motivação intrínseca, como o RND, promovam uma exploração mais eficiente do ambiente, eles também tornam o comportamento do agente mais difícil de interpretar. Isso ocorre porque a política aprendida passa a ser influenciada não apenas por recompensas extrínsecas explícitas, mas também por sinais internos de curiosidade, cuja dinâmica pode não ser imediatamente evidente. Nesse contexto, compreender por que o agente toma determinadas decisões torna-se um desafio fundamental.

Modelos baseados em redes neurais profundas, frequentemente utilizados para representar políticas em Aprendizado por Reforço, são conhecidos por seu alto poder de representação, mas também por sua baixa interpretabilidade. Esses modelos operam como verdadeiras “caixas pretas”, nas quais a relação entre entrada (estado) e saída (ação) não é facilmente compreendida. Assim, mesmo quando o agente apresenta um bom desempenho, torna-se difícil identificar quais aspectos do ambiente estão sendo considerados relevantes para a tomada de decisão.

Uma abordagem promissora para lidar com esse problema é o uso de técnicas de Inteligência Artificial Explicável (XAI), em particular métodos de visualização que permitem identificar regiões da entrada responsáveis por uma determinada decisão.

2.2.5.1 *Gradient-weighted Class Activation Mapping*

Uma das abordagens iniciais para promover interpretabilidade em redes convolucionais é o *Class Activation Mapping* (CAM) (ZHOU *et al.*, 2015), que permite identificar regiões da imagem relevantes para a predição de uma determinada classe. O CAM baseia-se na combinação linear dos mapas de ativação da última camada convolucional, ponderados pelos pesos associados à camada de classificação. Apesar de sua simplicidade e interpretabilidade direta, esse método apresenta limitações importantes, uma vez que requer modificações específicas na arquitetura da rede, como a substituição de camadas totalmente conectadas por operações de *global average pooling*. Essa restrição dificulta sua aplicação em modelos já treinados ou em arquiteturas mais complexas.

Com o objetivo de superar essas limitações, foi proposto o método *Gradient-weighted Class Activation Mapping* (Grad-CAM) (SELVARAJU *et al.*, 2016), que generaliza a ideia do CAM ao utilizar informações de gradiente para estimar a importância dos mapas de ativação, tornando possível sua aplicação em uma ampla variedade de arquiteturas sem a necessidade de

alterações estruturais ou re-treinamento do modelo, a visão panorâmica do método pode ser vista na figura 6.




Figura 6 – Visão panorâmica do método Grad-CAM. A ilustração detalha o fluxo de processamento onde informações de gradiente são utilizadas para ponderar os mapas de características das camadas convolucionais, resultando na geração de um mapa de calor que destaca as regiões relevantes da imagem de entrada para a classificação final.

Fonte: Adaptado de Theocharis (2024).

O Grad-CAM baseia-se na análise dos gradientes do escore de saída de uma classe (ou, no contexto de Aprendizado por Reforço, de uma ação ou valor associado) em relação aos mapas de ativação de uma camada convolucional. Especificamente, os gradientes são utilizados para estimar a importância de cada mapa de ativação na decisão final do modelo. Esses valores de importância são então utilizados para ponderar linearmente os mapas de ativação, gerando um mapa de calor que indica as regiões da entrada mais relevantes para a decisão considerada.

Formalmente, seja y^c o escore associado a uma saída de interesse c , e A^k o k -ésimo mapa de ativação de uma camada convolucional. A importância de cada mapa é dada por:

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k},$$

onde Z representa o número total de elementos no mapa. Em outras palavras, investiga-se como pequenas variações nessas representações internas impactam o valor associado à classe considerada. Regiões cuja variação provoca maior alteração no escore são interpretadas como mais relevantes para a decisão do modelo e são destacadas com maior intensidade, enquanto regiões com pouca ou nenhuma influência apresentam menor intensidade. O mapa de ativação

final é então obtido pela combinação linear dos scores com os mapas de ativação:

$$L_{\text{Grad-CAM}}^c = \text{ReLU} \left(\sum_k \alpha_k^c A^k \right).$$

A aplicação da função ReLU garante que apenas as contribuições positivas, isto é, aquelas que aumentam o escore da saída de interesse, sejam consideradas, resultando em um mapa de calor que destaca evidências favoráveis à decisão do modelo.

No contexto de aprendizagem por reforço, o Grad-CAM pode ser utilizado para analisar visualmente a política aprendida pelo agente. Ao destacar quais regiões do estado observado influenciam determinadas ações, torna-se possível investigar como o agente está utilizando as informações do ambiente, bem como avaliar o impacto de mecanismos de exploração, como o RND, no processo de tomada de decisão. Dessa forma, a combinação entre motivação intrínseca e interpretabilidade contribui não apenas para o desempenho do agente, mas também para uma compreensão mais profunda de seu comportamento.

3 TRABALHOS RELACIONADOS

3.1 Aprendizado por Reforço Profundo

Mnih *et al.* (2013) apresentam um dos primeiros marcos do Aprendizado por Reforço Profundo ao demonstrar que uma rede neural convolucional poderia aprender políticas de controle diretamente a partir de entradas visuais de alta dimensionalidade. Os autores propõem uma arquitetura baseada em *Deep Q-Network* (DQN), na qual quadros brutos de jogos Atari 2600 são utilizados como entrada e a rede estima valores de ação esperados. A abordagem representou uma ruptura em relação a métodos anteriores de Aprendizado por Reforço, pois reduziu a dependência de atributos definidos manualmente e mostrou que uma única arquitetura poderia aprender diferentes tarefas a partir de pixels.

Apesar de sua relevância, o trabalho de Mnih *et al.* (2013) ainda apresenta algumas limitações. A avaliação foi realizada em um conjunto reduzido de jogos, o que limita a generalização dos resultados. Além disso, a aprendizagem do agente permanece fortemente dependente de recompensas extrínsecas definidas pelo ambiente, sem mecanismos internos mais elaborados de exploração ou curiosidade. Assim, o artigo estabelece a base técnica do Aprendizado por Reforço Profundo, mas ainda deixa em aberto questões relacionadas à autonomia e à adaptatividade do agente.

Mnih *et al.* (2015) expandem e consolidam os resultados iniciais do DQN ao avaliar o método em 49 jogos Atari 2600. Nesse trabalho, um único agente, recebendo apenas os pixels da tela e a pontuação do jogo, aprende políticas competitivas utilizando a mesma arquitetura, o mesmo algoritmo e os mesmos hiperparâmetros. O estudo reforça a importância da combinação entre redes neurais convolucionais, *experience replay* e uma rede alvo separada, tornando-se um marco por demonstrar desempenho comparável ao humano em um conjunto amplo de tarefas visuais e sequenciais.

Entretanto, embora Mnih *et al.* (2015) represente um avanço expressivo em desempenho e escala experimental, o método ainda depende de grandes quantidades de interação com o ambiente e apresenta dificuldades em jogos que exigem exploração de longo prazo ou estratégias mais abstratas. Além disso, a recompensa externa permanece como principal guia de aprendizagem. Assim, o trabalho consolida o Aprendizado por Reforço Profundo como uma abordagem poderosa para controle baseado em percepção, mas também evidencia limitações relacionadas à eficiência exploratória.

Como fechamento dessa linha histórica, Hessel *et al.* (2018) mostram como a revolução iniciada pelo DQN motivou uma série de aprimoramentos posteriores. O trabalho combina diferentes extensões do DQN, incluindo Double DQN, *Prioritized Experience Replay*, arquitetura *dueling*, aprendizado multi-etapas, aprendizado distribucional e camadas ruidosas para exploração. Essa combinação alcançou desempenho de estado da arte no benchmark Atari 2600, tanto em eficiência de dados quanto em desempenho final. Ainda assim, para os objetivos desta pesquisa, o Rainbow é tratado principalmente como evidência da relevância histórica do DQN: ele mostra a força dessa família de métodos, mas permanece dentro de uma abordagem centrada na maximização de recompensas externas e em melhorias algorítmicas do aprendizado por valor.

A evolução do Aprendizado por Reforço Profundo, entretanto, não ocorreu apenas pela melhoria de métodos baseados em valor, como o DQN e suas extensões. Paralelamente, outra linha de pesquisa passou a explorar métodos baseados diretamente na otimização da política do agente. Enquanto abordagens como DQN e Rainbow estimam valores de ação para selecionar comportamentos, métodos de gradiente de política buscam ajustar diretamente os parâmetros da política responsável pela escolha das ações. Essa diferença é importante porque permite lidar de forma mais natural com políticas estocásticas, espaços de ação contínuos e problemas nos quais a forma da política aprendida é central para o desempenho do agente.

Um passo intermediário importante nessa direção foi o desenvolvimento de métodos ator-crítico, que combinam a estimação de valor com a otimização direta da política. Em vez de depender apenas de uma função de valor para escolher a ação, esses métodos utilizam um componente ator, responsável pela política, e um componente crítico, responsável por avaliar as ações ou estados. Trabalhos como o A3C, proposto por Mnih *et al.* (2016), mostraram que essa combinação poderia ser escalada de forma eficiente por meio de agentes assíncronos interagindo em paralelo com diferentes cópias do ambiente.

Essa linha de pesquisa abriu espaço para métodos voltados à otimização estável de políticas. O TRPO, proposto por Schulman *et al.* (2015), buscou limitar grandes alterações na política entre atualizações sucessivas, reduzindo o risco de degradações abruptas de desempenho. Embora eficaz, o método possui maior complexidade de implementação. Nesse contexto, o PPO, proposto por Schulman *et al.* (2017), surge como uma alternativa mais simples e prática, preservando a ideia de atualizações controladas da política por meio de uma função objetivo com *clipping*. Assim, o PPO pode ser entendido como uma continuação da transição do Aprendizado

por Reforço Profundo: dos métodos baseados em valor, historicamente importantes no Atari, para métodos on-policy baseados em política, mais flexíveis e amplamente utilizados em problemas modernos de controle.

Essa versatilidade pode ser observada em aplicações de grande escala posteriores ao artigo original. Em Berner *et al.* (2019), o PPO foi utilizado no treinamento do OpenAI Five, um sistema multiagente para o jogo Dota 2. Dota 2¹ é um jogo eletrônico competitivo do gênero *multiplayer online battle arena* (MOBA), no qual duas equipes controlam personagens com habilidades distintas e disputam objetivos estratégicos em um mapa compartilhado. Esse ambiente apresenta desafios como horizonte temporal longo, informação imperfeita, alta dimensionalidade e coordenação entre agentes. Por meio de treinamento distribuído em larga escala e autojogo, o sistema foi capaz de derrotar a equipe campeã mundial, evidenciando que métodos baseados em política podem ser escalados para tarefas complexas, dinâmicas e parcialmente observáveis.

Mais recentemente, o PPO também passou a ter papel importante fora do domínio clássico de jogos e controle. Em Ouyang *et al.* (2022), os autores utilizam Aprendizado por Reforço com Feedback Humano para ajustar modelos de linguagem a preferências humanas. Nesse processo, após uma etapa de ajuste supervisionado e treinamento de um modelo de recompensa, o PPO é empregado para otimizar a política do modelo de linguagem. Os resultados mostram que modelos menores ajustados com feedback humano podem ser preferidos a modelos maiores treinados apenas por predição de texto, indicando a relevância do PPO em problemas modernos de alinhamento e interação humano-máquina.

No campo da robótica, Yang *et al.* (2024) demonstram que o PPO continua sendo explorado em aplicações recentes e desafiadoras. O trabalho propõe o ClothPPO, uma estrutura para manipulação robótica de roupas em espaços de ação muito grandes e alinhados à observação visual. A abordagem combina pré-treinamento supervisionado com uma etapa posterior de refinamento por PPO, permitindo melhorar a política em uma tarefa de manipulação de objetos deformáveis. Esse resultado reforça a atualidade do PPO como método flexível para otimizar políticas em domínios que envolvem percepção visual, ação contínua ou de alta dimensionalidade e adaptação a dinâmicas complexas.

Um trabalho relevante sobre agentes em tarefas de forrageamento é apresentado por Mesquita *et al.* (2020), no qual os autores propõem um agente autônomo em um cenário com alimentos e venenos distribuídos pelo ambiente. A tarefa é modelada como um problema de

¹ Página oficial do jogo: <<https://www.dota2.com>>.

Aprendizado por Reforço Profundo, no qual imagens coloridas simulam a visão do agente e são processadas por uma rede neural convolucional. A partir dessas entradas visuais, um algoritmo baseado em SARSA aprende a selecionar ações que permitem ao agente buscar alimento e evitar venenos, demonstrando a viabilidade de combinar percepção visual e aprendizado por reforço em uma tarefa de forrageamento.

Embora o trabalho demonstre resultados importantes, algumas limitações podem ser observadas. A principal delas é o uso de uma recompensa extrínseca definida previamente, que já especifica quais interações devem ser valorizadas pelo agente, como buscar alimento e evitar veneno. Com isso, parte do comportamento desejado é introduzida diretamente pela função de recompensa, reduzindo a possibilidade de avaliar se o agente desenvolveria critérios próprios de relevância a partir da interação com o ambiente. Além disso, a avaliação concentra-se principalmente na curva de recompensa acumulada, o que dificulta uma análise mais detalhada dos comportamentos efetivamente aprendidos ao longo do treinamento. A interpretação da política aprendida também é limitada, pois não há uma investigação visual mais aprofundada sobre quais regiões ou elementos da observação influenciam as decisões do agente.

Também no contexto de forrageamento em ambientes virtuais, Filho *et al.* (2024) investigam agentes multissensoriais no cenário *Health-Gathering* da plataforma VizDoom (WYD-MUCH *et al.*, 2018). O trabalho parte da observação de que grande parte dos agentes de Aprendizado por Reforço Profundo depende predominantemente de informação visual, embora organismos naturais utilizem múltiplas modalidades sensoriais para navegar e localizar recursos. Para isso, os autores propõem uma estratégia de treinamento baseada em currículo, na qual o agente é gradualmente levado a utilizar tanto visão quanto áudio como fontes de informação. Os resultados indicam que, sem esse currículo, agentes com visão e audição tendem a ignorar o áudio quando a informação visual é suficiente. Entretanto, quando treinados de forma gradual, tornam-se mais robustos em cenários nos quais a visão é limitada ou indisponível.

Apesar desses resultados, algumas limitações podem ser observadas. A dependência de uma estratégia de currículo indica que a integração entre modalidades sensoriais não emerge de forma direta apenas pela disponibilidade dos canais de visão e áudio, exigindo uma organização cuidadosa do processo de treinamento. Além disso, a avaliação se concentra principalmente no desempenho final e na robustez diante da ausência de visão, deixando menos claro como o agente combina efetivamente as informações visuais e sonoras ao longo da tomada de decisão.

3.2 Função de Recompensa e Suas Implicações

A dependência de recompensas externas também levanta um problema central para o Aprendizado por Reforço Profundo: a engenharia de recompensa. Em princípio, a função de recompensa deveria expressar o comportamento desejado pelo projetista, na prática, porém, especificar essa função de forma completa é difícil, pois pequenas escolhas de modelagem podem levar o agente a otimizar atalhos indesejados. Esse problema é discutido por Amodei *et al.* (2016) como uma questão de especificação de objetivos: quando a recompensa observável não captura adequadamente a intenção humana, o agente pode maximizar o sinal recebido sem realizar o comportamento realmente esperado. A dificuldade, portanto, não está apenas em ajustar pesos ou penalidades, mas em transformar uma expectativa externa sobre o comportamento do agente em um critério fixo de valor.

Esse tipo de falha é frequentemente descrito como *reward hacking* ou *specification gaming*. Krakovna *et al.* (2020) definem esse fenômeno como um comportamento que satisfaz literalmente a especificação formal de um objetivo, mas sem alcançar o resultado realmente pretendido pelo projetista. O problema ocorre quando há uma diferença entre aquilo que se queria produzir no mundo e aquilo que foi efetivamente codificado como métrica, recompensa ou critério de avaliação. Nesses casos, o agente não precisa compreender a intenção humana por trás da tarefa, sendo assim, basta encontrar uma estratégia que maximize o sinal disponível.

Um exemplo apresentado por Krakovna *et al.* (2020) é a tarefa de empilhamento de blocos de Lego. O objetivo pretendido era fazer com que um bloco vermelho terminasse sobre um bloco azul. Entretanto, a recompensa foi definida com base na altura da face inferior do bloco vermelho quando ele não estivesse tocando o bloco azul. Em vez de realizar a manobra mais difícil de levantar o bloco vermelho e empilhá-lo corretamente, o agente simplesmente virou o bloco vermelho, elevando sua face inferior e obtendo recompensa sem cumprir o objetivo pretendido. A Figura 7 ilustra esse tipo de falha de especificação.

A importância desse exemplo está em mostrar que o comportamento do agente pode ser considerado bem-sucedido do ponto de vista do algoritmo, pois ele encontrou uma maneira eficiente de maximizar a recompensa especificada. No entanto, do ponto de vista do objetivo pretendido, o comportamento revela uma falha na formulação da tarefa. Assim, o problema não decorre necessariamente de uma deficiência do algoritmo de Aprendizado por Reforço, mas da distância entre a intenção do projetista e sua tradução em uma função objetivo. Como discutem Krakovna *et al.* (2020), a mesma capacidade de encontrar soluções inesperadas pode ser vista




Figura 7 – Exemplo esquemático de *specification gaming* em uma tarefa de empilhamento de Lego. O agente satisfaz a métrica especificada, elevar a face inferior do bloco vermelho, sem realizar o objetivo pretendido de empilhar o bloco vermelho sobre o azul.

Fonte: Adaptado de Popov *et al.* (2017).

como sinal de criatividade algorítmica em benchmarks, mas torna-se problemática quando se espera que o agente realize uma intenção específica no mundo.

De modo semelhante, Lehman *et al.* (2020) mostram, a partir de relatos da computação evolucionária e vida artificial, que processos de otimização podem produzir soluções criativas, mas também surpreendentes e indesejadas, quando a medida de desempenho não corresponde ao objetivo pretendido. Esses resultados indicam que o problema não está apenas no algoritmo de aprendizagem, mas na própria tentativa de reduzir comportamentos complexos a uma função objetivo externa e fixa. Quando a recompensa é usada para reforçar diretamente um comportamento específico, o agente tende a repetir a estratégia que satisfaz esse critério, mesmo que o contexto mude ou que existam alternativas mais adequadas. Nesse caso, a recompensa deixa de promover inteligência adaptativa e passa a cristalizar um padrão de ação previamente imaginado pelo projetista.

Para esta pesquisa, essa discussão é importante porque reforça a limitação de tratar a recompensa apenas como uma especificação explícita do projetista. Em tarefas de forrageamento,

por exemplo, recompensas manuais podem induzir comportamentos úteis, como coletar alimento e evitar dano, mas ainda dependem de uma interpretação externa sobre o que deve ser relevante para o agente. Essa dependência é especialmente problemática quando o objetivo é produzir personagens autônomos e inteligentes, pois um agente desse tipo não deveria apenas executar uma rotina recompensada independentemente do que ocorre ao seu redor. Espera-se que ele reconheça mudanças na dinâmica do ambiente, reorganize sua ação e descubra modos de comportamento que talvez não tenham sido antecipados pela engenharia de recompensas. Assim, a recompensa não deveria funcionar como um mecanismo para forçar uma solução definida de antemão, possivelmente limitada ou subótima, mas como parte de uma estrutura que favoreça a busca por soluções.

A implicação mais profunda dessa crítica diz respeito à produção de sentido. Ao definir uma recompensa explícita, o projetista não apenas orienta o aprendizado do agente, mas também atribui previamente um significado às interações: sobreviver, alcançar um estado desejado, passar uma fase, coletar um recurso ou evitar uma ameaça. O problema é que essa atribuição parte da perspectiva de um observador externo, e não da perspectiva do próprio agente. Em termos próximos aos de Varela (1991), há uma diferença entre o ambiente observado e o mundo vivido pelo organismo: o ambiente corresponde ao domínio físico descrito externamente, enquanto o mundo corresponde ao domínio de interações significativas que emerge para o próprio sistema em sua atividade. Portanto, quando o significado da tarefa é totalmente dado pela recompensa, corre-se o risco de substituir o domínio de significância do agente por uma leitura externa do que deveria importar. A perspectiva enativa sugere justamente esse deslocamento: em vez de apenas projetar recompensas para impor um comportamento desejado, torna-se relevante investigar como sinais de valor podem emergir da relação entre o agente, suas estruturas internas, suas condições de viabilidade e seu acoplamento estrutural com o ambiente. Nesse sentido, apenas o próprio agente, por meio de sua dinâmica interna e de sua história de interação, poderia constituir um domínio próprio de relevâncias, em vez de apenas receber de fora o significado de seus objetivos.

3.3 Aprendizado Enativo

Esta seção aproxima a discussão anterior sobre recompensas externas de uma perspectiva enativa para o aprendizado de agentes. Nos trabalhos revisados até aqui, o comportamento do agente é geralmente orientado por objetivos definidos previamente, principalmente por uma

função de recompensa explícita. A abordagem enativa desloca esse foco: em vez de tratar percepção, ação e valor como componentes separados, ela enfatiza o acoplamento contínuo entre agente e ambiente, no qual o significado das interações emerge da própria história de atividade do agente. Assim, o interesse principal passa a ser compreender como um sistema pode construir regularidades sensório-motoras, reconhecer possibilidades de ação e organizar seu comportamento a partir de sua experiência.

Um trabalho diretamente relacionado a essa perspectiva é apresentado por Georgeon *et al.* (2013), que propõem o modelo *Enactive Markov Decision Process* (EMDP). Sua principal contribuição é reformular o problema clássico de Aprendizado por Reforço ao tratar percepção e ação como uma única unidade de interação sensório-motora. Assim, em vez de selecionar uma ação isolada para depois receber uma observação e uma recompensa, o agente aprende a realizar interações com o ambiente, avaliando seu sucesso ou fracasso a partir da própria experiência. Essa mudança desloca o foco da maximização de recompensas externas para a aprendizagem de regularidades no acoplamento entre agente e mundo.

No EMDP, a motivação do agente está ligada à construção e ao domínio de sequências de interação. O agente passa a preferir interações que consegue realizar com sucesso e a organizar comportamentos mais complexos a partir dessas regularidades aprendidas. Esse ponto é importante porque aproxima o aprendizado artificial da perspectiva enativa, segundo a qual conhecer não é apenas representar o ambiente, mas agir nele de modo recorrente e significativo. Ainda assim, permanece em aberto como conectar essa automotivação a condições internas de viabilidade, adaptação e precariedade do próprio agente. Em outras palavras, falta explicar como o valor das interações pode depender também do estado interno do sistema que age.

Uma contribuição posterior nessa direção é apresentada por Nogueira *et al.* (2020), que investigam a autonomia intrínseca por meio de computação evolucionária em um ambiente aberto. O trabalho parte da crítica de que algoritmos evolucionários tradicionais, quando guiados por uma função de aptidão previamente definida, ainda descrevem externamente o comportamento esperado do agente. Em resposta a essa limitação, os autores propõem o EMOTIONAL, um algoritmo no qual a dinâmica de seleção é internalizada no próprio agente e vinculada à sua atividade contínua no ambiente, sem descrição explícita de objetivos, métricas de avaliação ou dinâmicas cooperativas. Nesse modelo, um robô virtual possui uma variável interna de energia, que diminui com sua atividade, pode ser reduzida por interações prejudiciais e pode ser recuperada por interações favoráveis. Assim, a precariedade do agente funciona como

pressão adaptativa: o comportamento não emerge porque o projetista definiu diretamente tarefas como “coletar frutas” ou “evitar venenos”, mas porque certas interações afetam a continuidade do próprio sistema.

Os resultados mostram a emergência de comportamentos de navegação e forrageamento em um ambiente com frutas, venenos e obstáculos, mesmo sem uma função objetivo que especifique diretamente essas ações. Os sinais sensoriais precisam ser incorporados à dinâmica do agente ao longo de sua história de interação, de modo que uma fruta não é tratada desde o início como recompensa no sentido clássico do Aprendizado por Reforço, mas adquire relevância porque modifica o estado corporal do agente e interfere em sua permanência em atividade. Para esta pesquisa, esse trabalho é relevante porque explora uma noção mais forte de autonomia comportamental, na qual o valor da experiência passa a depender da relação entre ação, percepção, energia interna e acoplamento com o ambiente. Ao mesmo tempo, o estudo evidencia desafios, pois a ausência de uma função de aptidão explícita torna a avaliação dos comportamentos menos direta e os caminhos evolutivos continuam influenciados pelos parâmetros internos do algoritmo e pelas regras do ambiente.

Outro ponto importante é desenvolvido por Nogueira *et al.* (2016), que enfatizam a riqueza sensorial e ambiental como condição para a emergência de comportamentos mais complexos em personagens virtuais autônomos. O trabalho compara formas de acoplamento sensório-motor e mostra que sistemas perceptivos mais expressivos, como visão baseada em câmera virtual, permitem comportamentos mais sensíveis ao ambiente do que sensores de proximidade mais simples, reduzindo limitações como pontos cegos e movimentos repetitivos. Ao relacionar visão, energia, ação e sobrevivência, o estudo reforça que a complexidade do ambiente e dos canais perceptivos influencia diretamente os tipos de regularidades que o agente pode construir. Assim, essa contribuição é importante porque mostra que a autonomia enativa não depende apenas de retirar uma função objetivo externa, mas também de oferecer um acoplamento suficientemente rico para que o agente possa constituir formas próprias de relevância e adaptação.

Ao final, esse panorama é reforçado por Filho e Nogueira (2022), que analisam implementações práticas de IA Enativa a partir dos critérios teóricos propostos para agência e para sistemas enativos. Os autores observam que a área ainda possui forte desenvolvimento conceitual e relativamente poucos experimentos práticos. A análise indica que muitos trabalhos conseguem satisfazer condições gerais de agência, mas encontram maior dificuldade em implementar princípios mais exigentes da IA Enativa, especialmente aqueles ligados à autonomia constitutiva

e à adaptatividade. Esse diagnóstico é importante porque mostra que o desafio não está apenas em produzir agentes capazes de agir no ambiente, mas em construir sistemas cujo comportamento esteja ligado à própria organização interna e à manutenção de suas condições de existência.

3.4 Aprendizado por Curiosidade

O aprendizado por curiosidade aparece no Aprendizado por Reforço Profundo como uma forma de fazer o agente explorar melhor o ambiente sem depender apenas de recompensas externas. Em vez de receber valor somente quando cumpre um objetivo definido pelo ambiente, o agente também pode receber sinais internos ligados à novidade, à incerteza ou à dificuldade de prever o que acontece depois de suas ações. Essa ideia é importante porque muda parcialmente a origem da recompensa. A interação passa a ter valor não apenas porque o projetista disse que ela é importante, mas também porque ela revela algo novo para o próprio agente.

Um exemplo importante dessa linha é o trabalho de Bellemare *et al.* (2016). Os autores retomam a ideia de exploração por contagem, comum em métodos mais clássicos, e a adaptam para ambientes com observações complexas, como imagens de jogos Atari. Como nesses ambientes não é simples contar estados de forma direta, o trabalho usa modelos de densidade para estimar pseudocontagens. Assim, estados menos conhecidos recebem um bônus de exploração. A solução é interessante porque leva uma ideia simples, visitar mais o que ainda é pouco conhecido, para cenários visuais de alta dimensionalidade. Ainda assim, esse tipo de recompensa continua muito ligado à novidade estatística da observação. Ele ajuda o agente a explorar regiões pouco visitadas, mas não garante que essa exploração tenha relação com necessidades internas ou com a manutenção do próprio agente.

Outra contribuição central é o módulo de curiosidade intrínseca proposto por Pathak *et al.* (2017). Nesse método, a curiosidade é calculada a partir do erro de predição das consequências das ações do agente em um espaço de características aprendido de forma autossupervisionada. Um ponto forte dessa abordagem é o uso de um modelo inverso, que ajuda a dar mais peso aos aspectos do ambiente que dependem das ações do agente. Com isso, o método tenta evitar que o agente seja recompensado por mudanças que ele não controla.

Os experimentos foram realizados principalmente nos ambientes VizDoom (WYD-MUCH *et al.*, 2018) e Super Mario Bros.². No VizDoom, os autores avaliaram cenários com recompensa extrínseca esparsa e também situações sem recompensa externa, investigando se o

² Wikipédia do Super Mario Bros: <https://pt.wikipedia.org/wiki/Super_Mario_Bros>.

sinal de curiosidade seria suficiente para levar o agente a explorar o ambiente de forma eficiente. Em Super Mario Bros., além da exploração sem recompensa, o trabalho analisou a generalização para fases não vistas, mostrando que a experiência adquirida em uma fase podia acelerar a exploração em outra. Esses resultados indicam que a curiosidade pode auxiliar tanto quando a recompensa externa é rara quanto quando ela está ausente, funcionando como um sinal interno capaz de orientar a exploração sem depender diretamente de uma recompensa manual associada ao objetivo final da tarefa.

O estudo de Burda *et al.* (2018a) leva essa discussão adiante ao investigar agentes treinados apenas por curiosidade, ou seja, os agentes não recebem recompensas externas durante o treinamento. Os experimentos foram conduzidos em larga escala, envolvendo 54 ambientes de benchmark, incluindo jogos Atari, Super Mario Bros. e ambientes de navegação 3D em Unity³. Os autores também investigaram diferentes espaços de características para calcular o erro de predição, comparando representações aleatórias e representações aprendidas. Em jogos Atari, características aleatórias foram suficientes para produzir comportamentos competitivos em vários casos, enquanto em Super Mario Bros. as características aprendidas apresentaram melhor generalização para fases novas.

Como descrito na Seção 2.2.4.2, o *Random Network Distillation* (RND) utiliza erro de predição como medida de novidade. No artigo original, Burda *et al.* (2018b) avaliam esse mecanismo principalmente em jogos Atari de exploração difícil, nos quais recompensas extrínsecas são raras e agentes treinados apenas com PPO tendem a explorar pouco. Os experimentos comparam políticas treinadas com recompensa extrínseca, métodos de curiosidade baseados em dinâmica e políticas treinadas com RND, analisando especialmente jogos como Montezuma's Revenge⁴.

Os resultados mostram que o RND melhora a exploração nesses ambientes e permite ao agente alcançar regiões do jogo que dificilmente seriam descobertas apenas por recompensas externas esparsas. Em alguns casos, como no do Montezuma's Revenge, o método apresenta desempenho substancialmente superior ao PPO sem recompensa intrínseca. Ainda assim, os experimentos permanecem centrados na capacidade de visitar estados novos e melhorar pontuações em benchmarks. O valor do estado continua associado à novidade estatística da observação, sem considerar diretamente condições internas de viabilidade ou precariedade do

³ Unity é uma plataforma e motor de desenvolvimento de jogos e simulações interativas. Página oficial: <<https://unity.com>>.

⁴ Wikipédia do jogo Montezuma's Revenge: <[https://en.wikipedia.org/wiki/Montezuma%27s_Revenge_\(video_game\)](https://en.wikipedia.org/wiki/Montezuma%27s_Revenge_(video_game))>.

agente.

Esses trabalhos mostram que a curiosidade pode ser usada de várias formas dentro do Aprendizado por Reforço Profundo. Ela pode aparecer como erro de predição, único sinal de aprendizagem ou destilação de redes aleatórias. Para os objetivos desta pesquisa, porém, a principal limitação dessa literatura é que a curiosidade costuma estar ligada à novidade da informação em si. Ela ajuda o agente a explorar, mas nem sempre explica por que certas experiências deveriam importar para ele. Por isso, esses trabalhos são uma ponte importante entre recompensas externas e sinais internos de aprendizagem, mas ainda deixam espaço para investigar formas de recompensa intrínseca mais próximas de processos enativos, nas quais o valor da interação depende da relação entre percepção, ação, estado interno e adaptação.

4 METODOLOGIA

Este capítulo apresenta a proposta metodológica deste trabalho, cujo objetivo é conectar o arcabouço teórico discutido nos capítulos anteriores com uma investigação prática em Aprendizado por Reforço Profundo. A pesquisa parte da hipótese de que a autonomia artificial pode ser investigada de modo mais adequado quando o comportamento do agente não é orientado apenas por recompensas externas, mas também por condições internas de viabilidade. Nesse sentido, a metodologia proposta busca construir um cenário experimental no qual percepção, curiosidade e precariedade estejam diretamente relacionadas.

Ao longo do capítulo, serão comentados os principais elementos necessários para a construção desse experimento, incluindo o ambiente *Health-Gathering*, a formulação em Aprendizado por Reforço, o algoritmo PPO, a estratégia de recompensa, o glaucoma artificial, a recompensa intrínseca por curiosidade, as configurações experimentais, as métricas de avaliação e as análises comportamentais e visuais. A descrição detalhada de cada um desses pontos será desenvolvida nas seções correspondentes.

4.1 Ambiente Experimental

O ambiente escolhido para os experimentos é o cenário *Health-Gathering*, da plataforma VizDoom (WYDMUCH *et al.*, 2018). Nesse cenário, o agente está situado em uma sala cujo chão causa perda contínua de vida. Para sobreviver por mais tempo, ele pode coletar *medikits*, itens distribuídos no ambiente que restauram sua vida. A Figura 8 apresenta uma visão superior desse cenário, destacando a distribuição dos *medikits* no ambiente.

Além disso, o *Health-Gathering* permite formular uma tarefa visual de navegação e forrageamento. O agente percebe o ambiente por meio de imagens da tela e deve selecionar ações que o mantenham em interação com o mundo. Essa característica aproxima o problema de cenários de Aprendizado por Reforço Profundo baseados em percepção visual, ao mesmo tempo em que fornece uma estrutura simples para investigar sobrevivência, busca por recursos e adaptação.

No contexto do VizDoom, um *tick* corresponde a uma unidade discreta de atualização do jogo. A cada *tick*, o ambiente atualiza seus elementos internos, como posição do agente, estado dos objetos, valor de vida e observação visual disponível. Assim, o episódio pode ser entendido como uma sequência finita de *ticks*, durante os quais o agente observa o ambiente,




Figura 8 – Visão superior do cenário *Health-Gathering*. Os itens em formato de “+” representam os *medikits* distribuídos no ambiente, que podem ser coletados pelo agente para restaurar sua vida.

Fonte: Elaborada pelo autor

escolhe ações e sofre as consequências dessas ações. Na configuração experimental adotada, cada episódio terá duração máxima de 2100 *ticks*, podendo terminar antes caso a vida do agente chegue a zero.

A perda de vida ocorre continuamente porque o chão do cenário é ácido. O agente inicia cada episódio com 100 pontos de vida, que também correspondem à sua vida máxima, e perde 8 pontos de vida a cada 36 *ticks*, independentemente da ação escolhida. Os *medikits* funcionam como recursos de recuperação: ao serem coletados, restauram 25 pontos de vida do agente. O ambiente conterá 16 *medikits* disponíveis simultaneamente, posicionados aleatoriamente no início do episódio. Novos *medikits* surgirão a cada 30 *ticks* do jogo, mantendo a dinâmica de busca por recursos ao longo do episódio.

Os principais elementos do ambiente padrão, portanto, incluem a vida inicial e máxima do agente, a duração máxima dos episódios, a taxa de perda de vida no chão ácido, a quantidade de *medikits* disponíveis, a quantidade de vida restaurada por cada item e a regra de surgimento dos novos *medikits*. Esses elementos definem a dinâmica básica de sobrevivência e coleta de recursos do cenário *Health-Gathering*.

4.2 Formulação em Aprendizado por Reforço

Como discutido na Seção 2.2.1, o Aprendizado por Reforço modela a interação entre agente e ambiente como um processo sequencial de observação, ação, transição de estado e recompensa. Nesta pesquisa, o cenário *Health-Gathering* será formulado a partir dessa estrutura: a cada instante de tempo, o agente recebe uma observação visual do ambiente, escolhe uma ação e recebe um sinal de recompensa. Em seguida, o ambiente é atualizado e uma nova observação é produzida. Esse ciclo se repete até o fim do episódio, que pode ocorrer quando a vida do agente chega a zero ou quando o limite máximo de *ticks* é atingido.

4.2.1 Observação

As observações serão compostas por imagens do ponto de vista do agente. Assim, o agente não receberá uma representação simbólica do ambiente, como coordenadas absolutas dos *medikits* ou mapas completos da sala, mas sim informações visuais para um personagem situado no cenário.

As imagens passarão por uma sequência fixa de pré-processamento, ilustrada na Figura 9. A observação original fornecida pelo ambiente possui resolução de 320×240 pixels em RGB. Em seguida, a imagem será convertida para escala de cinza, reduzindo os três canais de cor para um único canal de intensidade. Depois, será redimensionada para 161×161 pixels. Por fim, os valores dos pixels serão normalizados para o intervalo $[0, 1]$, em vez da escala original de 0 a 255. Essas transformações têm como objetivo reduzir o custo computacional do treinamento e padronizar a entrada recebida pela rede neural, preservando as informações visuais relevantes para a navegação e para a identificação dos *medikits*.




Figura 9 – Etapas de pré-processamento da observação visual do agente: imagem RGB original com resolução de 320×240 pixels, conversão para escala de cinza, redimensionamento para 161×161 pixels e normalização dos valores para o intervalo $[0, 1]$.

Fonte: Elaborada pelo autor

4.2.2 Ação

O conjunto de ações será composto por três comandos discretos de navegação: ir em frente, virar à esquerda e virar à direita. Essas ações permitem que o agente explore a sala e se desloque em direção aos recursos disponíveis, mantendo a formulação do problema simples e adequada aos objetivos iniciais da pesquisa.

4.2.3 Recompensa

No cenário *Health-Gathering*, a recompensa extrínseca padrão é definida pela própria tarefa: o agente recebe +1 a cada *tick* do jogo em que permanece vivo e recebe -100 quando morre. Essa formulação associa diretamente o sinal de recompensa à sobrevivência, fazendo com que o agente seja explicitamente incentivado a durar mais tempo no ambiente.

Neste trabalho, entretanto, essa recompensa extrínseca será zerada. Essa decisão evita que a solução do problema seja introduzida diretamente na função de recompensa e permite investigar formas alternativas de orientação comportamental. A recompensa utilizada nos experimentos será detalhada nos próximos capítulos, especialmente na discussão sobre motivação intrínseca e curiosidade artificial.

4.3 Algoritmo de Aprendizado

A política do agente será treinada por meio do algoritmo *Proximal Policy Optimization* (PPO). Como apresentado na Seção 2.2.3.3, o PPO é um método *on-policy* que busca atualizar a política de forma estável, evitando mudanças abruptas entre a política usada para coletar experiências e a nova política aprendida.

Essa característica mantém uma relação direta entre a experiência vivida pelo agente no ambiente e a atualização de seu comportamento. O agente age no cenário, sofre as consequências de suas ações, percebe o ambiente atualiza sua política a partir dessa trajetória de interação. Dessa forma, o PPO oferece uma base prática para investigar a relação entre percepção, ação, curiosidade e viabilidade em um ambiente visual.

Nesta seção, serão descritos os principais elementos necessários para a implementação do algoritmo de aprendizado, incluindo os hiperparâmetros utilizados e a arquitetura da rede neural.

4.3.1 Hiperparâmetros

Entre os hiperparâmetros adotados para o PPO, destacam-se o tamanho do lote de treinamento, a taxa de aprendizado e o fator de desconto, apresentados na Tabela 1.

Tabela 1 – Hiperparâmetros principais utilizados no PPO.

Parâmetro	Valor	Descrição
batch_size	256	Número de amostras utilizadas em cada lote de treinamento.
lr	0,00025	Taxa de aprendizado utilizada na atualização dos parâmetros.
discount	0,999	Fator de desconto aplicado aos retornos futuros.

4.3.2 Arquitetura da Rede Neural

A arquitetura da rede neural será responsável por transformar a observação visual pré-processada em uma representação latente utilizada pela política do agente. Como a entrada é uma imagem em escala de cinza, o modelo utiliza um codificador convolucional inspirado na arquitetura Mnih *et al.* (2013). A Tabela 2 apresenta a arquitetura utilizada.

Tabela 2 – Arquitetura da rede neural utilizada pelo agente.

Etapa	Camada	Configuração	Saída
1	Convolutacional 2D	$1 \rightarrow 32$, kernel 8×8 , stride 4×4	32 mapas de características
2	ReLU	Ativação não linear	32 mapas de características
3	Convolutacional 2D	$32 \rightarrow 64$, kernel 4×4 , stride 2×2	64 mapas de características
4	ReLU	Ativação não linear	64 mapas de características
5	Convolutacional 2D	$64 \rightarrow 32$, kernel 3×3 , stride 1×1	32 mapas de características
6	ReLU	Ativação não linear	32 mapas de características
7	Flatten	Vetorização das ativações	1568 unidades
8	Linear	$1568 \rightarrow 512$	512 unidades
9	ReLU	Ativação não linear	512 unidades
10	Linear	Linear $512 \rightarrow 3$	3 valores de ação

O codificador convolucional extrai características espaciais da observação visual, enquanto a camada linear projeta essas características para uma representação compacta de 512 unidades. A primeira camada não convolucional utiliza essa representação para produzir os valores associados às ações disponíveis para a política.

4.4 Estratégia de Recompensa

4.4.1 *O Problema da Recompensa*

A escolha da recompensa é um dos pontos centrais desta proposta metodológica. Um personagem artificial considerado inteligente não deve apenas repetir um comportamento fixo independentemente do que ocorre ao seu redor. Pelo contrário, espera-se que ele seja capaz de perceber mudanças no ambiente, compreender a dinâmica da situação em que está inserido e agir de maneira flexível. Nesse sentido, a inteligência não é entendida apenas como a execução eficiente de uma ação previamente desejada, mas como a capacidade de encontrar formas de ação adequadas diante de diferentes condições.

Reforçar diretamente um comportamento específico tende a produzir agentes que executam apenas aquele comportamento. Embora isso possa resolver uma tarefa delimitada, também pode tornar o agente monótono e limitar a descoberta de soluções melhores, que talvez não tenham sido previstas pelo projetista durante a engenharia de recompensas. Assim, quando a recompensa força uma solução, ela pode impedir que o agente explore outras possibilidades de ação que também resolveriam o problema, ou até o resolveriam de maneira mais robusta.

Esse problema retoma a discussão apresentada na fundamentação teórica sobre Aprendizado por Reforço, na qual a recompensa aparece como o sinal que orienta a atualização da política do agente (Seção 2.2.1). Como o agente aprende a maximizar a recompensa acumulada, a forma como esse sinal é definido não é um detalhe apenas técnico, pois ela delimita o que será considerado desejável dentro do processo de aprendizagem. Por isso, a engenharia de recompensas pode resolver tarefas específicas, mas também pode introduzir diretamente a solução esperada pelo projetista.

Essa distinção conduz ao problema conceitual discutido na fundamentação filosófica. Se a inteligência pode ser entendida como um fenômeno emergente da vida, isto é, como algo que surge de uma organização capaz de manter a si mesma em relação contínua com o ambiente (Seção 2.1.2), então não basta associar a palavra “vida” a uma variável numérica do ambiente. Em Aprendizado por Reforço, o agente não está propriamente trabalhando para se manter vivo. O que ele faz é maximizar um sinal numérico de recompensa acumulada. Mesmo quando a recompensa está associada ao tempo de sobrevivência, o agente não compreende esse número como vida. Para o algoritmo, trata-se apenas de um valor a ser aumentado.

Assim, dizer que o agente “quer sobreviver” é apenas uma metáfora. O problema em

si não possui significado para ele, a menos que a própria organização do agente e de sua interação com o ambiente produza algum domínio de relevância. Por isso, recompensar diretamente a coleta de *medikits*, a navegação até uma região ou o tempo de sobrevivência resolveria parte do problema experimental, mas manteria a orientação do comportamento inteiramente dependente de uma especificação externa. A proposta, portanto, não é eliminar a recompensa, pois ela continua sendo necessária ao funcionamento do Aprendizado por Reforço, mas deslocar seu papel, para que, em vez de funcionar como uma instrução direta sobre qual ação executar, ela favoreça a exploração e a busca por soluções.

4.4.2 Autopoiese, IA Enativa e Perspectiva de Solução

É nesse ponto que a Inteligência Artificial Enativa oferece uma motivação conceitual importante. Na perspectiva de Maturana e Varela (1980), a vida não é apenas a posse de uma variável chamada vida, mas uma dinâmica de autoprodução e manutenção de uma unidade que se diferencia do ambiente. Um ser vivo existe porque há uma dinâmica interna que trabalha continuamente para manter sua própria organização. Essa dinâmica depende do ambiente, pois os recursos necessários à sua continuidade precisam ser encontrados e incorporados. Por isso, a vida possui uma dimensão intencional, na qual o organismo se orienta no ambiente a partir daquilo que importa para a manutenção de sua própria existência.

A noção de autopoiese permite compreender essa relação. Um sistema autopoietico é uma dinâmica que produz e mantém a si mesma, distinguindo-se do meio em que está inserida. Essa manutenção, porém, não está garantida de antemão. O sistema permanece exposto a perturbações e depende de condições de viabilidade para continuar existindo. É essa exposição permanente à possibilidade de perda de organização que caracteriza a precariedade. Assim, a precariedade não é apenas uma limitação externa, mas aquilo que torna certas interações relevantes para o próprio sistema.

Essa perspectiva está diretamente ligada à fundamentação filosófica discutida no Capítulo 2, especialmente à relação entre autopoiese, acoplamento estrutural, produção de sentido e Inteligência Artificial Enativa. Os trabalhos relacionados a essa abordagem indicam que a autonomia não deve ser entendida apenas como execução eficiente de uma política, mas como a capacidade de agir a partir de uma organização, sensível às próprias condições de viabilidade (MATURANA; VARELA, 1980; VARELA, 1991; FROESE; ZIEMKE, 2009).

Com base nessa leitura, a perspectiva de solução adotada neste trabalho consiste em

introduzir uma forma artificial de precariedade no agente. A função dessa precariedade é fazer com que a condição interna do agente tenha consequências sobre sua relação com o ambiente. Em vez de dizer diretamente que coletar *medikits* é desejável, busca-se criar uma dinâmica em que ficar muito tempo sem recuperar sua condição interna afete suas possibilidades de perceber, explorar e continuar interagindo.

Dessa forma, a precariedade serve como mediação entre vida, percepção e ação. Ela transforma a viabilidade em uma condição prática para que o agente continue produzindo experiências visualmente informativas. A coleta de recursos pode então tornar-se relevante não porque foi imposta como objetivo final pela função de recompensa, mas porque preserva as condições que permitem ao agente explorar o ambiente.

A questão metodológica passa a ser, portanto, como introduzir a precariedade no agente. Se a proposta é fazer com que a condição interna afete a própria relação perceptiva com o ambiente, é necessário definir um mecanismo capaz de degradar e recuperar a percepção de acordo com essa condição. No experimento proposto, esse papel será desempenhado pelo glaucoma artificial, apresentado na seção seguinte.

4.5 Glaucoma como Precariedade

O glaucoma artificial é o mecanismo escolhido para materializar, no experimento, a precariedade discutida na seção anterior. Sua função não é apenas dificultar a tarefa visual do agente, mas tornar a condição interna de viabilidade relevante para a própria percepção. Enquanto o agente permanece sem coletar *medikits*, sua visão se degrada progressivamente. Quando coleta um *medikit*, essa degradação é removida. Desse modo, a precariedade deixa de aparecer como uma penalidade externa na função de recompensa e passa a atuar diretamente sobre a forma como o agente acessa o ambiente.

Essa escolha é importante porque conecta o problema da recompensa à perspectiva enativa adotada neste trabalho. Se o agente recebesse uma recompensa direta por coletar *medikits*, o comportamento esperado estaria explicitamente especificado pelo projetista. Com o glaucoma artificial, por outro lado, a coleta de recursos passa a ter importância indireta, pois preserva as condições perceptivas necessárias para que o agente continue explorando o ambiente. Assim, o glaucoma funciona como uma forma computacional de precariedade, pois traduz a passagem do tempo sem recuperação interna em perda progressiva de capacidade perceptiva.

A Figura 10 ilustra a evolução do efeito visual esperado em quatro momentos. A

primeira imagem apresenta a visão limpa do agente, após 0 *frames* sem comer, ou seja, o agente acabou de usar um *medikit*. A segunda mostra um glaucoma inicial, após 1 *frame* sem comer. A terceira mostra uma degradação mais acentuada, após 20 *frames* sem comer. A quarta e última mostra uma degradação severa, após 50 *frames* sem comer. Esse tipo de transformação representa a ideia de que um agente em pior condição interna não deixa apenas de receber pontos, mas passa a perceber o mundo de modo mais limitado.




Figura 10 – Evolução da percepção visual do agente com glaucoma artificial de força 100. Da esquerda para a direita, a figura mostra a visão limpa após 0 *frames* sem comer, glaucoma inicial após 1 *frame*, degradação intermediária após 20 *frames* e degradação severa após 50 *frames*.

Fonte: Elaborada pelo autor

Do ponto de vista implementacional, a velocidade de crescimento do glaucoma será controlada por uma variável do programa, chamada força do glaucoma. Essa variável define quantos pixels passam a sofrer degradação a cada *tick* em que o agente permanece sem coletar um *medikit*. Por exemplo, se a força do glaucoma tiver valor 100, então, a cada *tick* sem comer, mais 100 pixels serão afetados pelo glaucoma. De modo geral, se a força do glaucoma tiver valor x , então o glaucoma crescerá x pixels por *tick* sem recuperação. Quando o agente coleta um *medikit*, o nível de glaucoma é reiniciado e a percepção volta ao estado sem degradação.

Os pixels afetados pelo glaucoma seguem um padrão espacial definido do centro para as bordas da imagem. A degradação começa ao redor do ponto central da observação e se expande progressivamente formando um quadrado em torno de si mesmo. A cada atualização, novos pixels são incorporados à região degradada, aumentando o tamanho desse quadrado pixel a pixel. Dessa forma, o glaucoma não surge aleatoriamente na imagem, mas cresce de maneira ordenada, produzindo uma perda visual progressiva e espacialmente estruturada.

Formalmente, a evolução do glaucoma pode ser representada por uma variável g_t , que indica a quantidade acumulada de pixels afetados no instante t . Se o agente não coleta um *medikit*, então $g_{t+1} = g_t + x$, em que x representa a força do glaucoma definida no programa. Se ocorre a coleta, então $g_{t+1} = 0$. Esse valor determina o tamanho da região quadrada degradada

aplicada à observação antes que ela seja entregue à rede neural do agente.

Com isso, o glaucoma estabelece uma relação direta entre estado interno e percepção. Quanto maior o tempo sem recuperação, maior a degradação visual. Quanto mais cedo o agente encontra um recurso, mais rapidamente recupera sua percepção. A hipótese metodológica é que essa relação possa favorecer comportamentos adaptativos sem que a coleta de *medikits* precise ser recompensada diretamente. O modo proposto para transformar essa precariedade corporal em sinal de recompensa será apresentado na seção seguinte, por meio de recompensa intrínseca baseada em curiosidade e implementada com RND.

4.6 Recompensa Intrínseca por Curiosidade

Esta seção apresenta o ponto em que a precariedade corporal introduzida pelo glaucoma artificial é transformada em sinal de recompensa. Como discutido na Seção 4.4.1, o agente de Aprendizado por Reforço não age porque compreende a vida ou a sobrevivência como valores próprios. Ele ajusta sua política para maximizar uma recompensa acumulada, conforme a formulação de Aprendizado por Reforço apresentada na Seção 2.2.1. Por isso, a contribuição metodológica deste trabalho consiste em deslocar a recompensa de uma instrução direta, como coletar *medikits*, para uma consequência indireta da precariedade corporal.

A ideia central é que quanto mais precário estiver o corpo artificial do agente, menor deve ser a recompensa obtida por sua interação com o ambiente. De modo complementar, quanto menos precário estiver esse corpo, maior tende a ser a recompensa. Com isso, o agente não é recompensado diretamente por estar vivo ou por coletar um recurso específico. Ele é levado a buscar condições menos precárias porque essas condições preservam sua capacidade de perceber um ambiente mais rico e informativo. Assim, a recompensa passa a favorecer a manutenção do agente dentro de restrições de viabilidade, retomando a discussão sobre autopoiese, precariedade e IA Enativa desenvolvida na Seção 4.4.2.

Essa formulação também dialoga com os trabalhos relacionados discutidos no Capítulo 3. Em particular, trabalhos de Aprendizado por Reforço Profundo mostraram a eficácia de agentes treinados a partir de entradas visuais e recompensas escalares, mas permaneceram fortemente dependentes de objetivos externos definidos pelo ambiente ou pelo projetista. Já trabalhos relacionados à autonomia e à motivação intrínseca indicam a importância de sinais internos para orientar o comportamento, mas ainda deixam em aberto como relacionar esses sinais a uma condição corporal de precariedade. Este trabalho procura ocupar justamente esse

espaço, articulando percepção degradada, viabilidade e recompensa.

A recompensa total utilizada pelo agente será definida como a soma entre recompensa extrínseca e recompensa intrínseca, conforme a formulação discutida na fundamentação teórica sobre recompensa intrínseca:

$$r_t = r_t^{\text{ext}} + r_t^{\text{int}}.$$

Neste experimento, entretanto, a recompensa extrínseca será zerada, como definido na Subseção 4.4.1 e na formulação da recompensa do ambiente. Assim, tem-se:

$$r_t^{\text{ext}} = 0$$

e, conseqüentemente:

$$r_t = r_t^{\text{int}}.$$

4.6.1 Calculando a Recompensa Intrínseca

A recompensa intrínseca será calculada por meio do método *Random Network Distillation* (RND), apresentado na Seção 2.2.4.2. No RND, uma rede alvo fixa produz uma representação da observação, enquanto uma rede preditora tenta aproximar essa representação. O erro de predição entre essas redes funciona como medida de novidade. Observações mais ricas, variadas ou menos conhecidas tendem a produzir maior erro de predição e, portanto, maior recompensa intrínseca.

Os hiperparâmetros adotados para o RND são apresentados na Tabela 3. Esses valores definem o tamanho do lote de treinamento, a taxa de aprendizado da rede preditora, a ponderação inicial da recompensa intrínseca e a taxa de decaimento dessa ponderação. A arquitetura do codificador utilizada no RND será a mesma parte convolucional empregada na rede do PPO, descrita na Tabela 2.

A recompensa intrínseca final utilizada pelo agente será modulada pelos parâmetros β e κ . O parâmetro β controla a intensidade inicial da recompensa intrínseca, enquanto κ define a taxa de decaimento dessa influência ao longo do tempo. Assim, no instante t , a recompensa intrínseca modulada pode ser representada por:

Tabela 3 – Hiperparâmetros principais utilizados no RND.

Parâmetro	Valor	Descrição
batch_size	256	Tamanho do lote utilizado no treinamento do RND.
lr	0,001	Taxa de aprendizado utilizada na atualização da rede preditora.
beta	1,0	Coefficiente inicial de ponderação da recompensa intrínseca.
kappa	0,0	Taxa de decaimento do coeficiente de ponderação da recompensa intrínseca.

$$r_t^{\text{int}} = r_{t,\text{RND}}^{\text{int}} \beta e^{-\kappa t}.$$

Nesse caso, $r_{t,\text{RND}}^{\text{int}}$ representa a recompensa intrínseca calculada pelo erro de predição do RND antes da modulação temporal.

Neste contexto, o glaucoma interfere diretamente nesse mecanismo porque altera a informação visual disponível ao agente. Quando o nível de glaucoma é alto, a imagem torna-se progressivamente mais escura e menos informativa, como descrito na Seção 4.5. Com menos informação visual, a observação tende a produzir menor erro no RND, pois há menos estrutura perceptiva a ser diferenciada e explorada. Nesse cenário de maior precariedade, a curiosidade artificial tende a ser menor e, conseqüentemente, a recompensa intrínseca também diminui.

Por outro lado, quando o agente se encontra em uma condição menos precária, sua percepção permanece menos degradada. A imagem contém mais elementos do ambiente, mais variação visual e mais possibilidades de novidade. Nessa condição, o erro de predição do RND tende a ser maior, produzindo maior recompensa intrínseca. A recompensa, portanto, não é uma ordem direta para coletar *medikits*, mas uma consequência da relação entre corpo, percepção e exploração. O agente é favorecido quando preserva condições perceptivas menos precárias, pois essas condições ampliam sua possibilidade de encontrar novidade no ambiente.

4.6.2 Hipótese

Dessa forma, a precariedade corporal é convertida em sinal de recompensa por meio da própria percepção. O glaucoma atua sobre a imagem observada. A imagem observada afeta o erro de predição do RND. Esse erro define a recompensa intrínseca usada pelo PPO durante o treinamento. A hipótese metodológica é que esse encadeamento faça o agente lutar por condições

menos precárias, mantendo-se dentro das restrições de viabilidade sem que a coleta de *medikits* precise ser imposta como objetivo extrínseco.

4.7 Configurações Experimentais

Para avaliar a proposta, pretende-se comparar o desempenho do agente em três condições principais de recompensa. A primeira condição utilizará recompensa zerada, isto é, sem qualquer sinal extrínseco ou intrínseco orientando diretamente o aprendizado. A segunda condição utilizará a recompensa extrínseca padrão do ambiente *Health-Gathering*, definida pelo VizDoom. A terceira condição utilizará apenas recompensa intrínseca, calculada por meio do método *Random Network Distillation* (RND).

Cada uma dessas condições será avaliada sob diferentes intensidades de glaucoma artificial. Serão utilizadas forças de glaucoma iguais a 0, 20, 40, 60, 80 e 100, permitindo observar como o grau de degradação perceptiva interfere no aprendizado e no tempo de sobrevivência do agente. Desse modo, os experimentos combinam diferentes formas de recompensa com diferentes níveis de precariedade visual.

Essas configurações permitirão investigar se a precariedade perceptiva modifica o comportamento do agente. Em especial, busca-se observar se o agente passa a coletar *medikits* não porque essa ação foi diretamente recompensada, mas porque evitar o crescimento do glaucoma favorece a continuidade da exploração e da obtenção de recompensa intrínseca.

4.8 Métricas de Avaliação

A avaliação dos agentes deverá considerar tanto métricas quantitativas quanto análises qualitativas do comportamento aprendido. A principal métrica quantitativa será o tamanho do episódio, isto é, o tempo de sobrevivência do agente em cada configuração experimental. Essa medida permitirá comparar o desempenho obtido sem recompensa, com a recompensa extrínseca padrão do VizDoom e apenas com recompensa intrínseca baseada em RND, sempre considerando as diferentes forças de glaucoma definidas para o experimento.

Também será analisado o gráfico de recompensa intrínseca ao longo do treinamento. Nessa análise, pretende-se associar a cena observada pelo agente ao valor de recompensa intrínseca produzido pelo RND, verificando se a precariedade visual percebida pelo agente está sendo convertida em recompensa intrínseca na intensidade esperada. Assim, será possível avaliar

se observações mais informativas tendem a gerar maior novidade perceptiva e se observações mais degradadas pelo glaucoma reduzem adequadamente esse sinal.

Por fim, serão realizadas análises comportamentais a partir de diferentes distribuições espaciais dos *medikits* no cenário. Os recursos serão organizados em formatos de quadrado, círculo, *grid* e seno, conforme ilustrado na Figura 11, permitindo observar a trajetória do agente em cada arranjo. Essa análise buscará verificar se o caminho percorrido pelo agente é condizente com a disposição dos recursos e se a política aprendida apresenta padrões de navegação coerentes com a estrutura do ambiente.




Figura 11 – Distribuições espaciais dos *medikits* utilizadas nas análises comportamentais. Da esquerda para a direita, são apresentadas as distribuições em quadrado, círculo, *grid* e seno. Os sinais de “+” indicam os *medikits*, enquanto o ponto vermelho indica a posição inicial do agente no episódio.

Fonte: Elaborada pelo autor.

A adoção de distribuições fixas tem como objetivo tornar a análise das trajetórias mais controlada e comparável entre diferentes execuções. Em cenários com distribuição aleatória de *medikits*, uma configuração específica poderia facilitar excessivamente a sobrevivência do agente, caso os recursos surgissem próximos à posição inicial ou em regiões de fácil acesso. Por outro lado, outra configuração poderia dificultar de forma desproporcional o desempenho, caso os recursos fossem posicionados em regiões distantes ou pouco acessíveis. Ao utilizar arranjos fixos, torna-se possível avaliar de maneira mais clara se o comportamento aprendido acompanha a estrutura espacial dos recursos, reduzindo a influência de variações ocasionais na disposição dos *medikits*.

4.9 Análise Visual da Política Aprendida

Para complementar a avaliação, pretende-se utilizar técnicas de interpretabilidade visual, como Grad-CAM, discutido na Seção 2.2.5.1. O objetivo é identificar quais regiões da observação influenciam as decisões do agente. A Figura 12 apresenta um exemplo ilustrativo

desse tipo de visualização no cenário *Health-Gathering*. Essa análise é especialmente importante porque o agente atua a partir de imagens e porque a proposta do trabalho depende da relação entre percepção, curiosidade e viabilidade.




Figura 12 – Exemplo ilustrativo de mapa de calor inspirado em Grad-CAM aplicado ao cenário *Health-Gathering*. As regiões mais quentes indicam as áreas da observação com maior relevância para a decisão do agente, isto é, aquelas que mais importam na análise visual da política aprendida.

Fonte: Elaborada pelo autor.

Com o Grad-CAM, será possível investigar se o agente direciona sua atenção para elementos relevantes do ambiente, como *medikits*, regiões navegáveis ou obstáculos. Também será possível comparar mapas de ativação em diferentes níveis de degradação perceptiva, buscando compreender como a precariedade visual altera os elementos considerados relevantes pela política.

Essa etapa não tem apenas função técnica, mas também conceitual. Se a proposta busca discutir autonomia e produção de relevância, é necessário analisar não apenas se o agente obtém bom desempenho, mas também como ele utiliza as informações disponíveis para agir. A interpretabilidade visual, portanto, servirá como ferramenta auxiliar para compreender a política aprendida.

5 RESULTADOS

Este capítulo apresenta apenas um recorte inicial dos resultados obtidos. Como esta etapa do trabalho tem caráter de proposta, o objetivo não é antecipar a análise experimental completa, mas apenas indicar que a metodologia descrita no capítulo anterior já pode ser executada e observada em um cenário controlado. Assim, os resultados apresentados aqui devem ser entendidos como uma amostra preliminar, suficiente para ilustrar a viabilidade do experimento, deixando a avaliação sistemática para a continuidade da pesquisa.

5.1 Resultados Iniciais

Para evitar antecipar a comparação completa entre todas as configurações experimentais, foi selecionado apenas um caso simples de análise. O recorte apresentado considera a distribuição circular dos *medikits* e glaucoma artificial com força igual a 0. Nessa condição, não há degradação perceptiva ao longo do episódio, de modo que o agente percebe o ambiente sem perda progressiva de informação visual. Neste experimento, os agentes foram treinados por 4 milhões de passos de interação com o ambiente.

Mesmo nesse cenário inicial, é possível comparar três formas distintas de orientação do comportamento, sendo elas a execução sem recompensa, a execução com a recompensa extrínseca padrão do ambiente e a execução utilizando apenas recompensa intrínseca baseada em RND. Essa comparação não tem como objetivo estabelecer conclusões definitivas sobre o desempenho de cada abordagem, mas apenas mostrar como o comportamento do agente pode ser observado a partir das trajetórias produzidas em uma mesma configuração espacial.




Figura 13 – Trajetórias do agente no cenário circular com força de glaucoma igual a 0, considerando três condições experimentais: sem recompensa, com recompensa extrínseca padrão e apenas com recompensa intrínseca baseada em RND.

Fonte: Elaborada pelo autor.

A Figura 13 permite observar, de forma qualitativa, como diferentes sinais de recompensa produzem padrões distintos de deslocamento. Na configuração sem recompensa, o agente segue uma trajetória predominantemente aleatória, sem evidência de orientação consistente em direção aos recursos. Com a recompensa extrínseca padrão, a trajetória assume um padrão circular, acompanhando a disposição dos *medikits* e indicando um comportamento de perseguição desses recursos. Já na configuração com recompensa intrínseca baseada em RND, o agente não se desloca de forma ampla pelo cenário, em vez disso, permanece próximo ao canto inicial e passa a girar, produzindo variações perceptivas suficientes para obter sinal de curiosidade sem necessariamente explorar o ambiente de maneira mais distribuída.

Este recorte é propositalmente limitado. A força de glaucoma igual a 0 remove justamente o elemento de precariedade corporal que motiva a proposta principal deste trabalho. Nesse caso, não há degradação visual progressiva e, portanto, a percepção do agente não se torna mais precária ao longo do tempo. O resultado funciona, assim, como um ponto de partida: ele mostra o comportamento do agente quando o mecanismo de degradação ainda não exerce influência sobre sua experiência perceptiva.

A questão central permanece em aberto para a próxima etapa da pesquisa. Se, com glaucoma de força 0, não há degradação do corpo artificial e o aprendizado ainda não é plenamente mobilizado pela precariedade, o que acontecerá quando a força do glaucoma aumentar? Será que uma degradação perceptiva mais intensa, ao tornar a manutenção da condição interna mais relevante para a exploração, poderá favorecer o surgimento de um comportamento mais adaptativo?

6 CONCLUSÃO

Este trabalho apresentou uma proposta metodológica para investigar autonomia em agentes artificiais a partir da relação entre Aprendizado por Reforço Profundo, motivação intrínseca e condições internas de viabilidade. Em vez de tratar o agente apenas como um sistema orientado por recompensas externas, a metodologia propõe um cenário em que a sobrevivência, a percepção visual e a precariedade corporal simulada estejam diretamente relacionadas. Dessa forma, o ambiente *Health-Gathering* é assumido como um espaço experimental adequado para observar como diferentes formas de recompensa podem influenciar o comportamento de um agente situado.

A proposta articula o uso do algoritmo PPO, de observações visuais pré-processadas, de recompensas extrínsecas e intrínsecas e de um mecanismo de glaucoma artificial responsável por degradar progressivamente a percepção do agente. Essa escolha metodológica permite transformar conceitos discutidos na fundamentação teórica, como autonomia, viabilidade, curiosidade e acoplamento com o ambiente, em elementos observáveis dentro de uma tarefa computacional. Assim, o objetivo não é apresentar resultados definitivos nesta etapa, mas delimitar um caminho experimental capaz de sustentar a investigação nas fases seguintes da pesquisa.

Como continuidade, a pesquisa deverá executar e comparar as configurações experimentais propostas, considerando diferentes intensidades de glaucoma, diferentes estratégias de recompensa e diferentes distribuições espaciais dos *medikits*. As métricas de sobrevivência, recompensa intrínseca e análise das trajetórias deverão permitir avaliar se a precariedade perceptiva modifica a forma como o agente explora o ambiente e busca manter sua viabilidade. Com isso, espera-se que a metodologia contribua para discutir em que medida mecanismos de motivação intrínseca podem aproximar agentes artificiais de uma noção mais situada e operacional de autonomia.

REFERÊNCIAS

- AMODEI, D.; OLAH, C.; STEINHARDT, J.; CHRISTIANO, P.; SCHULMAN, J.; MANÉ, D. Concrete problems in ai safety. **CoRR**, abs/1606.06565, 2016. Disponível em: <<https://arxiv.org/abs/1606.06565>>.
- BARANDIARAN, X.; PAOLO, E. D.; ROHDE, M. Defining agency: Individuality, normativity, asymmetry, and spatio-temporality in action. **Adaptive Behavior**, v.17, 367-386 (2009), v. 17, 09 2009.
- BELLEMARE, M. G.; SRINIVASAN, S.; OSTROVSKI, G.; SCHAUL, T.; SAXTON, D.; MUNOS, R. Unifying count-based exploration and intrinsic motivation. In: **Proceedings of the 30th International Conference on Neural Information Processing Systems**. Red Hook, NY, USA: Curran Associates Inc., 2016. (NIPS'16), p. 1479–1487. ISBN 9781510838819.
- BERNER, C.; BROCKMAN, G.; CHAN, B.; CHEUNG, V.; DĘBIAK, P.; DENNISON, C.; FARHI, D.; FISCHER, Q.; HASHME, S.; HESSE, C.; JÓZEFOWICZ, R.; GRAY, S.; OLSSON, C.; PACHOCKI, J.; PETROV, M.; PINTO, H.; RAIMAN, J.; SALIMANS, T.; SCHLATTER, J.; ZHANG, S. **Dota 2 with Large Scale Deep Reinforcement Learning**. 2019.
- BURDA, Y.; EDWARDS, H.; PATHAK, D.; STORKEY, A. J.; DARRELL, T.; EFROS, A. A. Large-scale study of curiosity-driven learning. **CoRR**, abs/1808.04355, 2018. Disponível em: <<http://arxiv.org/abs/1808.04355>>.
- BURDA, Y.; EDWARDS, H.; STORKEY, A. J.; KLIMOV, O. Exploration by random network distillation. **CoRR**, abs/1810.12894, 2018. Disponível em: <<http://arxiv.org/abs/1810.12894>>.
- Di Paolo, E. Autopoiesis, adaptivity, teleology, agency. 12 2005. Disponível em: <https://sussex.figshare.com/articles/journal_contribution/Autopoiesis_adaptivity_teleology_agency/23368025>.
- FILHO, C. R.; NOGUEIRA, Y. L. B. Analyzing enactive ai implementations on enactive ai terms. **Research Square**, 2022. Disponível em: <<https://doi.org/10.21203/rs.3.rs-2251292/v1>>.
- FILHO, R. F. F.; SANTOS, A. M. M.; RODRIGUES, H. R.; NOGUEIRA, Y. L. B.; VIDAL, C. A.; CAVALCANTE-NETO, J. B.; SERAFIM, P. B. S. Using curriculum to train multisensory foraging DRL agents. In: **Anais do XXIII Simpósio Brasileiro de Jogos e Entretenimento Digital (SBGames)**. Porto Alegre, RS, Brasil: SBC, 2024. p. 456–473.
- FROESE, T.; ZIEMKE, T. Enactive artificial intelligence: Investigating the systemic organization of life and mind. **Artificial Intelligence**, v. 173, n. 3, p. 466–500, 2009. ISSN 0004-3702. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0004370208002105>>.
- GEORGEON, O. L.; WOLF, C.; GAY, S. An enactive approach to autonomous agent and robot learning. In: **2013 IEEE Third Joint International Conference on Development and Learning and Epigenetic Robotics (ICDL)**. [S.l.: s.n.], 2013. p. 1–6.
- GIGNAC, G. E.; SZODORAI, E. T. Defining intelligence: Bridging the gap between human and artificial perspectives. **Intelligence**, v. 104, p. 101832, 2024. ISSN 0160-2896. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0160289624000266>>.

HELSEL, M.; MODAYIL, J.; HASSELT, H. van; SCHAUL, T.; OSTROVSKI, G.; DABNEY, W.; HORGAN, D.; PIOT, B.; AZAR, M.; SILVER, D. Rainbow: combining improvements in deep reinforcement learning. In: **Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence and Thirtieth Innovative Applications of Artificial Intelligence Conference and Eighth AAAI Symposium on Educational Advances in Artificial Intelligence**. [S.l.]: AAAI Press, 2018. (AAAI'18/IAAI'18/EAAI'18). ISBN 978-1-57735-800-8.

KRAKOVNA, V.; UESATO, J.; MIKULIK, V.; RAHTZ, M.; EVERITT, T.; KUMAR, R.; KENTON, Z.; LEIKE, J.; LEGG, S. **Specification gaming: the flip side of AI ingenuity**. 2020. <<https://deepmind.google/discover/blog/specification-gaming-the-flip-side-of-ai-ingenuity/>>. Acessado em: 18 de maio de 2026.

LECUN, Y.; BOSER, B.; DENKER, J. S.; HENDERSON, D.; HOWARD, R. E.; HUBBARD, W.; JACKEL, L. D. Backpropagation applied to handwritten zip code recognition. **Neural Computation**, v. 1, n. 4, p. 541–551, 1989.

LEHMAN, J.; CLUNE, J.; MISEVIC, D.; ADAMI, C.; ALTENBERG, L.; BEAULIEU, J.; BENTLEY, P. J.; BERNARD, S.; BESLON, G.; BRYSON, D. M.; CHENEY, N.; CULLY, A.; DONCIEUX, S.; DYER, F. C.; ELLEFSEN, K. O.; FELDT, R.; FISCHER, S.; FORREST, S.; FRÉNOY, A.; GAGNÉ, C.; GOFF, L. L.; GRABOWSKI, L. M.; HODJAT, B.; HUTTER, F.; KELLER, L.; KNIBBE, C.; KRCAH, P.; LENSKI, R. E.; LIPSON, H.; MACCURDY, R.; MAESTRE, C.; MIIKKULAINEN, R.; MITRI, S.; MORIARTY, D. E.; MOURET, J.-B.; NGUYEN, A.; OFRIA, C.; PARIZEAU, M.; PARSONS, D.; PENNOCK, R. T.; PUNCH, W. F.; RAY, T. S.; SCHOENAUER, M.; SCHULTE, E.; SIMS, K.; STANLEY, K. O.; TADDEI, F.; TARAPORE, D.; THIBAUT, S.; WEIMER, W.; WATSON, R.; YOSINSKI, J. The surprising creativity of digital evolution: A collection of anecdotes from the evolutionary computation and artificial life research communities. **Artificial Life**, v. 26, n. 2, p. 274–306, 2020.

MathWorks. **What Is a Convolutional Neural Network?** 2026. Acessado em: 8 de maio de 2026. Disponível em: <<https://www.mathworks.com/discovery/convolutional-neural-network.html>>.

MATURANA, H.; VARELA, F. **Autopoiesis and Cognition: The Realization of the Living**. [S.l.]: Reidel, 1980.

MESQUITA, A.; NOGUEIRA, Y.; VIDAL, C.; CAVALCANTE-NETO, J.; SERAFIM, P. Autonomous Foraging with SARSA-based Deep Reinforcement Learning. In: **2020 22nd Symposium on Virtual and Augmented Reality (SVR)**. Porto de Galinhas, Brazil: IEEE, 2020. p. 425–433. ISBN 978-1-7281-9231-4. Disponível em: <<https://ieeexplore.ieee.org/document/9262697/>>.

MNIH, V.; BADIA, A. P.; MIRZA, M.; GRAVES, A.; LILLICRAP, T.; HARLEY, T.; SILVER, D.; KAVUKCUOGLU, K. Asynchronous methods for deep reinforcement learning. In: BALCAN, M. F.; WEINBERGER, K. Q. (Ed.). **Proceedings of The 33rd International Conference on Machine Learning**. New York, New York, USA: PMLR, 2016. (Proceedings of Machine Learning Research, v. 48), p. 1928–1937. Disponível em: <<https://proceedings.mlr.press/v48/mniha16.html>>.

MNIH, V.; KAVUKCUOGLU, K.; SILVER, D.; GRAVES, A.; ANTONOGLOU, I.; WIERSTRA, D.; RIEDMILLER, M. Playing atari with deep reinforcement learning. 12 2013.

Mnih, V.; Kavukcuoglu, K.; Silver, D.; Rusu, A. A.; Veness, J.; Bellemare, M. G.; Graves, A.; Riedmiller, M.; Fidjeland, A. K.; Ostrovski, G.; Petersen, S.; Beattie, C.; Sadik, A.; Antonoglou, I.; King, H.; Kumaran, D.; Wierstra, D.; Legg, S.; Hassabis, D. Human-level control through deep reinforcement learning. **Nature**, v. 518, n. 7540, p. 529–533, fev. 2015.

NOGUEIRA, Y. L. B.; BRITO, C. E. F. de; VIDAL, C. A.; CAVALCANTE-NETO, J. B. Towards intrinsic autonomy through evolutionary computation. **Artificial Intelligence Review**, v. 53, n. 6, p. 4449–4473, ago. 2020. ISSN 1573-7462. Disponível em: <<https://doi.org/10.1007/s10462-019-09798-1>>.

NOGUEIRA, Y. L. B.; Fisch de Brito, C. E.; VIDAL, C. A.; Cavalcante Neto, J. B. Emergent vision system of autonomous virtual characters. **Neurocomputing**, v. 173, p. 1851–1867, 2016. ISSN 0925-2312. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0925231215013922>>.

OUYANG, L.; WU, J.; JIANG, X.; ALMEIDA, D.; WAINWRIGHT, C.; MISHKIN, P.; ZHANG, C.; AGARWAL, S.; SLAMA, K.; RAY, A.; SCHULMAN, J.; HILTON, J.; KELTON, F.; MILLER, L.; SIMENS, M.; ASKELL, A.; WELINDER, P.; CHRISTIANO, P. F.; LEIKE, J.; LOWE, R. Training language models to follow instructions with human feedback. In: KOYEJO, S.; MOHAMED, S.; AGARWAL, A.; BELGRAVE, D.; CHO, K.; OH, A. (Ed.). **Advances in Neural Information Processing Systems**. Curran Associates, Inc., 2022. v. 35, p. 27730–27744. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2022/file/b1efde53be364a73914f58805a001731-Paper-Conference.pdf>.

PATHAK, D.; AGRAWAL, P.; EFROS, A. A.; DARRELL, T. Curiosity-driven exploration by self-supervised prediction. In: **Proceedings of the 34th International Conference on Machine Learning - Volume 70**. [S.l.]: JMLR.org, 2017. (ICML'17), p. 2778–2787.

POPOV, I.; HEESS, N.; LILLICRAP, T. P.; HAFNER, R.; BARTH-MARON, G.; VECERÍK, M.; LAMPE, T.; TASSA, Y.; EREZ, T.; RIEDMILLER, M. A. Data-efficient deep reinforcement learning for dexterous manipulation. **CoRR**, abs/1704.03073, 2017. Disponível em: <<http://arxiv.org/abs/1704.03073>>.

POZZA, N. D.; BUFFONI, L.; MARTINA, S.; CARUSO, F. Quantum reinforcement learning: the maze problem. **Quantum Machine Intelligence**, Springer Science and Business Media LLC, v. 4, n. 1, maio 2022. ISSN 2524-4914. Disponível em: <<http://dx.doi.org/10.1007/s42484-022-00068-y>>.

RYAN, R. M.; DECI, E. L. Intrinsic and extrinsic motivations: Classic definitions and new directions. **Contemporary Educational Psychology**, v. 25, n. 1, p. 54–67, 2000. ISSN 0361-476X. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0361476X99910202>>.

SCHULMAN, J.; LEVINE, S.; MORITZ, P.; JORDAN, M. I.; ABBEEL, P. Trust region policy optimization. **CoRR**, abs/1502.05477, 2015. Disponível em: <<http://arxiv.org/abs/1502.05477>>.

SCHULMAN, J.; WOLSKI, F.; DHARIWAL, P.; RADFORD, A.; KLIMOV, O. Proximal policy optimization algorithms. **CoRR**, abs/1707.06347, 2017. Disponível em: <<http://dblp.uni-trier.de/db/journals/corr/corr1707.html#SchulmanWDRK17>>.

SEARLE, J. R. Minds, brains, and programs. Cambridge University Press, v. 3, n. 3, p. 417–424, 1980. ISSN 0140525X. Disponível em: <<https://www.cambridge.org/core/article/minds-brains-and-programs/DC644B47A4299C637C89772FACC2706A>>.

SELVARAJU, R. R.; DAS, A.; VEDANTAM, R.; COGSWELL, M.; PARIKH, D.; BATRA, D. Grad-cam: Why did you say that? visual explanations from deep networks via gradient-based localization. **CoRR**, abs/1610.02391, 2016. Disponível em: <<http://arxiv.org/abs/1610.02391>>.

SUTTON, R. S.; BARTO, A. G. **Reinforcement Learning: An Introduction**. 2. ed. Cambridge, MA: MIT Press, 2018. Disponível em: <<http://incompleteideas.net/book/the-book-2nd.html>>.

SUTTON, R. S.; MCALLESTER, D.; SINGH, S.; MANSOUR, Y. Policy gradient methods for reinforcement learning with function approximation. In: **Proceedings of the 13th International Conference on Neural Information Processing Systems**. Cambridge, MA, USA: MIT Press, 1999. (NIPS'99), p. 1057–1063.

THEOCHARIS, S. **easy-explain: Explainable AI with GradCam**. 2024. <<https://pub.towardsai.net/easy-explain-explainable-ai-with-gradcam-e187f85a697c>>. Acessado em: 12 de maio de 2026.

TURING, A. M. Computing machinery and intelligence. **Mind**, Oxford University Press on behalf of the Mind Association, v. 59, n. 236, p. 433–460, 1950. ISSN 00264423. Disponível em: <<http://www.jstor.org/stable/2251299>>.

VARELA, F. J. **Autopoiesis and a Biology of Intentionality**. 1991. Unpublished manuscript.

WYDMUCH, M.; KEMPKA, M.; JAŚKOWSKI, W. Vizdoom competitions: Playing doom from pixels. **IEEE Transactions on Games**, IEEE, 2018. IEEE Transactions on Games outstanding paper award 2022.

YANG, L.; LI, Y.; CHEN, L. Clothppo: a proximal policy optimization enhancing framework for robotic cloth manipulation with observation-aligned action spaces. In: **Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence**. [s.n.], 2024. (IJCAI '24). ISBN 978-1-956792-04-1. Disponível em: <<https://doi.org/10.24963/ijcai.2024/762>>.

ZHOU, B.; KHOSLA, A.; LAPEDRIZA, À.; OLIVA, A.; TORRALBA, A. Learning deep features for discriminative localization. **CoRR**, abs/1512.04150, 2015. Disponível em: <<http://arxiv.org/abs/1512.04150>>.